

# 目 录

<b>第一章 机动多目标跟踪理论与方法综述</b>	.....	(1)
1.1 引言	.....	(1)
1.2 机动多目标跟踪基本原理	.....	(2)
1.3 机动目标模型	.....	(4)
1.4 自适应滤波算法	.....	(7)
1.5 跟踪门的形成方法	.....	(13)
1.6 多目标数据关联与跟踪维持	.....	(17)
1.7 多目标跟踪起始与终结	.....	(25)
1.8 人工神经网络在多目标跟踪中的应用概述	.....	(30)
1.9 本书的主要工作与特色	.....	(31)

## 第一篇 神经网络跟踪理论

<b>第二章 基于神经网络的机动目标信息融合与并行自适应跟踪</b>	.....	(33)
2.1 引言	.....	(33)
2.2 问题描述	.....	(33)
2.3 多层前馈神经网络与 BP 学习算法	.....	(34)
2.4 基于神经网络的信息融合系统及其基本原理	.....	(36)
2.5 目标特征提取与网络离线训练	.....	(38)
2.6 基于神经网络的信息融合与并行自适应跟踪算法(NIFPAT)	.....	(39)
2.7 仿真结果	.....	(40)
2.8 结论	.....	(45)
<b>第三章 随机神经网络组合优化与多目标数据关联</b>	.....	(46)

3.1 引言 .....	(46)
3.2 JPDA 及其计算组合爆炸 .....	(46)
3.3 Hopfield 网络模型与旅行商问题(TSP) .....	(50)
3.4 神经联合概率数据关联(NJPDA) .....	(55)
3.5 随机神经网络与快速随机神经联合概率数据关联(FSNJPDA) .....	(58)
3.6 仿真结果 .....	(60)
3.7 结论 .....	(61)
<b>第四章 随机神经网络组合参数优化 .....</b>	<b>(64)</b>
4.1 引言 .....	(64)
4.2 参数稳定性、灵敏度和鲁棒性分析理论概述 .....	(64)
4.3 随机神经网络组合参数优化与关键性能参数的确定 .....	(65)
4.4 结论 .....	(68)
<b>第五章 基于随机神经网络的机动多目标跟踪维持 .....</b>	<b>(69)</b>
5.1 引言 .....	(69)
5.2 机动目标“当前”统计模型和均值与方差自适应算法 .....	(69)
5.3 快速随机神经联合概率数据关联自适应滤波算法 .....	(72)
5.4 计算机仿真 .....	(74)
5.5 结论 .....	(82)
<b>第六章 基于随机神经网络和 Bayes 后验推理的机动多目标跟踪起始与终结 .....</b>	<b>(84)</b>
6.1 引言 .....	(84)
6.2 主跟踪子空间与边缘跟踪子空间 .....	(85)
6.3 Bayes 轨迹确定与终结方法(BTCT) .....	(85)
6.4 基于随机神经网络的“全邻”Bayes 跟踪起始与终结算法(SNABTIT) .....	(86)
6.5 计算机仿真 .....	(88)
6.6 结论 .....	(91)
<b>第二篇 应用</b>	
<b>第七章 三维空间中的机动目标建模与自适应跟踪 .....</b>	<b>(92)</b>

7.1	引言	.....	(92)
7.2	目标运动模型	.....	(92)
7.3	目标量测噪声	.....	(96)
7.4	跟踪滤波算法	.....	(97)
7.5	性能评价方法	.....	(101)
7.6	Monte Carlo 仿真结果	.....	(102)
7.7	结论	.....	(103)
<b>第八章 三维空间中的机动多目标神经自适应跟踪</b>		.....	(104)
8.1	引言	.....	(104)
8.2	三维空间中的目标运动描述	.....	(104)
8.3	三维空间中的跟踪门设计	.....	(105)
8.4	三维空间中的机动多目标快速随机神经自适应跟踪	.....	(106)
8.5	计算机仿真	.....	(107)
8.6	结论	.....	(113)
<b>第九章 回顾与展望</b>		.....	(114)
9.1	引言	.....	(114)
9.2	研究成果回顾	.....	(114)
9.3	研究展望	.....	(116)
<b>参考文献</b>		.....	(118)

## CONTENTS

### Chapter 1 Survey on Theory and Methods of Multiple Maneuvering Target Tracking

- 1. 1 Introduction
- 1. 2 Basic Principle of Multiple Maneuvering Target Tracking
- 1. 3 Models of Maneuvering Targets
- 1. 4 Adaptive Filtering Algorithms
- 1. 5 Tracking Gating Methods
- 1. 6 Data Association and Tracking Maintenance of Multiple Targets
- 1. 7 Tracking Initiation and Termination of Multiple Targets
- 1. 8 Outline of Applications of Artificial Neural Networks to Multiple Targets Tracking
- 1. 9 Research work and Characteristic of This Book

### Part I Neural Networks-Based Tracking Theory

### Chapter 2 Neural Network-Based Information Fusion and Parallel Adaptive Tracking of Maneuvering Targets

- 2. 1 Introduction
- 2. 2 Problem Description
- 2. 3 Multi-Layered Feed-Forward Network and Back Propagation Algorithm
- 2. 4 System Structure of Neural Network-Based Information Fusion and Basic Principle

- 2. 5 Extract of Target Identity and Off-Line Training of Neural Network
  - 2. 6 Neural Network-Based Information Fusion and Parallel Adaptive Tracking Algorithm
  - 2. 7 Computer Simulation
  - 2. 8 Summary
- Chapter 3 Stochastic Neural Network and Data Association of Multiple Targets**
- 3. 1 Introduction
  - 3. 2 Joint Probabilistic Data Association and Its Computational Combinatorial Explosion
  - 3. 3 Hopfield Network and Traveling Salesman Problem
  - 3. 4 Neural Joint Probabilistic Data Association
  - 3. 5 Stochastic Neural Network and Fast Stochastic Neural Joint Probabilistic Data Association
  - 3. 6 Computer Simulation
  - 3. 7 Summary
- Chapter 4 Combinatorial Parameter Optimization of Stochastic Neural Network**
- 4. 1 Introduction
  - 4. 2 Analysis Theory of Parameter Stability, Sensitivity and Robustness
  - 4. 3 Combinatorial Parameter Optimization of Stochastic Neural Network and Confirmation of Key Performance Parameters
  - 4. 4 Summary
- Chapter 5 Stochastic Neural Network-Based Tracking Maintenance of Multiple Maneuvering Targets**
- 5. 1 Introduction
  - 5. 2 Current Statistical Model and Adaptive Tracking Algorithm

- 5.3 Fast Stochastic Neural JPDA and Adaptive Filtering Algorithm
- 5.4 Computer simulation
- 5.5 Summary

**Chapter 6 Stochastic Neural Network and Bayesian Inference-Based Tracking Initiation and Termination of Multiple Maneuvering Targets**

- 6.1 Introduction
- 6.2 Main and Margin Tracking Subspaces
- 6.3 Bayesian Track Confirmation and termination Method
- 6.4 Stochastic Neural Network and Bayesian Inference-Based All-Neighbors Tracking Initiation and Termination Algorithm
- 6.5 Computer Simulation
- 6.6 Summary

**Part I Applications**

**Chapter 7 Modelling and Adaptive Tracking of Maneuvering Targets in Three Dimensional Space**

- 7.1 Introduction
- 7.2 Target Motion Model
- 7.3 Target Measurement Noise
- 7.4 Tracking Filtering Algorithms
- 7.5 Performance Evaluation
- 7.6 Monte Carlo Simulation
- 7.7 Summary

**Chapter 8 Neural Network-Based Adaptive Tracking of Multiple Maneuvering Targets in Three Dimensional Space**

- 8.1 Introduction

- 8. 2 Description of Target Motion in Three Dimensional Space**
- 8. 3 Design of Tracking Gate in Three Dimensional Space**
- 8. 4 Fast Stochastic Neural Adaptive Tracking Algorithm in Three Dimensional Space**
- 8. 5 Computer Simulation**
- 8. 6 Summary**

**Chapter 9 Review and Perspective**

- 9. 1 Introduction**
- 9. 2 Review of Research work**
- 9. 3 Perspective for Further Research work**

**References**

# 第一章 机动多目标跟踪理论与方法综述

## 1.1 引言

机动多目标跟踪(MMTT—Multiple Maneuvering Target Tracking)理论是运用随机统计决策、自适应滤波、知识工程和神经网络等现代技术,将探测器所接收到的信号数据分解为对应于各种不确定机动信息源所产生的不同观测集合或轨迹,一旦轨迹被确认,则被跟踪的目标数目以及对应于每一条运动轨迹的目标状态参数,如位置、速度和加速度等均可相应地估计出来。所涉及的问题是控制、指挥、通信和情报(C<sup>3</sup>I)学科发展的前沿问题,是当前国际上的热门研究方向。

MMTT 理论在国防和民用领域具有重要的应用价值。在国防上,它可用于反弹道导弹的防御,空防预警,地对空、舰对空、舰对舰、空对空的超视距多目标探测、跟踪与攻击,战场监视空地(海)多目标,精确制导和低空突防等。在民用领域,它可用于空中交通管制,防撞,导航及机器人视觉等。在 1991 年的海湾战争中,以美国为首的多国部队所使用的先进机载火控系统、空中预警飞机和地面“爱国者”防空导弹系统等武器装备,就是多目标跟踪技术综合运用的典型例证。

多目标跟踪的基本概念首先由 Wax<sup>[1]</sup> 在 1955 年提出。1964 年,Sittler<sup>[2]</sup> 在包括数据关联等内容的多目标跟踪理论方面取得了开创性突破,然而,Sittler 的工作出现在广泛应用递推卡尔曼滤波技术<sup>[3]</sup>之前。直到 70 年代初期,多目标跟踪理论才引起人们的极大兴趣。之后,由 Bar-Shalom<sup>[4,5]</sup> 和 Singer<sup>[6,7]</sup> 所进行的工作才开始了现代多目标跟踪理论及其应用研究的进一步发展,其主要

标志是数据关联与滤波理论的有机结合。80年代以来,以非线性大规模并行分布式处理为主流的神经网络研究的再次兴起<sup>[8~12]</sup>,为MMTT的研究注入了新的活力,给传统跟踪理论难以逾越的“鸿沟”,如计算组合爆炸等问题的有效解决带来了光明。

MMTT问题包括许多方面<sup>[13]</sup>,主要有机动目标模型与自适应跟踪算法、跟踪门(关联区域)的形成、数据关联、跟踪维持、跟踪起始与终结、漏报与虚警等。其中,数据关联是机动多目标跟踪技术中最重要而又最困难的方面。

## 1.2 机动多目标跟踪基本原理

所谓多目标跟踪,就是主体为了维持对多个目标(客体)当前状态的估计而对所接收到的量测信息进行处理的过程。通常,这些量测信息不是原始数据,而是检测子系统和信号处理器的输出<sup>[14]</sup>。图1.1是一个典型的机动多目标跟踪系统框图。其中,信息处理器子系统即本文将要重点研究的MMTT系统。

由于实际环境中现代高速机动多目标常常表现出两种不确定性:一是运动状态变化的不确定性;二是量测(信息)源的不确定性。这就要求MMTT系统必须适应机动的变化,同时作出正确的相关决策。

图1.2给出了一种简单的MMTT系统基本原理框图。这里着重描述各环节之间的相互关系。

设整个流程为递推过程,并且在先前扫描期间各目标轨迹已经形成。由探测器接收到的量测数据首先被考虑用于更新已建立的目标轨迹;跟踪门被用来粗略确定量测/轨迹配对是否合理;数据关联则用于最后确定最合理的量测/轨迹配对;然后,跟踪维持包括机动识别和自适应滤波与预测估计出各目标轨迹的真实状态;在跟踪空间中,那些不与已经建立的目标轨迹相关的量测或回波可能来自潜在的新目标或虚警,由跟踪起始方法可鉴别真伪,并相应地建立新的目标档案;当目标逃离跟踪空间或被摧毁时,由跟

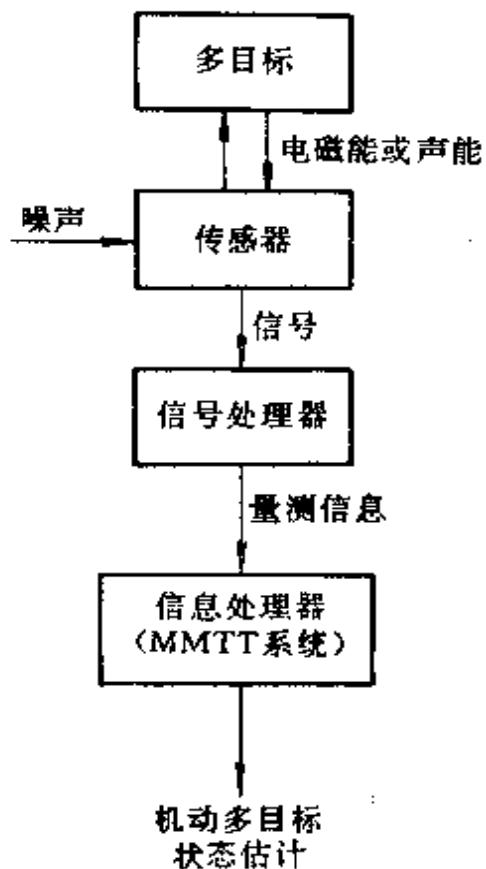


图 1.1 一个典型的机动多目标跟踪系统框图

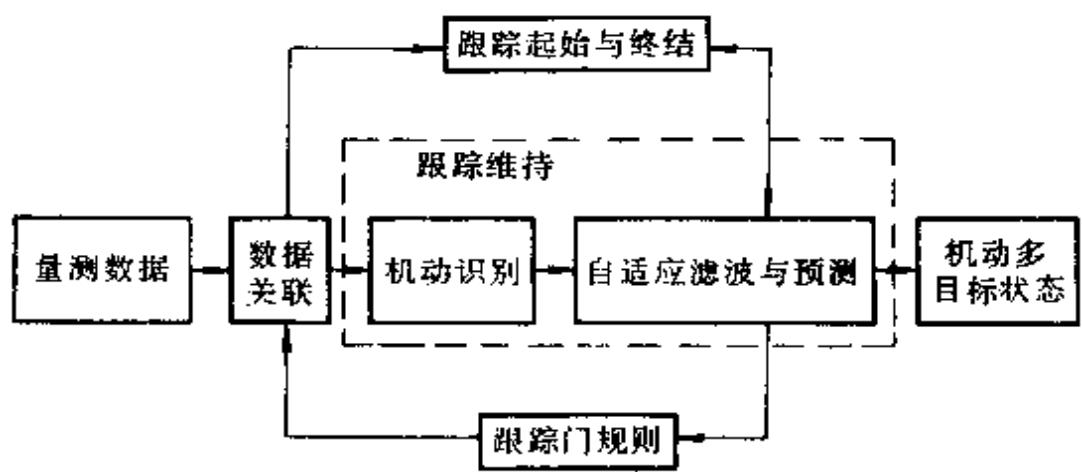


图 1.2 MMTT 系统基本原理框图

踪终结方法可消除多目标档案,以减轻不必要的计算负荷。最后,在新的量测到达之前,由目标预测状态和接收正确回波的概率可以确定下一时刻的跟踪门中心和大小,并重新开始下一时刻的递推循环。

### 1.3 机动目标模型

#### 1.3.1 CV 和 CA 模型

当目标无机动,即目标作匀速或匀加速直线运动时,可分别采用下面的二阶常速(CV)模型或三阶常加速(CA)模型<sup>[15,16]</sup>:

CV 模型

$$\begin{bmatrix} \dot{x} \\ \ddot{x} \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} x \\ \dot{x} \end{bmatrix} + \begin{bmatrix} 0 \\ 1 \end{bmatrix} w(t) \quad (1.1)$$

CA 模型

$$\begin{bmatrix} \dot{x} \\ \ddot{x} \\ \dddot{x} \end{bmatrix} = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} x \\ \dot{x} \\ \ddot{x} \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} w(t) \quad (1.2)$$

式中,  $x$ 、 $\dot{x}$  和  $\ddot{x}$  分别为目标的位置、速度和加速度分量;  $w(t)$  是均值为零、方差为  $\sigma^2$  的白噪声。

若目标发生机动,即运动目标的加速度向量发生变化时,一般有下面介绍的机动目标模型可供借鉴。

#### 1.3.2 时间相关模型(Singer 模型)

1970 年,Singer<sup>[17]</sup>首次假设机动加速度  $a(t)$  服从一阶时间相关过程,其时间相关函数为指数衰减形式:

$$R_a(\tau) = E\{a(t)a(t+\tau)\} = \sigma_a^2 e^{-\alpha|\tau|} \quad a \geq 0 \quad (1.3)$$

式中,  $\sigma_a^2$  为目标加速度方差;  $\alpha$  为机动频率。同时假定加速度均值为零,加速度的概率密度函数近似服从均匀分布,方差  $\sigma_a^2$  为

$$\sigma_a^2 = \frac{A_{\max}^2}{3}(1 + 4P_{\max} - P_0) \quad (1.4)$$

式中,  $A_{\max}$  为最大机动加速度;  $P_{\max}$  为其发生概率;  $P_0$  非机动发生概率。

对时间相关函数  $R_a(\tau)$  应用 Wiener-Kolmogorov 白化方法<sup>[13]</sup>, 机动加速度  $a(t)$  可用输入为白噪声的一阶时间相关模型来表示, 即

$$\dot{a}(t) = -\alpha a(t) + w(t) \quad (1.5)$$

这时, 目标运动方程可表示为

$$\begin{bmatrix} \dot{x} \\ \ddot{x} \\ \vdots \\ \ddot{x} \end{bmatrix} = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ \vdots & 0 & 0 \end{bmatrix} \begin{bmatrix} x \\ \dot{x} \\ \vdots \\ \ddot{x} \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{bmatrix} w(t) \quad (1.6)$$

式中,  $w(t)$  是均值为零, 方差为  $2\alpha\sigma_a^2$  的白噪声。

Singer 模型即一阶时间相关模型只适用于等速和等加速范围内的目标运动。对于超出此范围的运动, 可采用高阶时间相关模型<sup>[14]</sup>。

### 1.3.3 半马尔可夫模型

Singer 模型为零均值模型。这种零均值特性对于模拟目标机动似乎不太合理。为此, Moose 等<sup>[18~20]</sup>提出了具有随机开关均值的相关高斯噪声模型, 该模型把机动看作为相应于半马尔可夫过程<sup>[15]</sup>描述的一系列有限指令, 该指令由马尔可夫过程的转移概率来确定, 转移时间为随机变量。半马尔可夫模型为

$$\begin{bmatrix} \dot{x} \\ \ddot{x} \\ \vdots \\ \ddot{x} \end{bmatrix} = \begin{bmatrix} 0 & 1 & 0 \\ 1 & -\theta & 0 \\ \vdots & 0 & 0 \end{bmatrix} \begin{bmatrix} x \\ \dot{x} \\ \vdots \\ \ddot{x} \end{bmatrix} + \begin{bmatrix} 0 \\ 1 \\ \vdots \\ 0 \end{bmatrix} u(t) + \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{bmatrix} w(t) \quad (1.7)$$

式中,  $\theta$  为阻力系数;  $u(t)$  为确定性输入指令;  $\alpha$  为机动频率;  $w(t)$  为白噪声。比较(1.7)和(1.6)两式可见, 两模型的主要差别在于前

者引入了非零加速度 $u(t)$ 。

### 1.3.4 Novak 统计模型

Kendrick 等<sup>[22]</sup>把机动目标法向加速度的大小 $a_n$ 描述为非对称分布的时间相关过程,其概率密度的非对称性用如下确定性非线性函数来表示:

$$a_n(t) = b + c \cdot e^{d + \epsilon(t)} \quad (1.8)$$

式中, $b$ 、 $c$  和  $d$  是对应于目标特性的常数。其中零均值时间相关高斯过程 $\epsilon(t)$ 满足

$$\dot{\epsilon}(t) = -\frac{1}{\alpha} \epsilon(t) + w(t) \quad (1.9)$$

式中, $\alpha$  为机动频率; $w(t)$ 是均值为零,方差为 $2/\alpha$  的高斯白噪声。

选择一组特定的目标常数( $b, c, d$ ),就可得到一个确定的法向加速度概率密度函数。不难看到,尽管用这种方法来描述目标法向加速度大小时状态方程是非线性的,但其特点在于白色高斯过程能直接传播,且能保持概率密度函数的非对称性质。该模型被认为是现代载人飞行器逃避机动的典型模型。

### 1.3.5 机动目标“当前”统计模型

周宏仁教授认为<sup>[13, 23, 24]</sup>,当目标正以某一加速度机动时,下一时刻的加速度取值是有限的,且只能在“当前”加速度的邻域内,为此提出机动目标“当前”统计模型。该模型本质上是非零均值时间相关模型,加速度的“当前”概率密度用修正的瑞利分布描述,均值为“当前”加速度预测值,随机加速度在时间轴上符合一阶时间相关过程,即

$$\ddot{x}(t) = \bar{a}(t) + a(t) \quad (1.10)$$

$$\dot{a} = -\alpha a(t) + w(t) \quad (1.11)$$

式中, $\bar{a}(t)$ 为加速度“当前”均值,在采样周期内假设为常数。并且有

$$\ddot{x}(t) = -\alpha \ddot{x}(t) + \alpha \bar{a}(t) + w(t) \quad (1.12)$$

最后，“当前”统计模型的形式为

$$\begin{bmatrix} \dot{x} \\ \ddot{x} \\ \vdots \\ \ddot{x} \end{bmatrix} = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ \vdots & 0 & 0 \\ 0 & 0 & -\alpha \end{bmatrix} \begin{bmatrix} x \\ \dot{x} \\ \vdots \\ \ddot{x} \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \\ \vdots \\ \alpha \end{bmatrix} \bar{a}(t) + \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{bmatrix} w(t) \quad (1.13)$$

由于该模型采用非零均值和修正瑞利分布表征机动加速度特性，因而更加符合实际<sup>[25]</sup>。与传统的 Singer 模型相比，它能更为真实地反映目标机动范围和强度的变化，是目前较好的实用模型。

关于其他模型，由于不太实用，这里就不一一列举了。

## 1.4 自适应滤波算法

一般地讲，基于前述机动目标模型和各种基本滤波与预测方法<sup>[13]</sup>，如线性自回归滤波、两点外推滤波、维纳滤波、最小二乘滤波、 $\alpha-\beta$  和  $\alpha-\beta-\gamma$  滤波、卡尔曼滤波和简化的卡尔曼滤波等，都很难在目标各种运动状态下使滤波器具有良好的跟踪性能。为此，许多学者致力于对各种自适应滤波算法的研究并取得很多重要成果。这些算法概括起来大致可以分为三类：检测自适应滤波、实时辨识自适应滤波和“全面”自适应滤波。

### 1.4.1 检测自适应滤波

检测自适应滤波的基本思想是：机动的发生使原来的模型变差，从而造成目标状态估计偏离真实状态，滤波残差（新息）特性发生变化。根据残差过程的变化，可设计出机动检测准则，一旦检测到机动发生或消除，立即进行模型转换或噪声方差调整。此类算法的关键在于设计出合理的检测方式，包括检测门限的选择以及恰当的模型转换与调整等，不足之处是在机动发生和检测时刻之间存在不可避免的时间延迟。典型方法有下列几种。

#### 一、决策自适应跟踪器

1973 年，McAulay 和 Denlinger<sup>[26]</sup>根据新息过程统计特性的

变化,提出了一种机动检测器和自适应跟踪算法。该算法采用 CV 模型,检测原理是这样的:设非机动时目标的新息序列为

$$d_0(k) = y_0(k) - \mathbf{H}(k)\hat{\mathbf{X}}_0(k/k-1) = \mathbf{H}(k)\hat{\mathbf{X}}_0(k/k-1) + v(k) \quad (1.14)$$

一旦目标在第  $k_0$  时刻开始机动,由于所用模型的不精确性,估计误差  $\tilde{\mathbf{X}}(k/k-1)$  将大于  $\hat{\mathbf{X}}_0(k/k-1)$ ,这时

$$\mathbf{H}(k)\tilde{\mathbf{X}}(k/k-1) = \mathbf{H}(k)\hat{\mathbf{X}}_0(k/k-1) + Mu(k-k_0) \quad (1.15)$$

式中, $u(k-k_0)$  为单位阶跃函数; $M$  为与目标机动大小相关的偏差值; $\mathbf{H}(k)$  为量测矩阵; $y(k)$  为量测量。从而,机动目标的新息变为

$$d(k) = \mathbf{H}(k)\tilde{\mathbf{X}}(k/k-1) + v(k) = d_0(k) + Mu(k-k_0) \quad (1.16)$$

根据决策理论,偏差  $M$  的检测可化为下列假设检验:

$$H_1: \text{机动} \quad d(k) = d_0(k) + Mu(k-k_0) \quad (1.17)$$

$$H_0: \text{非机动} \quad d(k) = d_0(k) \quad (1.18)$$

决定  $H_0$  或  $H_1$  的最优检验可采用广义似然比,统计规则为

$$D(k) = \left\{ \sum_{i=0}^k d^2(i) - \min_{m, k_0, i=0} \sum_{i=k_0}^k [d(i) - Mu(i-k_0)]^2 \right\} \frac{H_1}{H_0} \gtrless \lambda \quad (1.19)$$

式中, $\lambda$  为某一给定门限。

若令  $k_0 = k - \delta$ ,  $\delta = 1, 2, \dots, \Delta$ , 则上式等价于

$$D(k) = \prod_{\delta=1,2,\dots,\Delta}^{\max} \left\{ \sum_{i=1}^k d^2(i) - \sum_{i=1}^k [d(i) - Mu(i-k+\delta)]^2 \right\} \frac{H_1}{H_0} \gtrless \lambda \quad (1.20)$$

为了实现上述假设检验,需要设计出一组具有不同  $\delta$  值的滤波器。

## 二、Thorp 检测器

1973 年,Thorp<sup>[27]</sup>提出了另一种基于机动检测的跟踪方法。该方法假设机动是偶然事件,而且机动的发生是瞬时的。

目标的运动通过在状态方程中引入一个二进制随机变量来描

述,即

$$\dot{X}(k+1) = \Phi(k)X(k) + \rho(k)w(k) \quad (1.21)$$

式中,  $\rho(k)$  为取值为 0 和 1 的标量, 并且

$$\left. \begin{array}{l} \rho(k)=0, \forall k \neq n \\ P\{\rho(k)=1\}=p \\ P\{\rho(k)=0\}=1-p \end{array} \right\} \quad (1.22)$$

上式表明, 强迫项  $w(k)$  仅在  $n=k$  瞬时以概率  $p$  出现。可以证明<sup>[28,29]</sup>, 瞬时机动发生后的最优估计是两个卡尔曼滤波器输出的加权和:

$$\begin{aligned} \dot{X}(n+\Delta/n+\Delta) &= L_1(y^\Delta)\dot{X}_0(n+\Delta/n+\Delta) \\ &\quad + L_2(y^\Delta)\dot{X}_1(n+\Delta/n+\Delta) \end{aligned} \quad (1.23)$$

加权系数为

$$L_2(y^\Delta) = \left[ 1 + \frac{(1-p)f_0(y^\Delta/y^{n-1})}{pf_1(y^\Delta/y^{n-1})} \right]^{-1} \quad (1.24)$$

$$L_1(y^\Delta) = 1 - L_2(y^\Delta) \quad (1.25)$$

式中,  $y^{n-1} \triangleq [y(1), \dots, y(n-1)]^T$ ;  $y^\Delta \triangleq [y(n), \dots, y(n+\Delta)]^T$ ; 下标为 0 和 1 的量对应于  $\rho(k)=0$  和  $\rho(k)=1$  的相应量;  $f$  为概率密度函数。

定义似然比

$$L_r(y^\Delta) = \frac{f_0(y^\Delta/y^{n-1})}{f_1(y^\Delta/y^{n-1})} \quad (1.26)$$

在给定量测  $y^\Delta$  条件下的假设检验为

$$\left. \begin{array}{l} H_0: \rho(n)=0 \\ H_1: \rho(n)=1 \end{array} \right\} \quad (1.27)$$

从似然比导出的假设检验统计准则如下:

对单个量测, 有

$$D_r(k) = d^T(k)[S_0^{-1}(k) - S_1^{-1}(k)]d(k) \stackrel{H_1}{\gtrless} \lambda \quad (1.28)$$

对多个量测, 有

$$D_m(k) = \sum_{i=k}^{k+1} d_0^T(i) S_0^{-1}(i) d_0(i) - \sum_{i=k}^{k+1} d_1^T(i) S_1^{-1}(i) d_1(i) \frac{H_1}{H_0} \geq \lambda \quad (1.29)$$

式中,  $\lambda$  为某一给定的门限。

该方法的不足之处是对机动的假设过于苛刻, 即认为机动的发生是瞬时事件。

### 三、输入(加速度)估计器

1979年, Chan 等提出了另一种跟踪机动目标的检测方法<sup>[30]</sup>, 这种方法不依赖于机动特性的先验知识, 而把机动速度看成是未知的确定性输入, 利用加权最小二乘法从残差中估计出机动加速度大小, 并用来更新目标的状态。

目标的状态方程为

$$\mathbf{X}(k+1) = \Phi \mathbf{X}(k) + \mathbf{B} u(k) + \mathbf{D} w(k) \quad (1.30)$$

式中,  $u(k)$  是未知的机动加速度输入;  $w(k)$  为状态噪声, 状态分量仅包含位置和速度。

设  $\mathbf{D}_0(k)$  和  $\mathbf{D}_1(k)$  分别为  $u(k) \equiv 0$  和  $u(k) \not\equiv 0$  的残差序列。假定目标在时间  $kT$  之前不发生机动, 而从时间  $kT$  开始以输入序列  $u(k), u(k+1), \dots, u(k+\Delta)$  机动, 则两残差序列之间的关系为

$$\mathbf{D}_0 = \mathbf{X} u + \mathbf{D}_1 \quad (1.31)$$

式中  $\mathbf{D}_0 = [d_0(k+1), \dots, d_0(k+\Delta)]^T$

$$\mathbf{D}_1 = [d_1(k+1), \dots, d_1(k+\Delta)]^T$$

$$u(k+i) = u \quad (i=1, \dots, \Delta)$$

且

$$\mathbf{X} = \begin{bmatrix} \mathbf{H} \mathbf{B} \\ \mathbf{H}[(\Phi - \mathbf{K}(k+1) \mathbf{H} + \mathbf{I}) \mathbf{B}] \\ \vdots \\ \mathbf{H} \left\{ \sum_{m=0}^{\Delta-2} \left[ \prod_{i=0}^m (\Phi - \mathbf{K}(k+\Delta-i-1) \mathbf{H}) \right] + \mathbf{I} \right\} \mathbf{B} \end{bmatrix} \quad (1.32)$$

式中  $\mathbf{K}(k)$  为第  $k$  时刻的滤波增益。 $\mathbf{D}_1$  的协方差矩阵为

$$\mathbf{S}_1 = \begin{bmatrix} s_1(k+1) \\ & s_1(k+2) \\ & & \ddots \\ & & & s_1(k+\Delta) \end{bmatrix} \quad (1.33)$$

$\boldsymbol{u}$  的加权最小二乘估计为

$$\hat{\boldsymbol{u}} = (\boldsymbol{X}^T \mathbf{S}_1^{-1} \boldsymbol{X})^{-1} (\boldsymbol{X}^T \mathbf{S}_1^{-1} \mathbf{D}_1) \quad (1.34)$$

机动目标的最优状态估计由  $\hat{\boldsymbol{u}}$  来修正, 即

$$\hat{\boldsymbol{X}}_1(k+\Delta+1/k+\Delta+1) = \hat{\boldsymbol{X}}_0(k+\Delta+1/k+\Delta+1) + M\hat{\boldsymbol{u}} \quad (1.35)$$

$$M = \left( \sum_{m=0}^{\Delta-1} \left[ \prod_{i=0}^m (\boldsymbol{\Phi} - \mathbf{K}(k+\Delta-i) \mathbf{H}) \right] + I \right) \mathbf{B} \quad (1.36)$$

式中,  $\hat{\boldsymbol{X}}_0(*)$  为非机动时目标状态的最优估计。

1982 年, Chan 等进一步发展了上述方法<sup>[31]</sup>; 1987 年, Bogler 提出改进的输入估计器<sup>[32]</sup>, 在准确地检测机动和修正机动加速度不连续性方面发展了上述思想。

#### 四、变维滤波(VDF)

Bar-Shalom 等<sup>[33]</sup>提出了称为 VDF 的机动检测自适应算法。该算法把机动看成是目标动态特性的内部变化, 而不是状态噪声方差的加入。检测手段采用平均残差法, 调整方式采用“开关”型转换。非机动时, 滤波器工作在 CV 模型上, 一旦检测到机动, 滤波器便转到 CA 模型上, 再由非机动检测器检测机动消除进而转到原来的 CV 模型。

设  $\mu(k)$  为基于 CV 模型的残差衰减记忆平均:

$$\mu(k) = \alpha \mu(k-1) + g(k) \quad (1.37)$$

式中,  $\alpha = 1 - \frac{1}{\Delta}$ , 且  $0 < \alpha < 1$ ,  $\Delta$  为机动检测时间;  $g(k)$  为残差范数。一旦  $\mu(k)$  超过某一门限, 便接受机动假设。非机动假设是检验下式

$$\mu_a(k) = \sum_{i=k-\Delta+1}^k g_a(i) \quad (1.38)$$

是否低于另一给定门限, 式中  $g_a(i)$  为加速度残差范数。

### 1.4.2 实时辨识自适应滤波

实时辨识自适应滤波指在线辨识出机动加速度或其统计特性(表现为均值和方差等)。典型方法有下列几种。

#### 一、自适应状态估计器

Moose 等<sup>[18~20]</sup>在半马尔可夫模型基础上,把目标机动输入  $u(t)$  看作为半马尔可夫过程,根据先验概率选择  $N$  个可能的机动输入  $u(t)=u_1, \dots, u_N$ , 并构造出带一组确定性指令的卡尔曼滤波器。这样,目标状态的最优估计等于机动指令输入条件估计的加权和。

设  $\hat{X}_i(k/k)$  表示第  $i$  个指令输入作用下目标状态的最优估计,那么基于量测序列  $Y^k = \{y(1), \dots, y(k)\}$ , 自适应状态估计为

$$\hat{X}(k/k) = \sum_{i=1}^N \lambda_i(k) \hat{X}_i(k/k) \quad (1.39)$$

式中

$$\hat{X}_i(k/k) = E\{X(k)/u_i(k-1), Y^k\} \quad (1.40)$$

$$\begin{aligned} \lambda_i(k) &= P\{u(k)=u_i/Y^k\} \\ &= cp\{y(k)/u_i(k-1), Y^{k-1}\} \cdot \sum_{j=1}^N \theta_{ij} \lambda_j(k-1) \end{aligned} \quad (1.41)$$

式中,  $c$  为归一化常数。马尔可夫转移概率为

$$\theta_{ij} = P\{u(k)=u_i/u(k-1)=u_j\} \quad (1.42)$$

概率密度函数  $p\{y(k)/u_i(k-1), Y^{k-1}\}$  近似服从正态分布, 即

$$p\{y(k)/u_i(k-1), Y^{k-1}\} = N\{\mathbf{H}(k)\hat{X}_i(k/k-1), \mathbf{P}(k/k-1)\} \quad (1.43)$$

上述方法实质上是多模型估计器在目标跟踪中的应用。然而,当这种方法以其完备形式表示时, 相应于一组连续增长的机动输入指令, 将会需要一组连续增长的卡尔曼滤波器, 特别当机动输入划分较细时, 所需并行滤波器较多, 相当大的计算负荷将会使这种技术既不易实现也不经济。

#### 二、基于“当前”统计模型的均值和方差自适应滤波算法

周宏仁<sup>[22,23,24]</sup>在机动目标“当前”统计模型基础上, 提出了相

应的均值和方差自适应跟踪算法。该算法采用修正瑞利分布来描述机动加速度的统计特性,因而更加合乎实际。同时,所假设的分布具有这样一个突出优点:分布随均值而变化,方差由均值决定。与以往的方法不同,这里的机动加速度是连续变化的,其均值等于当前时刻加速度分量的预测值。这样,在估计目标状态的同时,还可辨识出机动加速度均值,从而实时地修正加速度分布,并通过方差反馈到下一时刻的滤波增益上,实现了闭环自适应跟踪。具体算法详见第五章。

### 1.4.3 全面自适应滤波

实时辨识自适应滤波能较好地反映目标机动范围和强度的变化,机动时跟踪效果很好,但非机动时性能有所下降;而检测自适应滤波在非机动时跟踪精度较高,机动时性能较差。自然就产生了两类方法综合发展的趋势——全面自适应滤波。典型方法是交互式多模型算法。

1984~1989年,Blom 和 Bar-Shalom 在广义伪贝叶斯算法基础上,提出了一种具有马尔可夫切换系数的交互式多模型(IMM)算法<sup>[34~36]</sup>,其中多种模型并行工作,目标状态估计是多个滤波器交互作用的结果。该算法不需要机动检测,同时达到了全面自适应跟踪能力。具体算法详见第七章。

## 1.5 跟踪门的形成方法

跟踪门是跟踪空间中的一块子空间,中心位于被跟踪目标的预测位置,其大小由接收正确回波的概率来确定。落入跟踪门内的回波称为候选回波。跟踪门的形成既是限制不可能决策数目的关键环节,又是维持跟踪的先决条件。

假定量测维数为  $M$ ,滤波残差向量  $\mathbf{d}(k)$  的范数为

$$g(k) = \mathbf{d}^T(k) \mathbf{S}^{-1}(k) \mathbf{d}(k) \quad (1.44)$$

式中,  $\mathbf{S}(k)$  为残差协方差矩阵。可以证明<sup>[37]</sup>,  $g(k)$  服从自由度为  $M$

的  $\chi^2$  分布, 残差向量  $d(k)$  的  $M$  维高斯概率密度函数为

$$f[d(k)] = \frac{e^{-\frac{d(k)^2}{2}}}{(2\pi)^{M/2} \sqrt{|S(k)|}} \quad (1.45)$$

### 1.5.1 矩形跟踪门

最简单的跟踪门形成方法是在跟踪空间内定义一个矩形区域, 即矩形跟踪门<sup>[38]</sup>。

设残差向量  $d(k)$ , 量测向量  $Y(k)$  和预测量测向量  $\hat{Y}(k/k-1)$  的第  $i$  个分量分别为  $d_i(k)$ ,  $y_i(k)$  和  $\hat{y}_i(k/k-1)$ , 且对所有的  $i$  有相同的跟踪门常数  $K_G$ , 则当量测向量  $Y(k)$  满足关系

$$|y_i(k) - \hat{y}_i(k/k-1)| = |d_i(k)| \leq K_G \cdot \sigma_n \quad (i=1, 2, \dots, M) \quad (1.46)$$

时, 称  $Y(k)$  为候选回波。这里  $\sigma_n$  为第  $i$  个残差的标准偏差, 其大小为

$$\sigma_n = \sqrt{\sigma_w^2 + \sigma_p^2} \quad (1.47)$$

式中,  $\sigma_w^2$  为第  $i$  个量测噪声方差;  $\sigma_p^2$  为一步预测协方差矩阵的第  $i$  个对角线元素。

正确回波落入矩形跟踪门的概率为

$$\begin{aligned} P_G &= \int_{V_G} \cdots \int f[d(k)] dd_1 \cdots dd_M \\ &= \int_{-K_G}^{K_G} \frac{e^{-\frac{u_1^2}{2}}}{\sqrt{2\pi}} du_1 \cdots \int_{-K_G}^{K_G} \frac{e^{-\frac{u_m^2}{2}}}{\sqrt{2\pi}} du_m \\ &= [p(|t| \leq K_G)]^m = [1 - p(|t| > K_G)]^m \end{aligned} \quad (1.48)$$

式中

$$t = \frac{u}{\sqrt{2\pi}}$$

正确回波位于矩形跟踪门之外的概率为

$$\bar{P}_G = P(|t| > K_G) = 1 - P_G \quad (1.49)$$

式中,  $V_G$  为矩形跟踪门体积; 变换关系为  $u_i = d_i(k)/\sigma_n$ ; 随机变量

$t$  服从标准正态分布  $N(0, 1)$ ;  $P(|t| \leq K_G)$  和  $P(|t| > K_G)$  分别为接收和拒绝正确回波的概率。

当所选概率  $P_G$  较小时, 式(1.48)有下列近似关系

$$P_G \approx 1 - M\bar{P}_G \quad (1.53)$$

$M$  维矩形跟踪门的体积为

$$V_{GR}(M) = \int_{-K_G\sigma_1}^{K_G\sigma_1} dd_1 \cdots \int_{-K_G\sigma_M}^{K_G\sigma_M} dd_M = (2K_G)^M \prod_{i=1}^M \sigma_i \quad (1.54)$$

由残差方差归一化的  $M$  维矩形跟踪门体积为

$$V_{GR_1}(M) = (2K_G)^M \quad (1.55)$$

当每一个残差分量  $d_i(k)$  对应的跟踪门常数  $K_G$  互不相同时,  $M$  维矩形跟踪门体积公式分别变为

$$V_{GR_1}(M) = 2^M \prod_{i=1}^M K_{Gi} \sigma_{ri} \quad (1.56)$$

$$V_{GR_2}(M) = 2^M \prod_{i=1}^M K_{Gi} \quad (1.57)$$

### 1.5.2 椭球跟踪门

设  $\gamma$  为椭球跟踪门的门限大小, 当回波  $\mathbf{Y}(k)$  满足关系

$$\mathbf{g}(k) = \mathbf{d}^T(k) \mathbf{S}^{-1}(k) \mathbf{d}(k) \leq \gamma \quad (1.58)$$

时, 称  $\mathbf{Y}(k)$  为候选回波, 此即椭球跟踪门规则。

正确回波落入椭球跟踪门内的概率为

$$P_G(M) = P\{\chi_m^2 \leq \gamma\} = \int \cdots \int f(\mathbf{d}(k)) dd_1 \cdots dd_M \quad (1.59)$$

相应地, 跟踪门拒绝正确回波的概率为

$$\bar{P}_G(M) = P\{\chi_m^2 > \gamma\} = 1 - P_G(M) \quad (1.60)$$

对式(1.55)施行从  $\mathbf{d}$  到  $\mathbf{w}$  的变换以使残差协方差矩阵的非对角线元素为零, 则跟踪门规则变为

$$\frac{w_1^2}{\sigma_{w_1}^2} + \frac{w_2^2}{\sigma_{w_2}^2} + \cdots + \frac{w_M^2}{\sigma_{w_M}^2} \leq \gamma \quad (1.61)$$

进一步施行  $v_i = w_i / \sigma_{w_i}$  变换, 上式变为

$$r^2 = v_1^2 + v_2^2 + \cdots + v_m^2 \leq \gamma \quad (1.59)$$

再令  $z = r^2$ , 经推导可得

$$f(z) = \frac{z^{\frac{M}{2}-1} e^{-\frac{z}{2}}}{2^{\frac{M}{2}} \Gamma(\frac{M}{2})} \quad (1.60)$$

从而有

$$P_G(M) = \int_0^\gamma f(z) dz \quad (1.61)$$

最后,  $M$  维椭球跟踪门的体积为

$$V_{GE1}(M) = C_M \sqrt{|\mathbf{S}(k)|} \gamma^{M/2} \quad (1.62)$$

由  $\mathbf{S}(k)$  归一化的  $M$  维椭球跟踪门体积为

$$V_{GE2}(M) = C_M \gamma^{M/2} \quad (1.63)$$

式中

$$C_M = \frac{\pi^{M/2}}{\Gamma(\frac{M}{2})} \quad (1.64)$$

### 1.5.3 其他跟踪门

文献[39]推导了球面坐标系下扇形跟踪门的计算公式。

文献[40,41]根据椭球跟踪门规则, 给定了最优的极大似然门限  $\gamma_0$ , 以使得位于跟踪门内的正确回波最大可能来自被跟踪的目标, 而不是杂波。最优门限  $\gamma_0$  的表示式为

$$\gamma_0 = 2 \ln \left[ \frac{P_D}{(1-P_D)\beta(2\pi)^{M/2} \sqrt{|\mathbf{S}(k)|}} \right] \quad (1.65)$$

式中,  $P_D$  为检测概率;  $\beta$  为新源密度。

Lefferts<sup>[42]</sup>研究了边扫描边跟踪系统中使用  $\alpha-\beta$  滤波器时跟踪门的设计问题, 并证明了对于机动目标, 为了保证接收正确回波的概率为一常数, 跟踪门的大小应与非机动时跟踪门的大小有所不同。此结果表明, 在 MMTT 中, 跟踪门的设计确实是一项应当引起人们足够重视的问题。

## 1.6 多目标数据关联与跟踪维持

多目标数据关联与跟踪维持是多目标跟踪的核心部分,其中数据关联是多目标跟踪技术中最重要而又最困难的方面。

就多目标数据关联的基本方法而言<sup>[43]</sup>,主要有三类:一是面向目标的方法,其中假设置测来自己知的目标或杂波,典型方法有概率数据关联 PDA 和联合概率数据关联 JPDA;二是面向量测的方法,其中假设置测来自己知的目标、新目标或杂波,典型方法如多假设法;三是面向轨迹的方法<sup>[101,105]</sup>,其中假设轨迹未被检测、已经终结、与量测相关或者与机动起始相关。

就数学手段而言,主要有两种<sup>[13,44,45]</sup>,一种是利用空间累积信息的贝叶斯方法,另一种是依赖于时间累积信息的极大似然法。

密集回波环境下单目标跟踪的数据关联与跟踪维持典型方法有下列几种。

### 1.6.1 “最近邻”方法

Singer 等<sup>[46,47]</sup>提出了一种具有固定记忆要求并且能在多回波环境下工作的跟踪滤波器。这种滤波器仅利用在统计意义上与被跟踪目标预测位置(跟踪门中心)最近的回波作为候选回波,此决策方法等效于选择使统计距离最小或残差概率密度最大的回波。

显然,离目标预测位置最近的回波并非必定是目标回波,特别当跟踪器工作在密集回波环境中更是如此。因此,这种方法在实际应用中常常发生误跟和丢失目标的现象。

### 1.6.2 概率数据关联滤波(PDAF)

1972 年,Bar-Shalom 和 Jaffer<sup>[48]</sup>首先提出,有必要利用位于跟踪门内的所有回波以获得可能的后验信息。概率数据关联方法的最后形式则在 1975 年由 Bar-Shalom 与 Tse<sup>[49,50]</sup>给出。

将第  $k$  次扫描时候选回波的集合表示为

$$\mathbf{Y}_i = \{y_i(k)\}_{k=1}^{\xi_k} \quad (1.66)$$

由第 1 次至第  $k$  次扫描所获得的全部候选回波表示为

$$\mathbf{Y}^k = \{\mathbf{Y}_j\}_{j=1}^k \quad (1.67)$$

定义下列事件

$$\epsilon_{k,i} = \{y_i(k) \text{ 为正确回波}\} \quad (i=1, \dots, \xi_k) \quad (1.68)$$

$$\epsilon_{k,0} = \{\text{无候选回波为正确回波}\} \quad (1.69)$$

这样, 目标状态的最小方差估计或条件均值为

$$\begin{aligned} \hat{X}(k/k) &= E[X(k)/\mathbf{Y}^k] = \int X(k) P[X(k)/\mathbf{Y}^k] dX(k) \\ &= \sum_{i=0}^{\xi_k} \lambda_{k,i} E\{X(k)/\epsilon_{k,i}, Y^k\} \end{aligned} \quad (1.70)$$

式中

$$\lambda_{k,i} \triangleq P(\epsilon_{k,i}/\mathbf{Y}^k) \quad (i=0, 1, \dots, \xi_k) \quad (1.71)$$

被定义为每一候选回波来自被跟踪目标的后验概率。

这种算法的最大优点在于其最大存储量与标准卡尔曼滤波器几乎相等而且基本不变, 因此较易实现。

### 1.6.3 “全邻”最优滤波器

1974 年, Signer、Sea 和 Housewright<sup>[44]</sup>发展了一类“全邻”滤波器, 这种滤波器不仅考虑了所有候选回波(空间累积信息), 而且考虑了跟踪历史, 即多扫描相关(时间累积信息)。

假定多余回波(非目标回波)互不相关并且均匀分布于跟踪门内, 则任何体积  $V$  内多余回波的数目  $C$ , 服从均值为  $\beta V$  的泊松分布,  $\beta$  为未归一化的回波密度,  $C$  与扫描次序无关。

假定在  $k-1$  时刻, 轨迹  $a'$  正确的概率为  $P_a'(k-1)$ , 关键问题在于计算  $k$  时刻轨迹  $a$  为正确的概率  $P_a(k)$ 。轨迹  $a$  定义为

$$a = (a', i) \quad (1.72)$$

上式意味着轨迹  $a$  为  $k-1$  时刻的轨迹  $a'$  与  $k$  时刻所接收到的第一个回波的组合。

定义  $P_a(k)$  为

$$P_a(k) \leq P\{a', i/\xi_k, Y^k\} \quad (1.73)$$

其中  $\xi_k$  为第  $k$  次扫描期间的候选回波数。

由 Bayes 法则, 概率  $P_a(k)$  可計算如下:

$$\begin{aligned} P\{a', i/\xi_k, Y^k\} &= \frac{1}{C} P\{Y_k/a', i, \xi_k, Y^{k-1}\} \\ &\quad \cdot P\{i, \xi_k/a', Y^{k-1}\} \cdot P\{a', Y^{k-1}\} \end{aligned} \quad (1.74)$$

式中  $C$  为归一化常数。

可以证明, 由  $P_a'(k-1)$  计算  $P_a(k)$  的迭代公式为

$$P[a', i/\xi_k, Y^k] = \begin{cases} \frac{1}{C} \frac{\beta^{a_{k-1}}}{\xi_k!} e^{-\beta V_G} \cdot P_D \cdot N[\hat{Y} + H\mathbf{b}_a, S_a] \cdot P_a(k-1) & (i \neq 0) \\ \frac{1}{C} \frac{\beta^{a_k}}{\xi_k!} e^{-\beta V_G} (1 - P_D P_g) \cdot P_a(k-1) & (i = 0) \end{cases} \quad (1.75)$$

式中,  $V_G$  为跟踪门体积;  $P_D$  为检测概率;  $P_g$  为目标回波被检测且在跟踪门内的概率;  $N[* , **]$  表示均值为 \* , 方差为 \*\* 的高斯密度函数;  $\hat{Y}$  为目標预测状态;  $H$  为观测矩阵。

在存在轨迹  $a'(k-1)$  条件下, 当  $\hat{X}(k/k-1)$  的均值  $\mathbf{b}_a(k/k-1)$  及协方差矩阵  $P_a(k/k-1)$  给定时, 每一新轨迹  $a$  的状态预测偏差的均值  $\mathbf{b}_a(k/k-1)$  及协方差矩阵  $P_a(k/k-1)$  均可由递推方程导出。

目标状态更新由下式完成:

$$\hat{X}(k/k) = \hat{X}(k/k-1) + A^*(k) \quad (1.76)$$

可以证明, 最佳修正值量

$$A^*(k) = \sum_1^{L(k)} P_a(k) \mathbf{b}_a(k/k-1) \quad (1.77)$$

其中  $L(k) = (1 + \xi_k)L(k-1)$  为全部可能轨迹的总数。这时, 最佳更新估计误差的均值及协方差矩阵分别为

$$\mathbf{b}^*(k/k) = 0 \quad (1.78)$$

$$\begin{aligned} \dot{\mathbf{P}}^+(k/k) = & \sum_{i=1}^{L(k)} \mathbf{P}_a(k)[\mathbf{P}_a(k/k-1) + \mathbf{b}_a(k/k-1) \\ & \cdot \mathbf{b}_a^T(k/k-1)] - \mathbf{A}^+(k)\mathbf{A}^+(k)^T \end{aligned} \quad (1.79)$$

对下一采样周期的预测则为

$$\dot{\mathbf{X}}(k+1/k) = \Phi(k)\dot{\mathbf{X}}(k/k) \quad (1.80)$$

$$\dot{\mathbf{b}}_a(k+1/k) = \Phi(k)\dot{\mathbf{b}}_a(k/k) \quad (1.81)$$

$$\dot{\mathbf{P}}(k+1/k) = \Phi(k)\mathbf{P}(k/k)\Phi^T(k) + \dot{\mathbf{Q}}(k) \quad (1.82)$$

$$\mathbf{P}_a(k+1/k) = \Phi(k)\mathbf{P}_a(k/k)\Phi^T(k) + \dot{\mathbf{Q}}(k) \quad (1.83)$$

其中  $\Phi(k)$  为状态转移矩阵,  $\dot{\mathbf{Q}}(k)$  为状态噪声协方差矩阵。

显然,由于

$$L(k) = (1 - \xi_1)(1 - \xi_2) \cdots (1 - \xi_r) \quad (1.84)$$

这种最优滤波器在结构上要求计算机的存储量随扫描次数的增加而不断增加。为了限制计算机的存储量,文献[44]建议采用  $N$  次扫描记忆方法。仿真结构表明,当  $N=1$  时,可获得近乎最优的性能。当  $N=0$  时,所有轨迹将被组合,“全部”最优滤波器即为概率数据关联滤波器。

密集回波环境下多目标跟踪的数据关联与跟踪维持典型方法有下列几种。

#### 1.6.4 联合概率数据关联滤波(JPDAF)

1974 年,Bar-Shalom<sup>[17-19]</sup>推广了他的概率数据关联滤波方法,以便可以对多个目标进行处理而不需要关于目标和杂波的任何先验信息。

显然,如果被跟踪的多个目标的跟踪门不相交,或者没有回波位于相交区域内,则多目标跟踪问题总可以简化为多回波环境中的单目标跟踪问题进行处理。如果情况相反,则问题要复杂得多。

在联合概率数据关滤波算法中,Bar-shalom 首先引进了“聚”的概念。聚被定义为彼此相交的跟踪门的最大集合,目标则按不同的聚分为不同的群,对于每一个这样的群,总有一个二进制元素的聚矩阵与其关联,从聚矩阵中得到目标回波和杂波点的全排列和

所有的联合事件,进而通过联合似然函数来求解关联概率。JPDA 方法因其优良的相关性能而引起人们的高度重视。然而,由于 JPDA 的联合事件数是所有候选回波数的指数函数,并随回波密度的增加而急剧增大,计算负荷出现组合爆炸现象。因此,如何降低 JPDA 的计算量而又保持其优良性能仍是一项富有挑战性的课题。

关于 JPDAF 的详细内容见第三章。在 JPDAF 基础上为减小计算量,文献[13]提出了 MJPDAF 方法;为进一步提高跟踪性能,作者引入残差滤波(RF),提出了 MJPDAF—RF 方法,并获得相当好的结果。

### 1.6.5 多假设法

Reid<sup>[34]</sup>所提出的多目标跟踪算法是以“全邻”最优滤波器和 Bar-Shalom 的聚概念为基础的。主要过程包括:聚的构成、“假设”产生(每一可能轨迹为一假设)、每一假设的概率计算以及假设约简。

Reid 提出的“假设”概念与 Bar-Shalom 所指的联合事件几乎相同。假设形成的不同点在于:第一,对每一回波不仅考虑虚警的可能性,也考虑新目标出现的可能性;第二,将  $k$  时刻的假设视为  $k-1$  时刻的某一假设与当前数据集合关联的结果。

在所有可能假设的概率算出以后,零扫描( $N=0$ )算法和多扫描算法可用来更新多目标的状态。

可以说,Reid 方法综合了 Singer 方法和 Bar-Shalom 方法的优点,然而,其缺点在于过多地依赖于目标和杂波的先验知识,如已进入跟踪的目标数、虚警回波数、新目标回波数、虚假目标密度以及被检测目标密度等等。

### 1.6.6 整数规划法

从 1974~1977 年,Morefield 发表了一系列文献<sup>[13~17]</sup>以证明多目标跟踪问题实际上是一类已被充分研究过的离散最佳化

问题——0—1 整数规划问题中集合的分解和组合问题，并且推导出了多目标跟踪的整数规划方法。

首先，仍然是采用跟踪门对回波进行初选，从所有观测（候选回波）集合  $Y^k$  中构成一个可能的目标轨迹  $a_i$ ，并将其存储于可能轨迹的集合  $F$  中，即

$$F = \{a_i / a_i \subset Y^k, \ln P[\lambda / (\hat{X}(k))_{k=1}^n] > \alpha_s\} \quad (1.85)$$

其中

$$a_i = \{Y_{i,k}(k)\}_{k=1}^n \quad (1.86)$$

实际上是由观测序列组成的任一可能轨迹， $n$  为已完成的扫描次数，如果在跟踪空间中存在杂波，那么可能轨迹之一可能完全由虚警组成。集合  $F$  的构成由跟踪门规则来完成。

显然，所有的可能轨迹应满足

$$Y^k = \bigcup_{i=1}^m a_i \quad (1.87)$$

式中  $m$  为可能轨迹的总数，且

$$a_i \cap a_j = \emptyset \quad \forall i \neq j \quad (1.88)$$

对每一可能轨迹，其对数似然函数计算如下：

$$\begin{aligned} \ln(a_i) = & \frac{n}{2} \dim(Y_i) \ln^2 \pi + \frac{1}{2} \sum_{k=1}^n \ln |S(k)| \\ & + \frac{1}{2} \sum_{k=1}^n d^T(k) S^{-1}(k) d(k) \quad (i=1, \dots, m) \end{aligned} \quad (1.89)$$

式中， $d(k)$  ( $k=1, \dots, n$ ) 为与轨迹  $a_i$  中观测量相对应的新息； $S(k)$  为新息向量的协方差矩阵， $\dim(Y_i)$  为观测量  $Y_i$  的维数。

由此，可以定义一个  $m$  维的向量

$$L = \{\ln(a_i)\}_{i=1}^m \quad (1.90)$$

如果定义  $\tau$  为对观测集合  $Y^k$  进行分解的一种假设，则其正确的后验概率为

$$P(\tau / Y^k) = \frac{P(Y^k / \tau) P(\tau)}{P(Y^k)} \quad (1.91)$$

式中， $P(\tau)$  为假设  $\tau$  的先验概率，且假定所有可能的分解方案均

有相等的概率  $P(\tau)$ 。这样,欲使  $P\{\tau/Y^k\}$  为最大即等效于

$$\max_{a \in T} P\{Y^k/a\} \quad (1.92)$$

其中  $T$  为  $Y^k$  所有可能分解方案的集合。

进一步还可证明,方程(1.92)等效于

$$\min_{\rho} \rho^T L \quad (1.92)$$

即寻求一维数为  $m$  的二进制向量  $\rho$  使  $\rho^T L$  为最小。这样,跟踪问题就转化为一个整数规划问题。

规划问题的线性约束条件如下。定义一矩阵  $A$ ,其列取自可能轨迹的集合  $F$ :

$$A = [\psi_1, \dots, \psi_m] \quad (1.94)$$

式中  $\psi_j (j=1, \dots, m)$  为维数等于集合  $Y^k$  中观测量总数的二进制向量,  $\psi_j$  的第  $i$  个分量与  $Y^k$  的第  $i$  个元素相对应。因此,向量  $\psi_j$  指明了  $Y^k$  中的哪些元素属于  $a_i$ 。

观察式(1.88),不难发现,等效的二进制约束条件变为

$$Ap \leq I \quad (1.95)$$

其中  $I$  是全部元素为 1 的单位向量。

组合上述结果,产生如下完整的多目标跟踪问题:

$$\min \rho^T L \quad (1.96)$$

$$\text{约束 } Ap \leq I \quad (1.97)$$

$$\rho \text{ 为二进制向量} \quad (1.98)$$

式(1.96)~(1.98)定义为集合的组合问题。一旦求得矩阵  $A$ ,最大可能的轨迹集合即被选定,状态估计和协方差矩阵的计算均可在一组标准的卡尔曼滤波器中完成。

### 1.6.7 高斯和法

Alspach 以高斯和迭代 Bayes 估计为基础<sup>[58]</sup>,提出了跟踪多目标的高斯和法<sup>[59]</sup>。其中假定被跟踪的目标数与探测器接收到的回波数相等,而且每一回波均含有某一被跟踪目标的状态信息。

这种算法所需要的存储量随高斯和密度函数的项数的增大而

增大,因此,必须采取某些措施以剔除或组合高斯和中的某些项。此外,其漏报概率和虚警概率为零的假设与实际情况相距甚远,这些均使得这种方法目前还不太实用。

### 1.6.8 轨迹分裂法

处理多目标跟踪问题的其他方法之一是轨迹分裂法。这种以每一可能轨迹的似然函数为基础的方法是 Sittler 在其开创性的工作中<sup>[2]</sup>首先提出来的。在此工作中,Sittler 全面考虑了多目标跟踪问题,其中包括跟踪起始、轨迹确定、轨迹维持、空间关联、轨迹分裂以及交叉轨迹分析等等。基本方法是每当接收到一个多余回波时,即将原有轨迹分裂为相应数目的新轨迹,然后计算每一轨迹的似然函数,低于某一门限者摒弃,高于门限者则保留。

1975 年,Smith 和 Buechler<sup>[60]</sup>提出了一种类似的滤波方法,每一轨迹的似然函数由方程(1.89)来计算。一旦量测满足跟踪门规则,即被用来更新相应目标的状态,否则不予考虑。如果几个不同“目标”所得到的并行滤波状态估计相似的话,其中与似然函数较大的目标估计之差小于某一特定距离值的状态估计被剔除。如果某一轨迹的似然函数小于门限,则这一轨迹被认为是可能的虚警轨迹,并被摒弃。在密集回波环境下,这种方法所要求的计算量和存储量可能非常大,而且其辨别目标与虚警的能力也令人怀疑。

Stein 和 Blackman<sup>[61]</sup>也在 1975 年发展了 Sittler 的工作,并以极大似然法为基础提出了另一种最佳批处理算法。文中偏重于实际技术而对多目标跟踪的理论方面探讨不多。

### 1.6.9 简化的概率数据关联方法

1986 年,Fitzgerald<sup>[62]</sup>提出了一种简化的 JPDA 方法即 SPDA,其中关联概率用一个基于经验的特殊规则来计算,这种方法在跟踪两个目标时性能较好,但不能跟踪二个以上的多目标。

1993 年,Zhou 和 Bose<sup>[43]</sup>提出了基于深度优先搜索(DFS)的数据关联快速算法,其中根据 JPDA 导出的直接计算(DC)方法只

能跟踪 4 个目标,近似计算(AC)方法仅仅考虑了两个相关或交叉目标邻域内的其他目标和杂波,计算量大为降低,但其有效性和可靠性下降,有待理论证明和实验验证。

## 1.7 多目标跟踪起始与终结

多目标跟踪起始与终结是多目标跟踪理论中的两个重要组成部分,也是建立新目标档案和消除多余目标档案必不可少的决策环节。通常,按轨迹寿命的三个阶段将轨迹状态定义为假定轨迹、轨迹确定和轨迹终结三部分<sup>[37]</sup>。一般地,跟踪起始包括假定轨迹初始化和轨迹确定两部分,跟踪终结即指轨迹终结。

本节所讨论的技术是以“最近邻”相关方法为基础的,至于面向“全邻”相关的多目标跟踪起始与跟踪终结方法将在第六章专门论述。

典型方法有下列几种,

### 1.7.1 序列概率比检验(SPRT)

序列概率比检验方法主要用于轨迹确定与跟踪终结。文献[63 ~ 65]给出了该方法的全貌。首先,建立两种假设  $H_0$  和  $H_1$ ,即

$H_0$ : 跟踪终结;

$H_1$ : 跟踪起始。

然后计算相应于每一种假设的似然函数  $P_{0k}$  和  $P_{1k}$

$$H_0: P_{0k} = P_F^m (1 - P_F)^{k-m} \quad (1.99)$$

$$H_1: P_{1k} = P_D^m (1 - P_D)^{k-m} \quad (1.100)$$

式中,  $P_D$  和  $P_F$  分别为检测概率和虚警概率;  $m$  为检测数;  $k$  为扫描数。

其次, 定义相应于两种假设的似然比函数

$$U_k = \frac{P_{1k}}{P_{0k}} \quad (1.101)$$

并设置两种门限  $C_1$  和  $C_2$ 。最后, SPRT 方法的决策逻辑如下:

$$\left. \begin{array}{ll} U_t \leq C_1 & \text{接受假设 } H_0 \\ U_t \geq C_2 & \text{接受假设 } H_1 \\ C_1 < U_t < C_2 & \text{继续检验} \end{array} \right\} \quad (1.102)$$

式中门限  $C_1$  和  $C_2$  满足下列关系:

$$C_1 = \frac{\beta}{1 - \alpha} \quad (1.103)$$

$$C_2 = \frac{1 - \beta}{\alpha} \quad (1.104)$$

式中,  $\alpha$  和  $\beta$  为预先给定的允许误差概率;  $\alpha$  为  $H_0$  正确时接受  $H_1$  的概率;  $\beta$  为  $H_1$  正确时接受  $H_0$  的概率。

### 1.7.2 Bayes 轨迹确定与跟踪终结方法(BTCT)

文献[66, 67]给出的 Bayes 轨迹确定与跟踪终结方法(BTCT)优于上面提到的 SPRT 方法, 因为它很容易将检测历史和滤波残差信息引入到统计决策中去。

该方法的关键是计算在给定量测集合  $D$  条件下轨迹为真的后验概率  $P(T/D)$ , 由 Bayes 法则, 有

$$P(T/D) = \frac{P(D/T)P_o(T)}{P(D)} \quad (1.105)$$

式中

$$P(D) = P(D/T)P_o(T) + P(D/F)P_o(F) \quad (1.106)$$

$$P_o(F) = 1 - P_o(T) \quad (1.107)$$

式中,  $P(D/T)$  和  $P(D/F)$  分别为存在真实目标和虚假目标条件下接受量测集合  $D$  的概率;  $P_o(T)$  和  $P_o(F)$  分别为真实目标和虚假目标的先验概率;  $P(D)$  为接受量测集合  $D$  的概率。

定义数据似然比

$$L(D) = \frac{P(D/T)}{P(D/F)} \quad (1.108)$$

并组合式(1.105)~(1.108), 有

$$P(T/D) = \frac{L(D)P_o(T)}{L(D)P_o(T) + 1 - P_o(T)} \quad (1.109)$$

如果设  $L_k$  为第  $k$  次扫描时的数据似然比,  $P(T/D_k)$  为直到第  $k$  次扫描为止时目标为真的概率, 那么式(1.109)可变为如下递推形式:

$$P(T/D_k) = \frac{L_k P(T/D_{k-1})}{L_k P(T/D_{k-1}) + 1 - P(T/D_{k-1})} \quad (1.110)$$

设置轨迹确定概率门限  $P_{TC}$  和跟踪终结门限  $P_{TT}$ , 最后决策逻辑为: 当且仅当

$$P(T/D_k) \geq P_{TC} \quad (1.111)$$

时, 接受轨迹为真的假设; 当且仅当

$$P(T/D_k) < P_{TT} \quad (1.112)$$

时, 接受跟踪终结假设。

SPRT 方法属于“最近邻”相关方法, 仅适合稀疏回波环境和独立非机动目标跟踪情况。

### 1.7.3 $N$ 维分配法

1978~1983 年, Chang 等人<sup>[68, 69]</sup>提出了一种解决跟踪起始问题的  $N$  维分配方法。

考虑一个探测器扫描情况。假定第一次和第二次扫描分别产生  $N_1$  和  $N_2$  个目标检测, 问题在于如何把两个检测集合关联起来以形成最小数目即  $\min\{N_1, N_2\}$  的轨迹档案。一般情况下, 考虑到(1)目标分辨与检测的不完全性; (2)第二次扫描时出现新目标; (3)第二次扫描时被跟踪目标丢失等情况, 有  $N_1 \neq N_2$ 。

设  $\mathbf{Y}_k$  为第  $k$  次扫描期间  $N$  个量测的集合:

$$\mathbf{Y}_k = \{y_1(k), \dots, y_N(k)\} \quad (1.113)$$

$\mathbf{Y}^k$  为直到第  $k$  次扫描为止的全部量测集合:

$$\mathbf{Y}^k = \{\mathbf{Y}_i | i=1, \dots, k\} \quad (1.114)$$

为简化起见, 假定所有  $\mathbf{Y}_i$  的检测数为  $N$ , 并且探测器具有完全的目标检测。若这一假设非真的话, 必须产生很多假设以考虑各种可能性。显然, 对于  $\mathbf{Y}^k$  来说, 有  $N^k$  个量测序列组合, 每一个量测序列代表一个可能轨迹。用  $H_{n_k}(k)$  来表示每一个可能的组合:

$$H_{m_k}(k) = \{Y_{n_1}(1), Y_{n_2}(2), \dots, Y_{n_k}(k)\} \quad (1.115)$$

假设每一个可能的量测序列由跟踪滤波器来处理,那么,  $H_{m_k}(k)$  为正确的后验概率可递推地计算如下:

$$\begin{aligned} P\{H_{m_k}(k)/Y^k\} &= \frac{P\{Y_{n_k}(k)/H_{m_{k-1}}(k-1), Y^{k-1}\}}{P\{Y_{n_k}(k)/Y^{k-1}\}} \\ &\cdot P\{H_{m_{k-1}}(k-1)|Y^{k-1}\} \end{aligned} \quad (1.116)$$

这里  $P\{Y_{n_k}(k)/H_{m_{k-1}}(k-1), Y^{k-1}\}$  为利用  $H_{m_{k-1}}(k-1)$  和  $Y_{n_k}(k)$  时来自跟踪滤波器的残差向量的概率密度。最后,总数为  $N$  的轨迹集合可根据最大的假设概率来选择,即

$$\max_{N, H_{m_k}(k) \in F} \{P\{H_{m_k}(k)/Y^k\} \quad (m_k=1, \dots, N^k)\} \quad (1.117)$$

其中可能的轨迹集合  $F$  表示在给定的时间内每一量测仅被使用一次的约束:

$$F = \{H_{m_k}(k) : H_{i_k}(k) \cap H_{j_k} = \emptyset \quad (\forall i \neq j)\} \quad (1.118)$$

显然,以上方法的计算量较大。事实上,上述最优问题定义了一种  $N$  维分配问题。

在许多实际应用中,为了减少计算量,人们可以采用“聚”分析技术将对整个检测集合的研究转化为对许多独立且平行的子集来研究。

上面所讨论的三种递推方法一般适用于稀疏回波环境。在密集回波环境下,尚需采用下面介绍的能同时处理轨迹初始化和轨迹确定问题的批处理算法。

#### 1.7.4 极大似然法

1978~1981 年,Trunk 和 Wilson<sup>[70,71]</sup>提出了一种在密集检测环境中求解跟踪起始问题最优解的极大似然方法。该方法设置了下列假设:(1)考虑检测概率、虚警概率和目标分辨概率;(2)量测误差特性已知;(3)所有的目标均作匀速直线运动。并由此导出了  $N_T$  个轨迹组合的似然函数

$$L(N_T) = P_{FA}(N_{FA}) \cdot \left[ \frac{N_S N_T}{N_m} \right] P_D^{N_S N_T - N_m} (1 - P_D)^{N_m}$$

$$\begin{aligned} & \cdot \left( \frac{1}{\sqrt{2\pi}\sigma_s^2} \right)^{N_S N_T - N_m - N_{TR}} \prod_{j=1}^{N_T} \prod_{i=1}^{N_s} f(x_{ij} - y_{ij}) \\ & \cdot \prod_{k=1}^{N_{DR}} P_R(x_k) P_s(x_k) \end{aligned} \quad (1.119)$$

式中,  $N_T$  为轨迹数;  $N_{FA}$  为虚警数;  $N_S$  为扫描次数;  $N_m$  为与  $N_T$  个轨迹相关的漏检数;  $N_{DR}$  为至少存在两个轨迹时与分辨问题有关的检测数目;  $N_{TR}$  为至少存在两个轨迹时使用检测的轨迹总数;  $P_{FA}$  为虚警概率;  $P_D$  为检测概率;  $P_R$  为任何轨迹不可分辨的概率;  $P_s$  为距离合并概率;  $x_{ij}$  为第  $j$  次扫描时与第  $i$  个轨迹相关的检测距离, 若检测不相关, 则  $x_{ij}=0$ ;  $y_{ij}$  为直线轨迹上第  $j$  次扫描时第  $i$  个轨迹的预测距离;  $x_k$  为一般意义上的单一检测。

上式第一项表示虚警概率; 第二项表示检测概率; 第三项为量测误差概率; 最后一项为分辨概率。该方法通过赋予第  $i$  个轨迹(产生预测距离  $y_{ij}$ )—检测序列( $x_{ij}$ )而使式(1.119)取极大值。

根据公式(1.119), 极大似然法总是通过引入虚假轨迹来消除虚警。为避免此问题, 作者引进了分辨因子  $F_R$  和漏检因子  $F_m$ , 且  $1 > F_m > F_R$ , 其中  $F_R$  用来减小不可分辨检测对轨迹的影响,  $F_m$  用来减少漏检对轨迹的影响。这样, 修正的似然函数为

$$L_M(N_T) = L(N_T) F_R^{N_{TR} - N_{DR}} F_m^{N_m} \quad (1.120)$$

在应用中, 一般考虑五次扫描, 一个可能的轨迹至少需要三次检测并通过式(1.120)来实现最优解。

遗憾的是, 尽管上述方法在理论上具有极好的性能, 但由于所需计算量极大而无法在实际中实现。当然, 它可以作为与其他易于实现方法相比较的一个标准。

### 1.7.5 跟踪门方法

1.5 节给出的最优跟踪门限  $\gamma_0$  也可用作为确定跟踪终结的准则。

最优跟踪门限  $\gamma_0$  的表达式为

$$\gamma_e = 2 \ln \frac{P_d}{(1 - P_d) \beta (2\pi)^{M/2} \sqrt{|S|}} \quad (1.121)$$

式中,  $P_d$  为检测概率;  $\beta$  为新回波密度(目标回波和多余回波);  $M$  为观测维数;  $|S|$  为残差协方差矩阵的行列式。

由跟踪门规则可知, 当由跟踪滤波器所产生的残差范数  $g(k)$  满足关系

$$g(k) \leq \gamma_e \quad (1.122)$$

时, 探测器接受到的回波最大可能来自被跟踪的目标。因此, 只要  $\gamma_e > 0$ , 就存在着更新被跟踪目标轨迹的可能, 相反, 若  $\gamma_e < 0$ , 则所接收到的回波最大可能来自新源回波而非被跟踪的目标。

如果已计算出椭球跟踪门大小  $\gamma$ , 则一个自然而然的跟踪终清准则为: 当且仅当

$$Y_e < Y_{\min} \quad (1.123)$$

成立时, 接受跟踪终结假设。式中  $Y_{\min}$  为某一最小的门限值。 $Y_{\min}$  值可由具有  $M$ (观测维数)个自由度的标准  $\chi^2_M$  分布求取, 以保证在满足预先给定的轨迹更新概率条件下跟踪不致于被终结。

解决多目标跟踪起始问题的其他方法, 还有前面介绍的整数规划法、多假设法和 Hough 变换<sup>[72~74]</sup>批处理算法。同时, 也有人<sup>[75, 76]</sup>采用动态规划方法<sup>[75, 76]</sup>来解决跟踪起始和跟踪维持问题。

另外, 从应用观点出发, Castella<sup>[77]</sup>提出了解决轨迹起始和终结问题的滑窗方法, 基本原理是当时间窗内的检测数达到某一特定值  $M$  或减小到某一特定值  $N_0$  时, 轨迹起始和终结便告成功, 这是跟踪起始和跟踪终结问题的最简单准则。

最后, 需要说明的是, 跟踪终结是跟踪起始问题的逆问题, 跟踪起始的某些思想可为求解跟踪终结时所借鉴和采纳。

## 1.8 人工神经网络在多目标跟踪中的应用概述

80 年代以来, 在世界上再次兴起并得到迅猛发展的人工神经网络技术(Artificial Neural Networks, 简称 ANN)<sup>[8~12]</sup>, 由于其

独特的大规模并行处理、分布式信息存储、良好的自适应性和自组织性,以及很强的学习、联想和容错功能等特征,给人类尖端技术革命带来了希望。特别是与传统的随机自适应系统相比,ANN不仅具有更强的学习功能,而且还具有记忆、选择、抽象和识别能力。通过对 ANN 系统的训练,有可能自动找到解决机动多目标跟踪问题的新的有效手段。

Sengupta, Ilcis 和 Kaczewski 等<sup>[78,79]</sup>,在应用 ANN 解决多目标数据关联方面,已迈出了可喜的一步,但仍有许多问题尚待研究,譬如局部极小、网络参数优化和快速收敛等等。值得庆幸的是,ANN 在克服数据关联计算组合爆炸方面,已经显示出光明的前景。

在此基础上,结合随机系统的特点深入研究,有可能取得新的突破,并发展成为新一代的神经网络跟踪理论。

## 1.9 本书的主要工作与特色

本书的目标是致力于提出一种新的神经网络跟踪理论,并将其实应用于三维空间的多目标跟踪中。

本书的主要工作与特色如下:

(1)提出一种基于神经网络的高性能机动目标信息融合与并行自适应跟踪方法;

(2)基于 Boltzmann 随机神经网络和模拟增益退火,提出一种快速随机神经联合概率数据关联算法,从根本上解决传统数据关联方法难以克服的计算组合爆炸问题;

(3)利用参数稳定性、灵敏度和鲁棒性理论,提出随机神经网络组合参数的优化方法;

(4)提出基于随机神经网络的机动多目标快速自适应跟踪维持算法;

(5)以 Bayes 方法为基础,提出一种基于随机神经网络的跟踪起始与终结方法;

(5) 在三维空间中,采用混合状态变量,建立一种新的状态方程三通道形式上解耦的线性目标运动模型,避免非线性模型线性化带来的模型误差,与耦合模型相比,大大降低滤波计算量;

(7) 将神经网络跟踪理论应用于三维空间的多目标跟踪问题中,并给出相应的目标量测噪声和性能评价方法;

(8) 建立神经网络跟踪理论体系。

# 第一篇 神经网络跟踪理论

## 第二章 基于神经网络的机动目标信息 融合与并行自适应跟踪

### 2.1 引言

本章基于多层前馈神经网络、误差反向传播(BP)学习算法<sup>[80,81]</sup>和“当前”统计模型<sup>[82]</sup>，利用全状态反馈，提出一种新的基于神经网络的机动目标信息融合与并行自适应跟踪算法(NIPAT)。该算法采用双滤波器并行结构，神经网络基于全状态输入样本集进行离线训练，并根据特征向量在线自动融合全状态反馈信息和自动调节网络输出，其中滤波器  $F_1$  以较大的系统方差快速响应目标机动，滤波器  $F_2$  基于信息融合后的神经网络的输出，以方差自适应形式保持对目标状态的高精度跟踪。仿真结果表明，该算法克服了“当前”统计模型在目标弱机动和非机动时因系统方差的有限调整所带来的精度损失，具有对目标各种运动状态的良好自适应跟踪能力。

### 2.2 问题描述

第一章给出了“当前”统计模型及其均值和方差自适应跟踪算

法。该模型和算法的基本思想是,当目标正以某一加速度机动时,下一时刻的加速度取值是有限的,且只能在“当前”加速度的邻域内,加速度符合非零均值时间相关过程,其概率密度由修正的瑞利分布描述。再利用瑞利分布随均值而变化、方差由均值决定的特点,并令加速度均值等于当前时刻的加速度预测值,就实现了均值和方差自适应滤波。

理论研究表明,该模型的系统方差  $\sigma_w^2$  与加速度方差  $\sigma_a^2$  成正比,即

$$\sigma_w^2 \propto \sigma_a^2 = \begin{cases} \frac{4-\pi}{\pi} (\alpha_{\max} - \bar{a})^2 & (\bar{a} \geq 0) \\ \frac{4-\pi}{\pi} (\alpha_{-\max} - \bar{a})^2 & (\bar{a} < 0) \end{cases} \quad (2.1)$$

式中,  $\bar{a}$  为加速度均值;  $\alpha_{\max}$  和  $\alpha_{-\max}$  分别为最大正负加速度,由人工设定。显而易见,(1)当  $\alpha_{\max}$  取较大值或  $\alpha_{-\max}$  取较小值时,跟踪系统能以较大的系统方差保持对目标机动的快速响应;(2)当  $\alpha_{\max}$  或  $\alpha_{-\max}$  一定,当目标以较小的加速度机动,特别是加速度为零时,系统方差很大,跟踪精度较低;当目标以较大的加速度机动时,系统方差较小,跟踪精度较高。上述特征表明,该模型和算法对高度机动目标具有很强的自适应能力和较高的跟踪精度,但对弱机动,特别是非机动目标,由于系统方差的有限调整而带来跟踪精度下降;另一方面,该模型的系统方差自适应仅仅利用了加速度估计信息。如何更充分地利用目标位置、速度和加速度信息,即全状态信息;如何更有效准确地自动调整系统方差以适应目标的各种运动变化,则是本章所要解决的问题。

### 2.3 多层前馈神经网络与 BP 学习算法

图 2.1 所示为一种多层前馈神经网络,该网络由输入层、输出层和至少一个隐层构成,各层由若干个非线性处理单元即神经元组合而成。

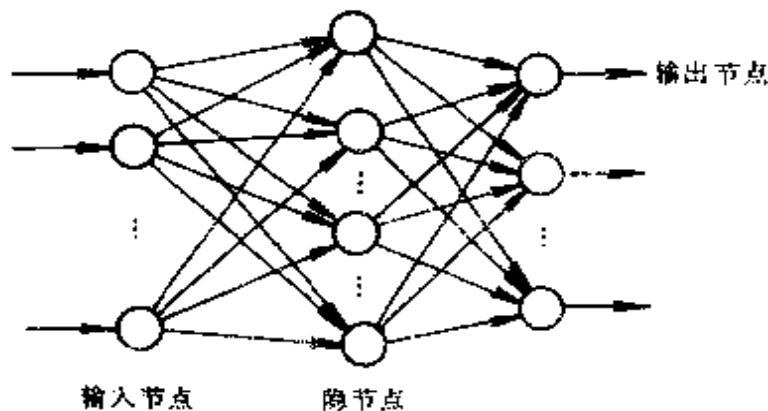


图 2.1 多层前馈神经网络

BP 学习算法,是美国学者 Rumelhart 等<sup>[80]</sup>对图 2.1 所示网络进行研究而提出的一种有效监督学习方法。该算法基于最小均方误差准则,由误差正向传播和反向传播组成,通过比较网络的实际输出与期望输出来不断地调节网络权值,直至收敛为止。网络中每个节点的输入输出存在如下非线性关系:

$$O_{pj} = \{1 + \exp[-(\sum_i \omega_{ji} O_{pi} + \theta_j)]\}^{-1} \quad (2.2)$$

式中, $O_{pj}$ 为模式  $p$  输至网络节点  $j$  的输出; $\omega_{ji}$ 为节点  $i$  到节点  $j$  的联接权; $\theta_j$ 为节点  $j$  的阈值。

定义网络的误差函数为

$$\epsilon \triangleq \sum_p \epsilon_p = \sum_p \sum_j (t_{pj} - O_{pj})^2 / 2 \quad (2.3)$$

式中  $t_{pj}$ 为期望的输出。相应的代价函数为

$$J \triangleq E[\epsilon] = \sum_p E[\epsilon_p] \triangleq \sum_p J_p \quad (2.4)$$

网络的最佳权值为使式(2.4)取极小值时的解,为此利用非线性规则中的最速下降法来求解最佳权值。训练集中每个样本输至网络时网络的权值都要作相应的调整,其改变量为

$$\Delta \omega_{ji} = -\eta \frac{\partial \epsilon_p}{\partial \omega_{ji}} \quad (2.5)$$

其中参数  $\eta$  为学习速率。

由于

$$\frac{\partial \epsilon_p}{\partial w_{pj}} = \frac{\partial \epsilon_p}{\partial \text{net}_{pj}} \cdot \frac{\partial \text{net}_{pj}}{\partial w_{pj}}, \quad (2.6)$$

$$\text{net}_{pj} = \sum_i w_{ji} \cdot O_{pi} \quad (2.7)$$

记  $\frac{\partial \epsilon_p}{\partial \text{net}_{pj}} \triangleq \delta_{pj}$ , 并称为节点  $j$  的误差信号, 则式(2.6)变为

$$\frac{\partial \epsilon_p}{\partial w_{pj}} = -\delta_{pj} \cdot O_{pi} \quad (2.8)$$

从而有

$$\Delta w_{pj} = \eta \delta_{pj} \cdot O_{pi} \quad (2.9)$$

对输出层节点  $j$ , 有

$$\delta_{pj} = (t_{pj} - O_{pj})O_{pj}(1 - O_{pj}) \quad (2.10)$$

对隐层节点  $j$ , 有

$$\delta_{pj} = \frac{\partial \epsilon_p}{\partial \text{net}_{pj}} = \sum_k -\frac{\partial \epsilon_p}{\partial \text{net}_{pk}} \cdot \frac{\partial \text{net}_{pk}}{\partial \text{net}_{pj}} = \sum_k \delta_{pk} w_{kj} (1 - O_{pj}) O_{pj} \quad (2.11)$$

式中,  $\delta_{pk}$  为节点  $j$  上一层节点  $k$  的误差信号;  $w_{kj}$  为节点  $j$  到其上一层节点  $k$  的联接权。为了加速权值收敛, 在式(2.9)中加入惯性项, 即

$$\Delta w_{pj}(n+1) = \eta \delta_{pj} \cdot O_{pi} + \alpha' \Delta w_{pj}(n) \quad (2.12)$$

其中  $\alpha'$  为惯性比例因子, 且  $0 < \alpha' < 1$ 。式(2.2)~(2.12)构成 BP 学习算法。

## 2.4 基于神经网络的信息融合系统及其基本原理

基于神经网络(NN)的信息融合系统如图 2.2 所示, 其中滤波器  $F_1$  和  $F_2$  并行工作, 神经网络融合两滤波器全状态信息即位置、速度和加速度信息, 并反馈至  $F_1$ ,  $F_2$  的输出即为目标的状态估计。

该信息融合系统的基本原理是, 滤波器  $F_1$  采用“当前”统计模型, 以较大的系统方差, 或等价于选取较大的  $\alpha_{\max}$  或较小的  $\alpha_{\min}$ ,

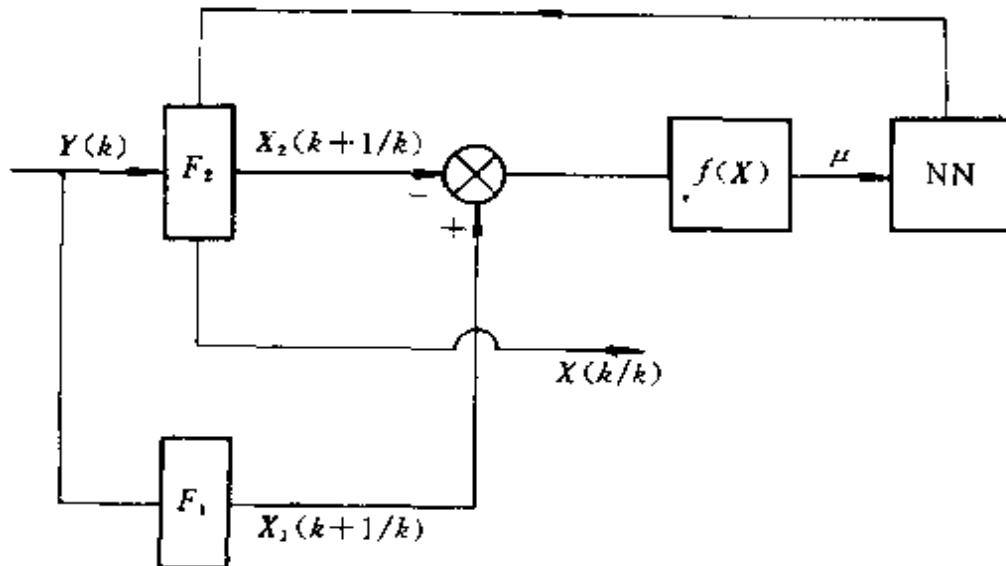


图 2.2 基于神经网络的信息融合系统

即以较大的加速度方差  $\sigma_{F_2}^2 = \sigma_a^2$  保持对目标机动的快速响应; 滤波器  $F_2$  仍采用“当前”统计模型, 但加速度方差  $\sigma_{F_2}^2$  的自动调整是融合  $F_1$  和  $F_2$  的全部信息即全状态反馈信息后, 根据神经网络的输出  $net_0 \in (0, 1)$  以  $\sigma_{F_2}^2 = net_0 \cdot \sigma_a^2$  的形式适应目标的各种运动变化。换言之, 当目标高度机动时, 神经网络根据特征向量  $(\mu_1 \mu_2 \mu_3)^T$  在线自动输出一个接近于 1.0 的值, 使得  $\sigma_{F_2}^2$  接近于  $\sigma_{F_1}^2$ , 即  $F_2$  以较大的系统方差快速响应目标的强机动变化, 并保持对目标状态的高精度跟踪; 当目标非机动时, 神经网络在线自动输出一个接近于零的值, 使得  $\sigma_{F_2}^2$  较小, 即  $F_2$  以较小的系统方差保持对非机动目标的高精度跟踪; 当目标在强弱机动之间变化时, 神经网络在线自动输出一个(0,1)间的值, 使得  $F_2$  以足够准确的系统方差适应目标的运动变化, 同时又保持对目标状态的高精度跟踪。可以预见, 由于全状态信息的引入和反馈, 在量测维数不变的情况下, 融合系统除了能提高目标位置估计精度外, 还能大幅度改善目标速度和加速度估计性能。

## 2.5 目标特征提取与网络离线训练

这里采用全状态反馈方法,以便最大程度地利用目标的位置、速度和加速度状态信息,选目标特征向量  $\mu$  即神经网络的输入为两滤波器的状态预测误差之差的范数  $[\mu_1 \mu_2 \mu_3]^T$ ,即

$$\mu_1 = f_1(\mathbf{X}) = \frac{[\hat{x}_1(k+1/k) - \hat{\bar{x}}_1(k+1/k)]^2}{s_1(k+1) + s_2(k+1)} \quad (2.13)$$

$$\mu_2 = f_2(\mathbf{X}) = \frac{[\hat{x}_1(k+1/k) - \hat{\bar{x}}_2(k+1/k)]^2}{p_{1,22}(k+1/k) + p_{2,22}(k+1/k)} \quad (2.14)$$

$$\mu_3 = f_3(\mathbf{X}) = \frac{[\hat{x}_1(k+1/k) - \hat{\bar{x}}_2(k+1/k)]^2}{p_{1,33}(k+1/k) + p_{2,33}(k+1/k)} \quad (2.15)$$

式中,  $\hat{x}_i(k+1/k)$ ,  $\hat{\bar{x}}_i(k+1/k)$  和  $\hat{\bar{x}}_i(k+1/k)$  ( $i=1, 2$ ) 分别为两滤波器的位置、速度和加速度预测值;  $s_1(k+1)$  和  $s_2(k+1)$  分别为两滤波器的位置残差方差;  $p_{i,22}(k+1/k)$  和  $p_{i,33}(k+1/k)$  ( $i=1, 2$ ) 分别为两滤波器的速度和加速度预测方差。

对目标各种运动形式和机动水平的大量仿真发现, 特征向量  $\mu = [\mu_1 \mu_2 \mu_3]^T$  的变化规律为

$$\left. \begin{array}{l} \mu_1 \in [L_{\mu_1}, H_{\mu_1}] = [0.05, 0.2] \\ \mu_2 \in [L_{\mu_2}, H_{\mu_2}] = [0.2, 0.6] \\ \mu_3 \in [L_{\mu_3}, H_{\mu_3}] = [0.1, 0.4] \end{array} \right\} \quad (2.16)$$

学习样本选取如下:

当所有特征变量处于低值时,认为目标处于非机动状态, 神经网络的输出  $net_0$  为一接近于零的值; 当所有特征变量处于高值时,认为目标处于强机动状态, 网络输出  $net_0$  为一接近于 1.0 的值; 当目标在强机动和非机动之间变化时, 特征向量各元素具有不同的敏感性, 不一定同时达到高值, 为使滤波器  $F_2$  能较快地响应机动, 当特征变量中 1 个或 2 个达到高值时, 也应设置一些较大的学习样本值, 即网络的输出  $net_0$  设置为一些较大的值。总的学习样本至少为 8 组。

两层神经网络具有逼近任意非线性函数的学习能力<sup>[91,92]</sup>。这里选取含有一个隐层的神经网络, 其中输入节点数为 3, 输出节点数为 1, 根据经验, 选隐层节点数为 7, 学习速率  $\eta = 0.7$ , 惯性比例因子  $\alpha' = 0.9$ 。离线训练中, 当 BP 学习算法的迭代次数为 2000 步时, 认为网络达到稳定。此时, 网络总体误差为  $\epsilon = 0.000038$ 。网络一旦离线训练好, 即可用于在线信息融合与跟踪。

## 2.6 基于神经网络的信息融合与平行自适应跟踪算法(NIFPAT)

设两波波器  $F_1$  和  $F_2$  并行工作, 目标状态方程和量测方程分别为

$$\dot{\boldsymbol{X}}(k+1) = \boldsymbol{\Phi}(k+1, k)\boldsymbol{X}(k) + \boldsymbol{U}(k)\boldsymbol{u} + \boldsymbol{w}(k) \quad (2.17)$$

$$\boldsymbol{Y}(k) = \boldsymbol{H}(k)\boldsymbol{X}(k) + \boldsymbol{V}(k) \quad (2.18)$$

式中,  $\boldsymbol{X}(k) = [x(k) \ \dot{x}(k) \ \ddot{x}(k)]^T$ ;  $\boldsymbol{\Phi}(k+1, k)$  为状态转移矩阵;  $\boldsymbol{U}(k)$  为输入矩阵;  $\boldsymbol{w}(k)$  为高斯状态噪声向量;  $\boldsymbol{H}(k)$  为一维量测矩阵;  $\boldsymbol{V}(k)$  为与  $\boldsymbol{w}(k)$  独立的高斯量测噪声。

NIFPAT 滤波方程为

$$\hat{\boldsymbol{X}}_i(k/k) = \hat{\boldsymbol{X}}_i(k/k-1) + \boldsymbol{K}_i(k)[\boldsymbol{Y}(k) - \boldsymbol{H}(k)\hat{\boldsymbol{X}}_i(k/k-1)] \quad (2.19)$$

$$\dot{\hat{\boldsymbol{X}}}_i(k/k-1) = \boldsymbol{\Phi}(k, k-1)\hat{\boldsymbol{X}}_i(k-1/k-1) + \boldsymbol{U}(k)\boldsymbol{u}_i(k) \quad (2.20)$$

$$\boldsymbol{K}_i(k) = \boldsymbol{P}_i(k/k-1)\boldsymbol{H}^T(k)[\boldsymbol{H}(k)\boldsymbol{P}_i(k/k-1)\boldsymbol{H}^T(k) + \boldsymbol{R}(k)]^{-1} \quad (2.21)$$

$$\boldsymbol{P}_i(k/k-1) = \boldsymbol{\Phi}(k, k-1)\boldsymbol{P}_i(k-1/k-1)\boldsymbol{\Phi}^T(k, k-1) + \boldsymbol{Q}_i(k-1) \quad (2.22)$$

$$\boldsymbol{P}_i(k/k) = [\boldsymbol{I} - \boldsymbol{K}_i(k)\boldsymbol{H}(k)]\boldsymbol{P}_i(k/k-1) \quad (2.23)$$

$$\bar{\boldsymbol{a}}_i(k) = \dot{\hat{\boldsymbol{r}}}_i(k/k-1) \quad (2.24)$$

式中,  $i=1, 2$ ,  $\hat{\boldsymbol{X}}_i(k/k)$  和  $\boldsymbol{X}_i(k/k-1)$  分别为两滤波器的估计和预测量;  $\boldsymbol{K}_i(k)$  为滤波增益;  $\boldsymbol{P}_i(k/k-1)$  和  $\boldsymbol{P}_i(k/k)$  分别为预测和估计

协方差矩阵;  $R(k)$  为量测方差,且有

$$R(k) = [\beta x(k) + \Delta x_0]^2 \cdot E[\omega^2(k)] \quad (2.25)$$

式中  $\beta$  为相对量测误差系数;  $\Delta x_0$  为探测器固定量测误差;  $\omega(k)$  是均值为零、方差为 1 的正态伪随机数。对滤波器  $F_1$  和  $F_2$  分别有

$$Q_1(k) = 2\alpha\sigma_{F_1}^2 Q_0 \quad (2.26)$$

$$Q_2(k) = 2\alpha\sigma_{F_2}^2 Q_0 \quad (2.27)$$

$$\sigma_{F_1}^2 = \begin{cases} \frac{4-\pi}{\pi}(\alpha_{\max} - \bar{\alpha}_1)^2 & (\alpha_1 \geq 0) \\ \frac{4-\pi}{\pi}(\alpha_{\max} - \bar{\alpha}_1)^2 & (\alpha_1 < 0) \end{cases} \quad (2.28)$$

$$\sigma_{F_2}^2 = \begin{cases} \text{net}_c \cdot \frac{4-\pi}{\pi}(\alpha_{\max} - \bar{\alpha}_2)^2 & (\alpha_2 \geq 0) \\ \text{net}_c \cdot \frac{4-\pi}{\pi}(\alpha_{\max} - \bar{\alpha}_2)^2 & (\alpha_2 < 0) \end{cases} \quad (2.29)$$

式中,  $\text{net}_c$  为神经网络信息融合后的输出;  $\alpha$  为机动频率;  $Q_0$  为与  $\alpha$  和采样周期  $T$  有关的常值矩阵。

全状态信息  $[\mu_1 \mu_2 \mu_3]^T$  通过神经网络实现信息融合和反馈, 系统的输出  $\hat{X}_2(k/k)$  为状态估计。

## 2.7 仿真结果

为了评价 NIFPAT 算法的有效性, 本章对加速度阶跃、转圈、匀加速和匀速四类典型目标运动形式进行了仿真, 并将 NIFPAT 算法与基于“当前”统计模型的自适应跟踪算法(简称 CMAT 算法)进行了性能比较。

仿真中, 取  $\alpha = 0.01$ ,  $\beta = 0.01$ ,  $\Delta x_0 = 30$ ,  $a_{\max} = 100 \text{m/s}^2$ ,  $T = 0.5 \text{s}$ ; 匀速运动中, 目标速度  $v = 400 \text{m/s}$ ; 匀加速运动中, 目标加速度  $a = 40 \text{m/s}^2$ ; 转圈运动中,  $v = 300 \text{m/s}$ ,  $a = 30 \text{m/s}^2$ ; 加速度阶跃运动中,  $v = 400 \text{m/s}$ ,  $a = 30 \text{m/s}^2$ 。图 2.3~图 2.10 分别给出了

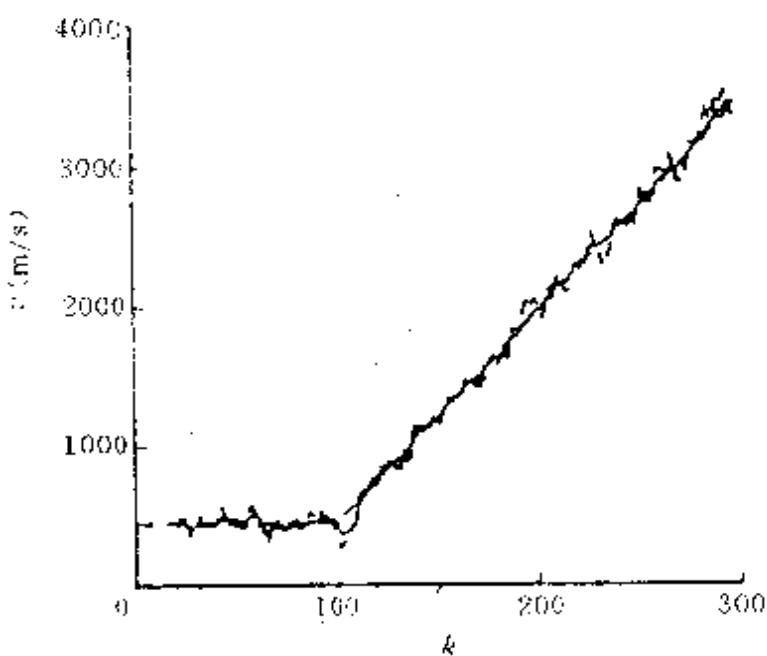


图 2.3 速度估计曲线(加速度阶跃)

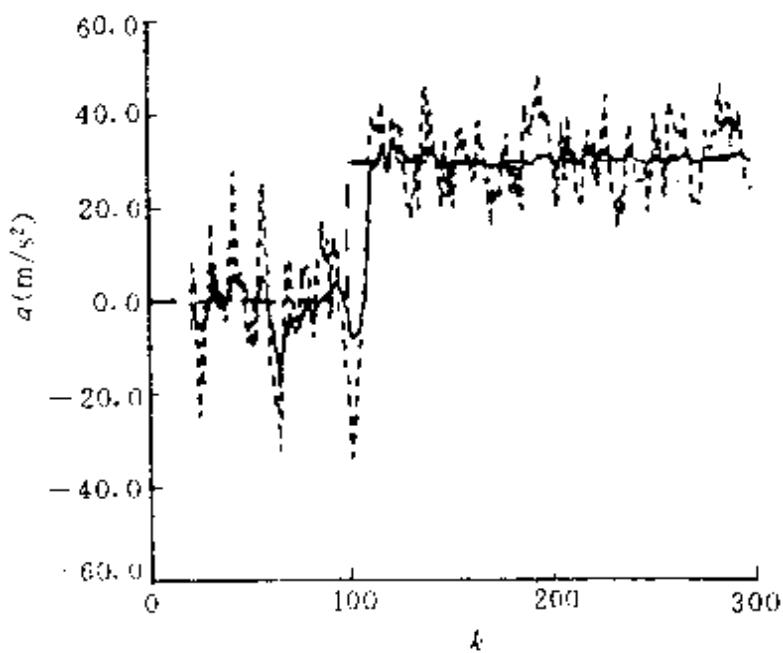


图 2.4 加速度估计曲线(加速度阶跃)

NIFPAT 和 CMAT 两种算法对目标四类典型运动的速度和加速度估计曲线。图中,短划线代表真值,实线代表 NIFPAT 估计曲线,点虚线表示 CMAT 估计曲线。从图中可以看出,NIFPAT 算

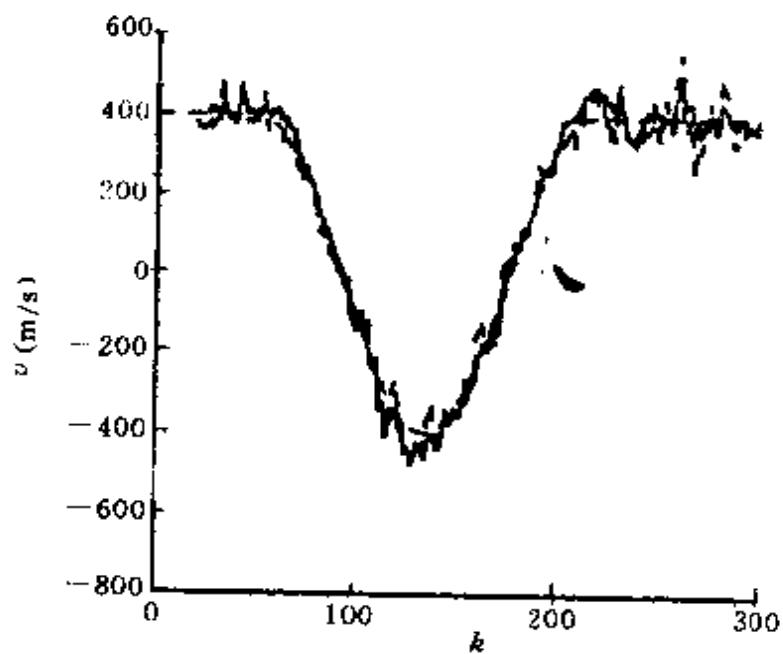


图 2.5 速度估计曲线(转圈)

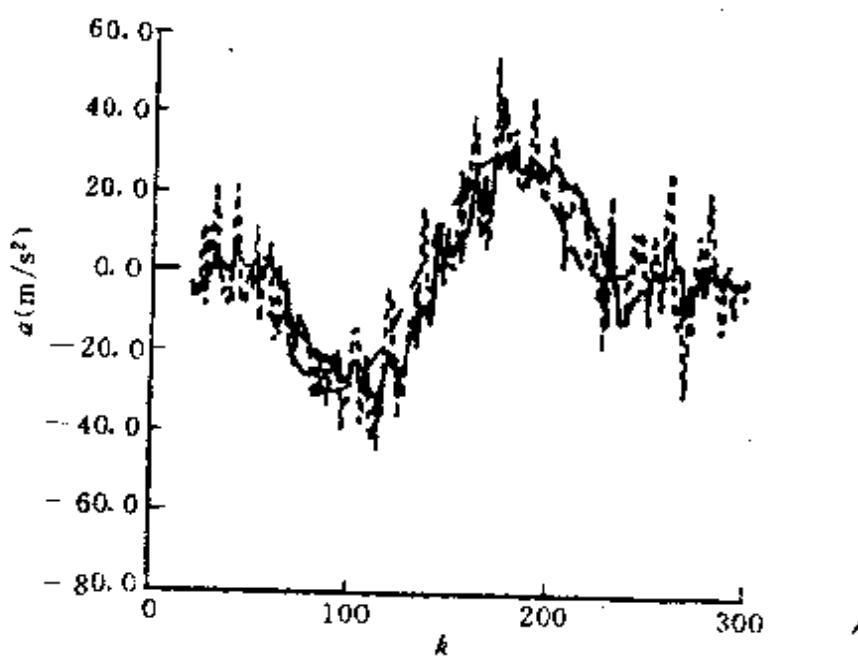


图 2.6 加速度估计曲线(转圈)

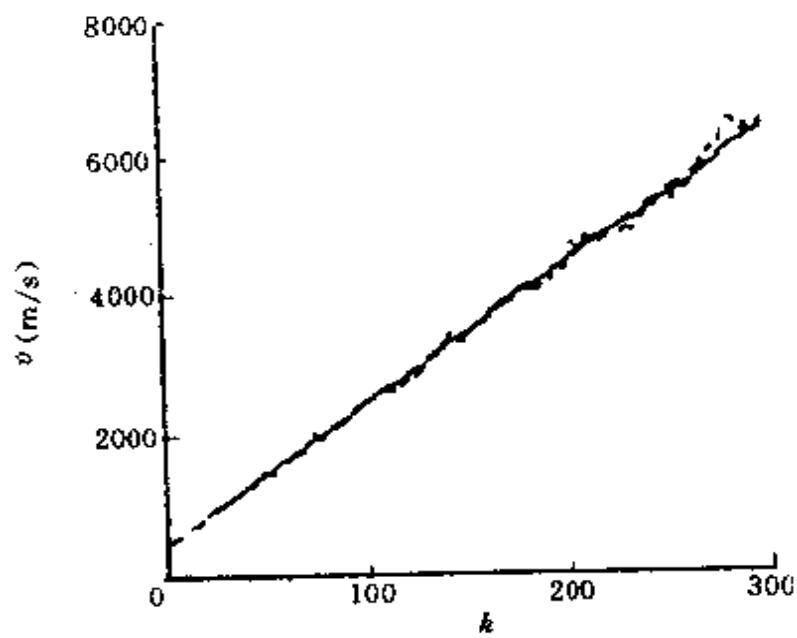


图 2.7 速度估计曲线(匀加速)

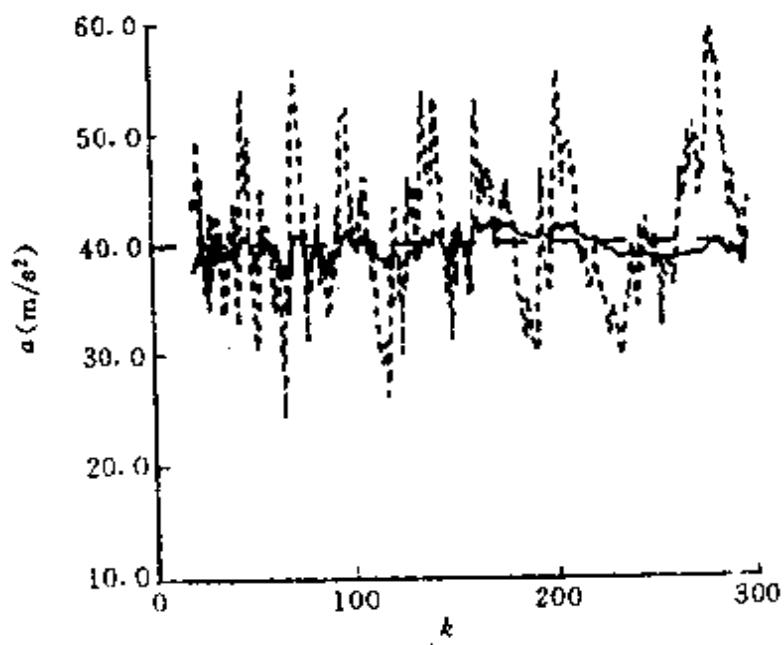


图 2.8 加速度估计曲线(匀加速)

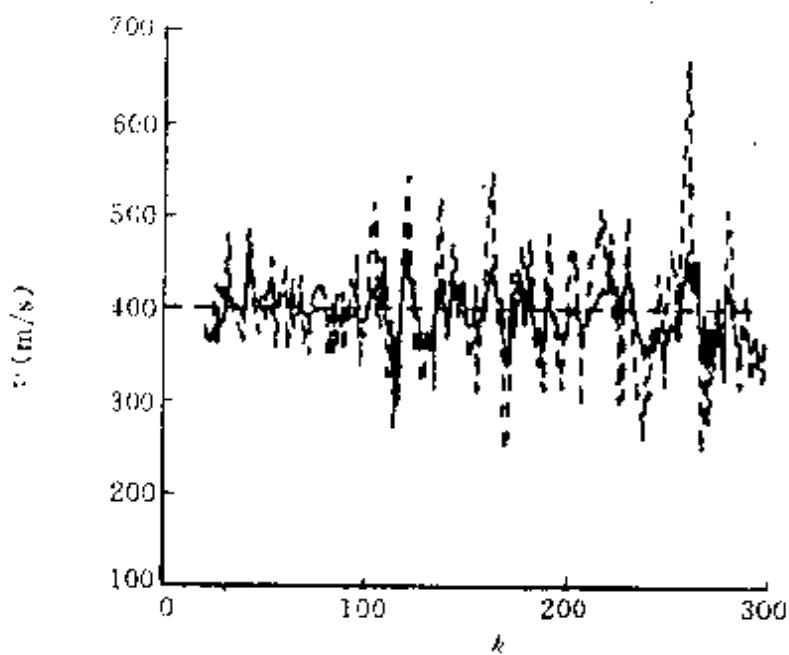


图 2.9 速度估计曲线(匀速)

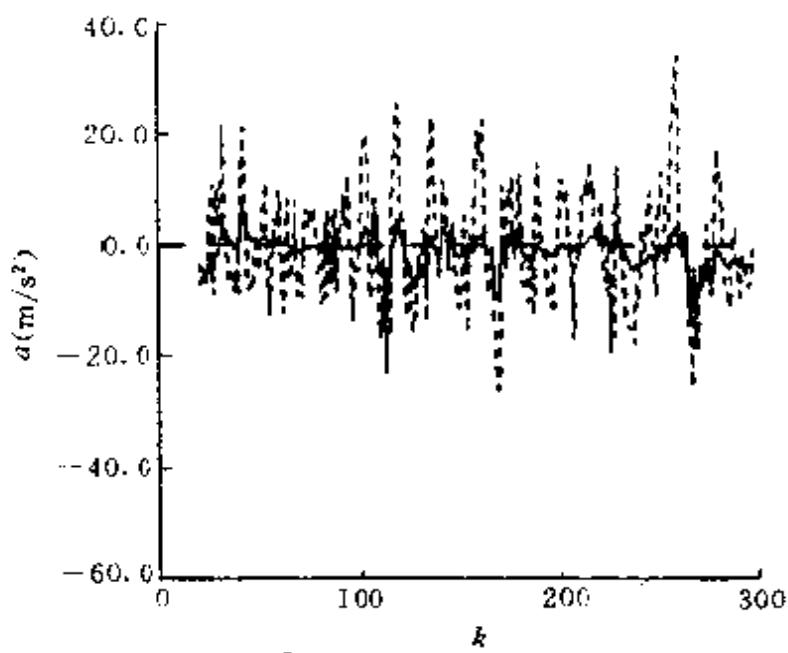


图 2.10 加速度估计曲线(匀速)

法的跟踪曲线具有较小的估计误差，并能快速地响应目标的机动。表 2.1 给出了在相同量测序列下，两种算法的相对估计误差压缩比  $E_N$ ，即 NIFPAT 算法的标准估计均方差与 CMAT 算法的标准估计均方差之比。从表中可以看出， $E_N$  均小于 1，特别令人可喜的是，与 CMAT 算法相比，NIFPAT 算法不仅能改善位置估计性能，而且能大幅度地提高速度和加速度跟踪精度。

表 2.1 NIFPAT 和 CMAT 算法的相对估计误差压缩比

$E_N$	位 置	速 度	加 速 度
加速度阶跃	0.814	0.583	0.613
转 圈	0.857	0.767	0.773
匀 加 速	0.583	0.294	0.156
匀 速	0.724	0.405	0.284

## 2.8 结论

理论和仿真研究表明，本章提出的 NIPAT 算法集信息融合与自适应滤波于一体，不仅克服了 CMAT 算法的不足，而且具有对目标各种运动状态的良好自适应跟踪能力。由于采用了神经网络信息融合和并行滤波结构，本算法避免了基于传统统计滤波的双滤波器串联结构<sup>[82]</sup>所产生的量测噪声相关、估计相关和计算复杂性等问题，是一种有效可行的机动目标全面自适应跟踪方法。

本算法适用于对目标速度和加速度估计精度较高的场合。

## 第三章 随机神经网络组合优化与 多目标数据关联

### 3.1 引言

1974年以来,Bar-Shalom 经过不断完善提出了著名的联合概率数据关联(JPDA)方法<sup>[1]</sup>,以便对多个目标进行跟踪而不需要关于目标和杂波的任何先验信息。由于 JPDA 在密集回波环境下跟踪多目标所表现出的优良性能,因而一经提出,便引起极大重视,被认为是跟踪多目标的最有效可靠的手段。然而,这种方法随着目标和回波数目的增加,其联合关联假设数目急剧增大,计算量出现组合爆炸现象,限制了其广泛的实际应用。如何简化 JPDA,在大大降低其计算量的同时又得保持其优良性能,成为迫切需要解决的问题。

ANN 的研究使这一问题的解决出现一线光明。由于神经网络的优良性能,特别是其并行处理能力,使得它在组合优化问题上显示出令人鼓舞的应用前景。本章通过对 JPDA 性能特征的分析,将多目标数据关联表达为一类约束组合优化问题,进而应用随机神经网络求解,仿真结果证明了本方法的有效性。

### 3.2 JPDA 及其计算组合爆炸

设密集回波环境下目标  $t$  的状态方程为

$$X^t(k+1) = \Phi X^t(k) + C W^t(k) \quad (t=1, 2, \dots, T) \quad (3.1)$$

相应的量测方程为

$$Z(k) = \begin{cases} H(k)X^*(k) + V(k) & (\text{量测来自目标 } t) \\ u(k) & (\text{量测来自杂波}) \end{cases} \quad (3.2)$$

式中,  $X(k)$  为状态向量;  $Z(k)$  为量测向量;  $W(k)$  和  $V(k)$  分别为状态噪声和量测噪声, 且为互不相关的零均值高斯白噪声向量序列, 其协方差矩阵分别为  $Q(k)$  和  $R(k)$ ,  $\Phi^*$ 、 $G^*$ 、 $H$  分别为状态转移矩阵、输入矩阵和观测矩阵;  $u(k)$  为在关联域内均匀分布的杂波。

引入新息向量

$$d^*(k) = Z(k) - H\hat{X}^*(k/k-1) \quad (3.3)$$

其协方差矩阵为

$$S^*(k) = H P^*(k/k-1) H^T + R(k) \quad (3.4)$$

式中,  $\hat{X}^*(k/k-1)$  为一步状态预测;  $P(k/k-1)$  为预测协方差矩阵; 新息范数为

$$g^*(k) = [d^*(k)]^T [S^*(k)]^{-1} d^*(k) \quad (3.5)$$

在多回波环境下对  $T$  个目标跟踪时, 首先对接收到的所有回波与  $T$  个目标分别进行关联, 通过设置各个目标的跟踪门或关联区域  $V^t(t=1, 2, \dots, T)$  得到  $T$  个目标的候选回波集。设  $k$  时刻目标  $t$  的候选回波集为

$$Z^t(k) = \{Z_i^t(k)\}_{i=1}^{m^t(k)} \quad (3.6)$$

$k$  时刻  $T$  个目标的候选回波集为

$$Z(k) = \{Z_i^t(k)\}_{t=1}^{m(k)} \quad (3.7)$$

到时刻  $k$  目标  $t$  和  $T$  个目标总的候选回波集分别为

$$Z^t(k) = \{Z^t(k)\}_{k=1}^k \quad (3.8)$$

$$Z(k) = \{Z(k)\}_{k=1}^k \quad (3.9)$$

式中,  $m^t(k)$  和  $m(k)$  分别为  $k$  时刻目标  $t$  的候选回波数和  $T$  个目标的候选回波数。

$m(k)$  个候选回波与  $T$  个目标的隶属关系可用  $m(k) \times T$  的聚矩阵  $\Omega(k)$  表示, 即

$$[\Omega(k)]_{t,i} = \begin{cases} 1 & Z_i(k) \in V^t(k) \\ 0 & Z_i(k) \notin V^t(k) \end{cases} \quad (3.10)$$

其中第  $t$  列“1”的个数就是目标  $t$  关联域内的候选回波数  $m^t(k)$ 。下面分两种情况讨论：

1.  $\Omega(k)$  每行只有一个“1”，表示  $T$  个目标的关联域之间不相交或相交域内无候选回波，此时

$$m(k) = \sum_{t=1}^T m^t(k) \quad (3.11)$$

这种情况下，多目标数据关联转化为多回波环境下单目标的数据关联问题，采用 PDA 方法便可得到满意的解决。

2.  $\Omega(k)$  每行不止一个“1”，这时

$$m(k) < \sum_{t=1}^T m^t(k) \quad (3.12)$$

式意味着  $T$  个目标的关联域出现交集，且交集内有候选回波，这是典型的多目标数据关联问题，下面着重讨论之。

定义下列假设事件：

$$\theta_t = \{\mathbf{Z}_t(k)\text{ 为目标 }t\text{ 的候选回波}\}$$

$$\theta_t^c = \{\text{目标 }t \text{ 无任何候选回波}\}$$

则目标  $t$  的状态估计为

$$\begin{aligned} \hat{\mathbf{X}}^t(k/k) &= E[\mathbf{X}^t(k) | \mathcal{Z}(k)] \\ &= \sum_{l=0}^{m(k)} \beta_l(k) \hat{\mathbf{X}}_l^t(k/k) \end{aligned} \quad (3.13)$$

式中  $\hat{\mathbf{X}}_l^t(k/k)$  是在第  $l$  个候选回波下对目标  $t$  所作的状态估计。而且

$$\beta_l^t(k) = \begin{cases} P\{\theta_0^t(k) | \mathcal{Z}(k)\} & (l=0) \\ P\{\theta_l^t(k) | \mathbf{Z}(k)\} & (l \neq 0 \text{ 且 } [\Omega(k)]_{l,t}=1) \\ 0 & (\text{其他}) \end{cases} \quad (3.14)$$

$$\sum_{l=0}^{m(k)} \beta_l^t(k) = 1 \quad (t=1, 2, \dots, T) \quad (3.15)$$

为计算  $\beta_l^t(k)$ ，引入可行联合事件

$$\epsilon(n, k) = \bigcap_{l=1}^{m(k)} \theta_l^t(k) \quad (3.16)$$

式中， $\{t_l; l=1, 2, \dots, m(k)\}$  是目标点与杂波点的有序排列； $t_l \neq 0$

对应于目标,  $t_i=0$  对应于杂波;  $n$  是总数为  $N$  的联合事件集合的序号。对于任意第  $n$  个可行联合事件, 满足以下假设:

假设 1 杂波点的个数  $q$  满足  $m(k)-T \leq q \leq m(k)$ ;

假设 2 若  $t_i \neq t_l$ , 则  $t_i \neq t_l$ , 一个目标只能产生一个回波;

假设 3  $t_i$  必须满足  $[\Omega(k)]_{t_i, t_i} = 1$ , 即  $Z_i(k) \in V^i(k)$ ;

假设 4  $\epsilon(n, k)$  唯一, 即一个回波只能属于一个目标。

由式(3.16)和以上假设, 可形成下列  $N \times T$  的可行关联假设矩阵:

$$[\Theta(k)]_{n,t} = \begin{cases} 1 & \text{若在 } \epsilon(n, k) \text{ 假设下第 } t \text{ 个目标与第 } l \text{ 个回波相关} \\ & (V^i(k) \text{ 中所有其他回波来自杂波或其他目标}) \\ 0 & \text{若在 } \epsilon(n, k) \text{ 假设下第 } t \text{ 个目标与任何回波都不相} \\ & (V^i(k) \text{ 中所有其他回波来自杂波或其他目标}) \end{cases}$$

该矩阵中的每一行对应于一个可行假设, 其列数为  $T$ , 行数为  $N$ , 从而有

$$\theta_t(k) = \bigcup_{\{n : [\Theta(k)]_{n,t} = 1\}} \epsilon(n, k) \quad (3.17)$$

$$\begin{aligned} P\{\epsilon(n, k) | Z(k)\} &= \frac{P\{Z(k) | \epsilon(n, k), Z(k-1)\}}{\sum_{n=1}^N P\{Z(k) | \epsilon(n, k), Z(k-1)\}} \\ &= \frac{1}{C} P\{Z(k) | \epsilon(n, k), Z(k-1)\} \end{aligned} \quad (3.18)$$

式中,  $C$  为归一化常数。联合似然函数为

$$\begin{aligned} P\{Z(k) | \epsilon(n, k), Z(k-1)\} &= \prod_{l=1}^{m(k)} P\{Z_l(k) | \epsilon(n, k), Z(k-1)\} \\ &= \lambda^{m(k)-T} \prod_{l=1}^T P_{[\Theta(k)]_{n,t}}^l(k) \end{aligned} \quad (3.19)$$

式中

$$p_l^i(k) = \begin{cases} \lambda(1 - P_D) & (\text{若 } l=0) \\ \frac{1}{(2\pi)^{M/2} |\mathbf{S}^i(k)|^{1/2}} \exp[-\frac{1}{2} g_l^i(k)] P_D & (\text{若 } l \neq 0, \text{ 且 } Z_l(k) \in V^i(k)) \\ 0 & (\text{其他}) \end{cases} \quad (3.20)$$

式中,  $\lambda$  为杂波密度;  $P_D$  为探测器接收正确回波的概率;  $M$  为量测

向量的维数;  $g_i^*(k)$  为新息范数;  $S'(k)$  为目标  $i$  的新息协方差矩阵。

JPDA 关联概率为

$$\beta_i^*(k) = \sum_{\{n : [\Theta(k)]_{n,i} = i\}} P\{\epsilon(n, k) | Z(k)\} \\ (l \leq i \leq T, 0 \leq l \leq m(k)) \quad (3.21)$$

从矩阵  $\Theta(k)$  可知, 可行联合事件总数可变, 且为

$$N = \prod_{t=1}^T m^t(k) \quad (3.22)$$

可见  $N$  随候选回波数和目标数的增加而急剧增加。文献[79]也指出, 该方法计算量近似与目标数的阶乘( $T!$ )成正比。因而, JPDA 方法在密集回波环境下跟踪多目标时, 其关联概率的计算负荷呈指数规律增长, 出现计算组合爆炸现象, 从而限制了该方法广泛的实际应用<sup>[78,83]</sup>。

### 3.3 Hopfield 网络模型与旅行商问题(TSP)

1985 年, Hopfield 和 Tank<sup>[84]</sup>建立全互连神经网络模型, 并且用它成功地探讨了被证明具有 NP(非多项式)完全复杂性的旅行商问题(TSP)的求解方法, 在世界学术界引起震惊和关注。

研究表明, 在 Hopfield 网络中, 当神经元无自连接和连接权矩阵具有对称性, 即

$$\left. \begin{array}{ll} W_{ii} = 0 & (i = 1, 2, \dots, N) \\ W_{ij} = W_{ji} & (i, j = 1, 2, \dots, N) \end{array} \right\} \quad (3.23)$$

时, 算法是收敛的。

Hopfield 网络分离散型和连续型两类。

#### 3.3.1 离散型 Hopfield 网络

在有  $N$  个神经元的离散型 Hopfield 网络中, 对神经元  $i$  而言,  $V_1, V_2, \dots, V_N$  为其输入, 它们对神经元的影响程度用连接权  $W_{1i}, W_{2i}, \dots, W_{Ni}$  来表征,  $\theta_i$  为神经元  $i$  的阈值,  $V_i$  为其输出, 则有

$$V_i = \text{sgn}(\sum_{j \neq i}^N W_{ij} V_j - \theta_i) \quad (3.24)$$

网络计算能量函数定义为

$$E = \frac{1}{2} \sum_{i=1}^N \sum_{\substack{j=1 \\ j \neq i}}^N W_{ij} V_i V_j + \sum_{i=1}^N \theta_i V_i \quad (3.25)$$

能量的变化量为

$$\Delta E_i = \frac{\partial E}{\partial V_i} \Delta V_i = \Delta V_i \left( -\sum_{\substack{j=1 \\ j \neq i}}^N W_{ij} V_j + \theta_i \right) \quad (3.26)$$

考虑到  $|V_i| = 1$ , 只要满足

$$\theta_i \leq \sum_{\substack{j=1 \\ j \neq i}}^N W_{ij} \quad (3.27)$$

则有

$$\Delta E_i \leq 0 \quad (3.28)$$

可以看出, 这种网络是一个多输入、多输出、带阈值的二态非线性动力学系统。在满足一定的参数条件下, 其计算能量函数 (Lyapunov 函数) 在网络运行过程中是不断减小的, 最后趋于稳定的平衡状态, 其最小值位于由  $0 \leq v_i \leq 1$  定义的  $n$  维超立方体的某个顶点上。

### 3.3.2 连续型 Hopfield 网络

这种网络在时间上连续, 各神经元处于同步工作状态。设  $u_i$  为神经元  $i$  的内部膜电位状态,  $V_i$  为其输出,  $C_i$  为细胞膜输入电容,  $R_i$  为细胞膜的传递电阻, 则可建立神经元  $i$  的状态方程和输出方程如下:

$$\frac{du_i}{dt} = -\frac{u_i}{\tau} + \sum_{\substack{j=1 \\ j \neq i}}^N W_{ij} V_j + I_i \quad (3.29)$$

$$V_i = g(u_i) \quad (3.30)$$

图 3.1 为用运算放大器构造的连续型 Hopfield 网络。图中采用对称的全局连接方法。

通常, 式(3.30)采用单调递增函数, 即在引入调节参数  $u_0$  后

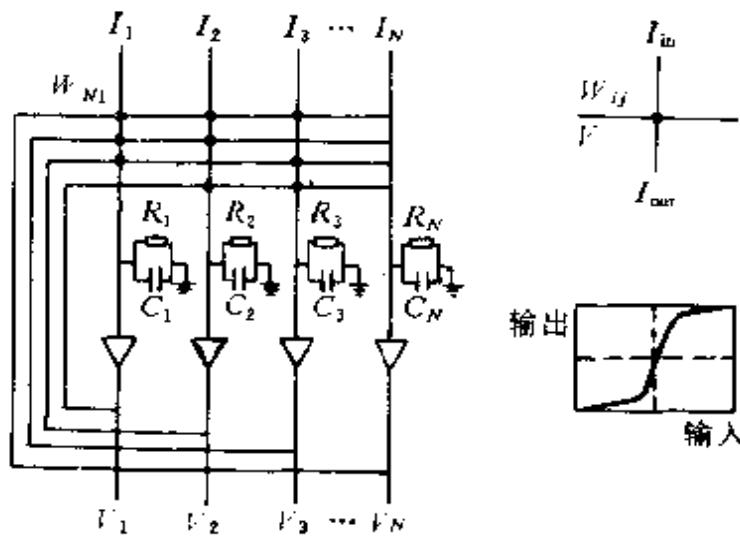


图 3.1 连续型 Hopfield 网络

有

$$V_i = g\left(\frac{u_i}{u_0}\right) - \frac{1}{2} [1 + \tanh\left(\frac{u_i}{u_0}\right)] = \frac{1}{1 + e^{-\frac{2u_i}{u_0}}} \quad (3.31)$$

当  $u_0$  值不断减小时, 式(3.31)描述的单调递增 S 型曲线逐渐和离散的阶跃函数靠近。

网络的计算能量函数为

$$E = -\frac{1}{2} \sum_{i=1}^N \sum_{j=1, j \neq i}^N W_{ij} V_i V_j - \sum_{i=1}^N V_i I_i + \sum_{i=1}^N \frac{1}{\tau} \int_0^{V_i} g^{-1}(t) dt \quad (3.32)$$

不难看出

$$\frac{dE}{dV_i} = -\left(\sum_{j=1, j \neq i}^N W_{ij} V_j + I_i - \frac{u_i}{\tau}\right) = -\frac{du_i}{dt} \quad (3.33)$$

从而有

$$\frac{dE}{dt} = \sum_{i=1}^N \frac{dE}{dV_i} \frac{dV_i}{dt} = -\sum_{i=1}^N \frac{dV_i}{dt} \frac{du_i}{dt} = -\sum_{i=1}^N \frac{du_i}{dV_i} \left(\frac{dV_i}{dt}\right)^2 \quad (3.34)$$

当  $V_i = g(u_i)$  为 Sigmoid 函数时, 其逆函数  $u_i = g^{-1}(V_i)$  为非减函数, 即

$$\frac{du_i}{dV_i} = \frac{d}{dV_i} [g^{-1}(V_i)] > 0 \quad (3.35)$$

从而由式(3.34)知

$$\frac{dE}{dt} \leq 0 \quad (3.36)$$

因此,由式(3.29)和式(3.30)所表征的动态方程,其能量函数是不断减小的,并最后稳定至其极小值(或全局极小值)。

由此不难想到,如果我们能把某个待解决的问题化为一个计算能量函数,且使这个能量函数的最小极值正好对应于一定约束条件下的问题的解答时,则这个问题就可以用连续型 Hopfield 网络来求解了。

### 3.3.3 TSP 及其神经网络求解策略

连续型 Hopfield 网络可用来求解著名的 TSP 组合优化难题<sup>[84~86]</sup>。

问题的表达为:设有  $N$  个城市  $C = \{C_1, C_2, \dots, C_N\}$ ,给定  $C$  中任意两个城市间的距离  $d(C_i, C_j) = d_{ij}, 1 \leq i, j \leq N$ ,现在要找出一个城市的排列  $\{C_n(1), C_n(2), \dots, C_n(N)\}$ ,使得闭合路径  $\sum_{i=1}^N d[C_n(i), C_n(i+1)]_{\text{mod}N}$  为最小。这是一个典型的 NP 完全复杂性难题,若用传统的穷举搜索法,则要从  $\frac{1}{2}(N-1)!$  个方案中选出最短路径,考虑到每条路径要计算  $N$  个距离之和,其计算量将正比于  $\frac{1}{2}N!$ 。对于只有 20 个城市的 TSP 问题,若用每秒运算 1 亿次的 Cray 巨型计算机按穷举搜索法计算需要 350 年之久,显然,这是无法实现的。用神经网络求解,则可把最短路径问题方便地化为一个求解能量函数的最小值问题。

为清楚起见,这里举出一个有  $A, B, C, D$  和  $E$  五个城市的 TSP 例子加以说明。显然,可用一个换位阵来表征一条访问路径。图 3.2 表示一条访问路径  $B \rightarrow D \rightarrow C \rightarrow E \rightarrow A \rightarrow B$  及相应的换位矩阵。此时的路径长度为

$$S = d_{BD} + d_{DC} + d_{CE} + d_{EA} + d_{AB} \quad (3.37)$$

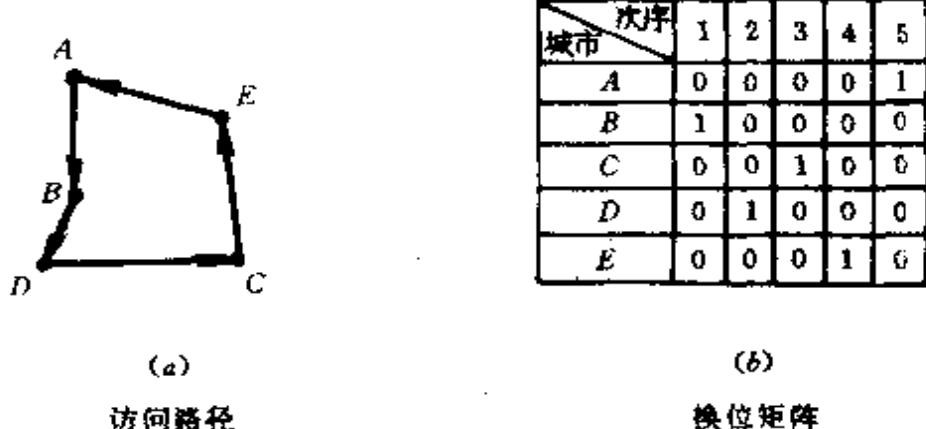


图 3.2 访问路径及其换位矩阵

对于  $N$  个城市来说,换位矩阵[TSP]有  $N \times N$  个元素,需用  $N^2$  个互连的神经元网络来表征,约束条件为:(1) [TSP]每行只能有一个“1”; (2) [TSP]每列只能有一个“1”; (3) [TSP]中元素“1”之和应为  $N$ ; (4) 所构造能量函数的极小值对应于最短路径。

设  $V_{xi}$  是在  $[TSP]_{x,i}$  位置上神经元的输出电压,  $V_{xi}=1$  表示第  $x$  个城市在第  $i$  次被访问,否则为 0。由上述约束条件可构造出相应的计算能量函数

$$\begin{aligned}
 E_{\text{TSP}} = & \frac{a}{2} \sum_{x=1}^N \sum_{i=1}^{N-1} \sum_{j=i+1}^N V_{xi} V_{xj} + \frac{b}{2} \sum_{i=1}^N \sum_{x=1}^{N-1} \sum_{y=x+1}^N V_{xi} V_{yi} \\
 & + \frac{c}{2} \left( \sum_{x=1}^N \sum_{i=1}^N V_{xi} - N \right)^2 \\
 & + \frac{d}{2} \sum_{x=1}^N \sum_{y=1}^N \sum_{i=1}^N d_{xy} V_{xi} (V_{yi+1} + V_{yi-1}) \quad (3.38)
 \end{aligned}$$

式(3.38)中的前 three 项与约束条件(1)、(2)和(3)的要求相对应,只有当上述三条件均满足时,前三项取最小值 0,故称前三项为惩罚项。第四项为目标项,其最小值对应于最短路径长度。

根据式(3.29)、(3.30)和式(3.32),可以将连续型 Hopfield 网络求解 TSP 的  $(x,i)$  处神经元的动态方程表为

$$\frac{du_{xi}}{dt} = -\frac{u_{xi}}{\tau} - a \sum_{\substack{j=1 \\ j \neq i}}^N V_{xj} - b \sum_{y=1}^N V_{yi} - c \left( \sum_{z=1}^N \sum_{j=1}^N V_{zj} - N \right)$$

$$-d \sum_{y=1}^N d_{xy} (V_{y,i+1} + V_{y,i-1}) \quad (3.39)$$

$$V_n = g(u_n) = \frac{1}{2}(1 + \tanh \frac{u_n}{u_0}) \quad (3.40)$$

此时, 神经元( $x, i$ )和( $y, j$ )间的连接权  $W_{x,y}$  和神经元( $x, i$ )的偏置  $I_x$  分别为

$$W_{x,y} = -a\delta_{xy}(1 - \delta_{ij}) + b\delta_{ij}(1 - \delta_{xy}) - c - dd_{xy}(\delta_{j,i+1} + \delta_{j,i-1}) \quad (3.41)$$

$$I_x = cN \quad (3.42)$$

式中  $\delta_{ij}$  的定义为

$$\delta_{ij} = \begin{cases} 1 & (i=j) \\ 0 & (i \neq j) \end{cases} \quad (3.43)$$

从而式(3.38)可等价为

$$E_{TSP} = -\frac{1}{2} \sum_i \sum_j \sum_x \sum_y W_{x,y} V_x V_y - \sum_i \sum_x V_x I_x \quad (3.44)$$

适当选择( $a, b, c, d$ )以确定权值  $W_{x,y}$ , 在给定  $V_n$  初始条件下, 由式(3.39)和式(3.40)反复迭代, 使电路的稳定状态接近全局最小极值点。经验表明, 取  $a=500, b=500, c=200, d=500, \tau=1$  和  $u_0=0.02$  时, 能得到较满意的结果。

### 3.4 神经联合概率数据关联(NJPDA)

JPDA 方法的实质是从似然函数  $p_t^i(k)$  中求解关联概率  $\beta_t^i(k)$ , 它是一个类似于 TSP 并在计算上具有 NP 完全复杂性的组合优化问题。因此, 可以模拟 Hopfield 网络对 TSP 的求解策略提出一个全新的 JPDA 方法, 即神经联合概率数据关联方法(NJPDA)。

JPDA 具有以下两个独有的重要特征<sup>[28,83]</sup>。设事件  $G(X)=\{\text{变量 } X \text{ 具有大值}\}$ , 则

特征 1  $G\{\beta_t^i(k)\} \cap G\{\beta_t^r\} = \emptyset, \forall t \neq r$

$$\text{特征 2 } G\{\beta_t^i(k)\} = G\{p_t^i(k)\} \cap G\left(\prod_{\substack{t' \neq t \\ j \neq i}} p_j^{t'}(k)\right)$$

JPDA 的两个特征使得数据关联问题有表 3.1 所示的约束条件。由表 3.1 可以看出, 由似然函数求关联概率类似于求解 TSP。

表 3.1 JPDA 和 TSP 约束条件对比表

	JPDA	TSP
1	$\sum_{i=0}^{m(k)} \beta_t^i(k) = 1, t=1, 2, \dots, T$	通过所有 $N$ 个城市
2	$G\{\beta_t^i(k)\} \cap G\{\beta_{t'}^j(k)\} = 0, \forall t \neq t'$ $\Leftrightarrow$ 一个回波只能属于一个目标	两个城市不能同时经过
3	$G\{\beta_t^i(k)\} \cap G\{\beta_{t'}^j(k)\} = 0, \forall t \neq t'$ $\Leftrightarrow$ 一个目标只能产生一个回波	一个城市只能经过一次
4	$G\{\beta_t^i(k)\} = G\{p_t^i(k)\} \cap G\left(\prod_{\substack{t' \neq t \\ j \neq i}} p_j^{t'}(k)\right)$ $\Leftrightarrow$ 寻求最佳关联概率	寻求最短路径

构造  $[m(k)+1] \times T$  的神经元网络矩阵, 列对应于目标, 行对应于回波, 第零行对应于没有任何候选回波这一特殊事件。若定义神经元的输出电压  $V_i^t$  为关联概率  $\beta_t^i(k)$ ,  $p_t^i(k)$  为该神经元的输入电流,  $i=0, 1, 2, \dots, m(k)$ ;  $t=1, 2, \dots, T$ , 则可构造如下相应于数据关联问题(DAP)的能量函数

$$\begin{aligned} E_{\text{DAP}} = & \frac{a}{2} \sum_t \sum_i \sum_{i' \neq i} V_i^t V_{i'}^t + \frac{b}{2} \sum_t \sum_i \sum_{j \neq i} V_i^t V_j^t \\ & + \frac{c}{2} \sum_t (\sum_i V_i^t - 1)^2 + \frac{d}{2} \sum_t \sum_i (V_i^t - p_i^t)^2 \\ & + \frac{e}{2} \sum_t \sum_i \sum_{i' \neq i} (V_i^t - \sum_{j \neq i} p_j^t)^2 \end{aligned} \quad (3.45)$$

其中  $p_i^t$  是  $p_t^i(k)$  的归一化值, 即

$$\rho_l^t(k) = \frac{p_l^t(k)}{\sum_{j=0}^{m(k)} p_j^t(k)} \quad (t=1, 2, \dots, T; l=0, 1, 2, \dots, m(k)) \quad (3.46)$$

式(3.45)中第一项对应于约束条件2,第二项对应于约束条件3,第三项对应于约束条件1,第四、五项对应于约束条件4。与TSP类似,将式(3.45)写成

$$E_{\text{DAP}} = -\frac{1}{2} \sum_t \sum_i \sum_i \sum_i W_{ij}^t V_i^t V_j^t - \sum_t \sum_i V_i^t I_i^t \quad (3.47)$$

式中

$$W_{ij}^t = -[a\delta_{ij}(1-\delta_{ii}) + b\delta_{ii}(1-\delta_{ij}) + c\delta_{ii} + d\delta_{ii}\delta_{ij} - e(T-1)\delta_{ii}\delta_{ij}] \quad (3.48)$$

$$I_i^t = c + (d+e)\rho_i^t + e(T-1 - \sum_i \rho_i^t) \quad (3.49)$$

由上可知,权值  $W_{ij}^t$  不依赖于  $\rho_i^t(k)$ ,而完全由系数  $\{a\ b\ c\ d\ e\}$  组合构成,一旦选定,  $W_{ij}^t$  便随之确定,神经网络结构便固定下来,因此,没有必要在每一个采样时刻为一组新的似然函数重新设计一个新的神经网络。相反,输入电流  $I_i^t$  可以很方便地由似然函数来控制。

求解 DAP 的神经网络动态方程为

$$\begin{aligned} \frac{du_i^t}{dt} = & \frac{u_i^t}{\tau_0} - a \sum_{\substack{i=1 \\ i \neq j}}^T V_j^t - b \sum_{\substack{j=0 \\ j \neq i}}^{m(k)} V_j^t - c \left( \sum_{j=0}^{m(k)} V_j^t - 1 \right) \\ & - [d + e(T-1)]V_i^t - (d+e)\rho_i^t + e(T-1 - \sum_{i=1}^T \rho_i^t) \end{aligned} \quad (3.50)$$

$$V_i^t = g(u_i^t) = \frac{1}{2} (1 + \tanh \frac{u_i^t}{u_0}) = \frac{1}{1 + \exp(-2u_i^t/u_0)} \quad (3.51)$$

很明显,上述网络结构具有并行处理的特点,输入不同的  $\rho_i^t(k)$ ,网络便开始其动态演化过程,最终趋于平衡状态。此时,各神经元的输出电压  $V_i^t$  便成为对应的关联概率  $\beta_i^t(k)$ 。因此,密集回波环境下多目标数据关联的计算量大大降低。若目标数增大,建立

在传统串行处理基础的 JPDA 方法计算量呈组合爆炸现象,而这种 NJPDA 方法仅需要一个较大的互连神经元网络。回波密度越大,目标数目越多,NJPDA 方法的优越性愈突出。

系数 $\{a\ b\ c\ d\ e\}$ 的取值决定了对不同特征和约束的权重。较大的 $d$ 值将使 $V_l$ 接近于 $p_l$ ,这相当于近似的普通 PDA 方法;较大的 $a\ b$ 和 $c$ 值将产生最近邻解,这相当于“最近邻”相关方法;一组适当选择的组合参数 $\{a\ b\ c\ d\ e\}$ 将完全模拟和复现 JPDA 的所有性质。

### 3.5 随机神经网络与快速随机神经联合概率数据关联(FSNJPDA)

仿真研究表明,利用上述计算能量函数 $E_{DAP}$ 的极小值来确定系统的稳定点,从而得到满足约束条件的满意解,往往由于陷入局部极小而无法达到全局最小,从而得不到全局最优解。同时还发现,要想得到全局最优解,所需计算时间将为无穷大。

为了避免能量函数陷入局部极小点,并大幅度提高收敛速度,以获得关联概率接近全局最优的满意解,可采用基于 Boltzmann 机的随机神经网络和增益模拟退火方法。

Boltzmann 机模型于 1983 年由 Hinton, Sejnowski 和 Ackley 提出<sup>[87, 88]</sup>,其拓扑结构、连接权矩阵和能量函数等方面,都和 Hopfield 神经网络模型类似。

设 $S_i$ 表示神经元 $i$ 的内部状态, $S_j$ 为从神经元 $j$ 来的输入, $\theta_i$ 为阈值, $p_i(0)$ 和 $p_i(1)$ 分别表示神经元 $i$ 输出为 0 和 1 的概率。在 Boltzmann 机模型下, $I_i$ , $p_i(0)$ 和 $p_i(1)$ 的关系为

$$S_i = \sum_{j=1}^N w_{ij} S_j - \theta_i \quad (3.52)$$

$$p_i(0) = \frac{1}{1 + \exp(-S_i/T_0)} \quad (3.53)$$

$$p_i(1) = 1 - p_i(0) = \frac{\exp(-S_i/T_0)}{1 + \exp(-S_i/T_0)} \quad (3.54)$$

式中,参数  $T_0$  为网络温度。不难看出,  $T_0$  越大, 神经元  $i$  的输出取值为 0 和 1 的机会接近, 使得各神经元有更多的机会进行状态选择, 也即状态变化越容易, 陷入局部极小的机会越小。为了使网络收敛到低温下的平衡状态, 可以从高温开始, 徐徐降温, 最后保证以相当高的概率收敛到网络的最小能量状态。这种先升温后缓慢降温的方法称为模拟退火法。

比较式(3.51)和式(3.53), 可以看出, Hopfield 网络中神经元的增益( $1/u_0$ )同 Boltzmann 机模型中温度参数  $T_0$  的倒数( $1/T_0$ )的作用非常类似, 因此, 可以方便地将 Boltzmann 机模型和模拟退火方法引入到 Hopfield 网络的运行过程中, 其基本思想是, 若神经元增益低, 则状态轨迹可以避开局部极小点; 若增益太低, 则演化很慢, 达到稳态的时间可能很长; 为此, 在演化之初能量函数梯度大时降低增益, 使演化尽量避免误入局部陷阱, 而在演化后期能量函数梯度小时加大增益, 从而使演化加速进行并尽快达到全局最小。这种先降低增益后增大增益的方法称为增益模拟退火方法。本文取  $u_0 = 0.02 \times 0.995^k$ ,  $k$  为迭代次数。根据万能逼近性质, 这种方法将使能量函数以概率 1 趋近于全局最小。

此外, 对初始条件加入随机噪声可促进收敛<sup>[87]</sup>。由式(3.51)有

$$u_i^t = \frac{u_0}{2} \ln \left( \frac{V_i^t}{1 - V_i^t} \right) \quad (3.55)$$

若选  $V_i^t$  的初始条件为

$$V_i^t = \frac{1}{1 + m(k)} \quad (3.56)$$

因  $V_i^t$  满足  $\sum_{i=0}^{m(k)} V_i^t = 1$ , 则

$$u_i^t = -\frac{u_0}{2} \ln m(k) \quad (3.57)$$

选  $u_i^t$  的初始条件为

$$u_t^i = \delta u_t^i - \frac{u_0}{2} \ln m(k) \quad (3.58)$$

式中,  $\delta u_t^i$  是在  $[-0.1u_0, 0.1u_0]$  上服从均匀分布的随机变量;  $u_0$  取值为 0.02, 以保证具有足够的收敛速度。

我们称在 NJPDA 中引入 Boltzmann 机随机神经网络和增益模拟退火后的方法为快速随机神经联合概率数据关联方法(FSNJPDA)。

### 3.6 仿真结果

为了便于对 FSNJPDA 进行仿真, 需将式(3.50)和式(3.51)化为如下差分方程:

$$\begin{aligned} u_t^i(i+1) = & \frac{\tau_0 - \xi}{\tau_0} \cdot u_t^i(i) - \xi a \sum_{\substack{\tau=1 \\ \tau \neq i}}^T V_\tau^i(i) - \xi b \sum_{\substack{j=0 \\ j \neq i}}^{m(k)} V_j^i(i) \\ & - \xi c \left( \sum_{j=0}^{m(k)} V_j^i(i) - 1 \right) - \xi [d + e(T-1)] V_i^i(i) \\ & + \xi (d + e) \rho_i^i + \xi e (T-1 - \sum_{\tau=1}^T \rho_\tau^i) \end{aligned} \quad (3.59)$$

$$V_i^i(i) = \frac{1}{2} [1 + \tanh \frac{u_t^i(i)}{u_0}] \quad (3.60)$$

式中,  $\xi$  为步长;  $\tau_0$  和  $\xi$  分别取为 1s 和 0.00001s; 神经元初始条件如式(3.56)和式(3.58)所示; 杂波密度  $\lambda$  为  $0.2 \text{ km}^{-2}$ ; 目标数  $T$  为 14; 神经网络组合参数取为  $\{a \ b \ c \ d \ e\} = \{6.0 \ 45.0 \ 890.0 \ 20.0 \ 5.0\}$ , 参数优化取值过程见下章。仿真时取迭代 200 次的  $V_i^i$  为关联概率  $\beta_i^*$  的满意解。仿真结果如表 3.2 所示, 表中给出了 FSNJPDA 和 JPDA 在某时刻关联概率的对比值。不难看出, 本章提出的 FSNJPDA 方法不仅能足够准确地求解关联概率, 计算量大大降低, 而且又保持了 JPDA 方法的优良性能。

相反, 在相同条件下, NJPDA 要达到 FSNJPDA 求解关联概率的满意程度, 其迭代次数至少要 400 步, 收敛时间增大一倍以

上。而且,在参数选择不当的情况下,NJPDA 还容易陷入局部极小点。

需要说明,当采用零阶差分时,连续型网络退化为离散型网络。

### 3.7 结论

本章通过对 JPDA 性能特征的分析,并与著名的 TSP 类比,将多目标数据关联化为一类约束组合优化问题,进而应用随机神经网络和增益模拟退火技术求解,提出了一种新的快速随机神经联合概率数据关联方法 FSNJPDA。仿真结果表明,该方法在不损失 JPDA 优良性能的前提下,克服了计算上出现的组合爆炸现象,收敛速度大大提高,避免了局部极小,保证了网络的全局最优性能,得出了在一定时间内接近于全局最优的数据关联概率的满意解。

这种求满意解而不求绝对精确解以节省大量处理时间的方法,正是人类大脑智能信息活动的一个极其重要的特征。

当目标数  $T$  和杂波密度  $\lambda$  很大时,为限制网络维数的增高,进一步降低 FSNJPDA 的计算量,可采用将跟踪空间  $V_T$  合理化分为  $L$  个子空间的方法,即  $V_T = V_T \cdot L$ ,使得在每个子空间  $V_L$  中能用 FSNJPDA 方法,而后将这些子空间的结果综合起来。或者根据聚矩阵  $\Omega(k)$  中列向量的“1”范数分析目标的相关态势,对相互关联的目标聚类应用 FSNJPDA,而对互不相关的目标准则应用 PDA,这是在大空域内求解密集目标数据关联问题的有效手段。

表 3.2 某时刻 FSNJPDA 和 JPDA 的关联概率

回 波 场 法		非有效 回波												
		1	2	3	4	5	6	7	8	9	10	11	12	13
1	FSNJPDA	0.02				0.03	0.01							0.94
	JPDA	0.01				0.02	0.01							0.96
2	FSNJPDA	0.01	0.90											
	JPDA	0.01	0.05											
3	FSNJPDA	0.02						0.87	0.02					
	JPDA	0.08						0.84	0.01					
4	FSNJPDA	0.03								0.88				0.09
	JPDA	0.09								0.85				0.06
5	FSNJPDA	0.03					0.82							0.08
	JPDA	0.04					0.88							0.04
6	FSNJPDA	0.01	0.11			0.83		0.03	0.02					0.07
	JPDA	0.09	0.06			0.89		0.04	0.01					0.04
7	FSNJPDA	0.06			0.03			0.87				0.04		
	JPDA	0.02			0.01			0.91				0.06		
8	FSNJPDA	0.01			0.11	0.03	0.01							0.84
	JPDA	0.00			0.05	0.02	0.07							0.86
9	FSNJPDA	0.01	0.02									0.97		
	JPDA	0.03	0.03									0.94		
10	FSNJPDA	0.02			0.12			0.01	0.85					
	JPDA	0.01			0.06			0.01	0.92					
11	FSNJPDA	0.01	0.06							0.88	0.03	0.02		
	JPDA	0.00	0.09							0.81	0.03	0.07		

		国 波 非有效 国波													
		1	2	3	4	5	6	7	8	9	10	11	12	13	14
目 标	方 法	FSNJPDA	0.02		0.93										
		JFDA	0.01		0.91										
13	方 法	FSNJPDA	0.03		0.95						0.02				
		JFDA	0.02		0.96						0.02				
14	方 法	FSNJPDA	0.02								0.11				
		JFDA	0.05								0.02				

注：空格中的所有值为0；

目标/真实回波对：1/14,2/1,3/6,4/9,5/5,6/4,7/7,8/13,9/10,10/8,11/11,12/3,13/2,14/12。

## 第四章 随机神经网络组合参数优化

### 4.1 引言

上章研究表明,求解多目标关联概率的随机神经网络结构完全由组合参数 $\{a\ b\ c\ d\ e\}$ 决定,组合参数的取值直接影响着跟踪系统的性能。组合参数优化和关键性能参数的确定,至今仍是基于神经网络的跟踪系统设计的难点<sup>[3,84,85]</sup>。本章基于参数稳定性、灵敏度和鲁棒性分析理论,借助于计算机仿真,提出一种随机神经网络组合参数优化方法。仿真结果表明,该方法不仅能给出最优或次优参数组合,而且能确定影响系统性能的关键因素,不失为一种有效的参数优化工具。

### 4.2 参数稳定性、灵敏度和鲁棒性分析理论概述

灵敏度和鲁棒性分析理论是现代控制系统设计与分析的一种有效工具。系统设计的首要问题是保证系统能稳定可靠地工作。

参数稳定性是指系统参数在某一区域内变化时仍能保持系统稳定工作的能力。

灵敏度是指系统在额定工作点附近有小的参数摄动时,这种摄动对系统性能的影响程度。

鲁棒性是指系统参数在额定工作点附近大范围变化时,系统仍能在一个足够大的区域中保持对性能指标要求的能力。

设  $J$  为系统的性能指标,且  $J$  是参数向量  $a$  的函数,在最优工况下,由于  $J$  取极小值,故有

$$\frac{\partial J}{\partial \mathbf{a}}|_{\mathbf{a}=\mathbf{a}_0^*} = 0 \quad (4.1)$$

式中  $\mathbf{a}_0^*$  为给定性能指标下的最优参数向量。

### 4.3 随机神经网络组合参数优化与关键性能参数的确定

本节的目的是寻求最优的随机神经网络组合参数  $\{a\ b\ c\ d\ e\}$ ，以使得跟踪系统能适应大范围目标数和杂波密度的变化。换言之，组合参数  $\{a\ b\ c\ d\ e\}$  的适当选择应首先保证 Hopfield 网络工作在稳定区域，即使网络具有很强的鲁棒性和较小的参数灵敏度，又同时保证系统的性能指标最优或渐近最优。

由上一章可知，随机神经网络的能量函数为

$$\begin{aligned} E_{DAP} = & \frac{a}{2} \sum_i \sum_j \sum_{i \neq j} V_i^j V_i^i + \frac{b}{2} \sum_i \sum_j \sum_{i \neq j} V_i^j V_j^i \\ & + \frac{c}{2} \sum_i (\sum_i V_i^i - 1)^2 + \frac{d}{2} \sum_i \sum_j (V_i^j - \rho_i^j)^2 \\ & + \frac{e}{2} \sum_i \sum_j \sum_{i \neq j} (V_i^j - \sum_{i \neq j} \rho_i^j)^2 \end{aligned} \quad (4.2)$$

表面上看，似乎  $E_{DAP}$  与组合参数  $\{a\ b\ c\ d\ e\}$  呈线性关系。但实际上，由于神经元输出电压  $V_i^j$  与组合参数有关，因而  $E_{DAP}$  是关于  $\{a\ b\ c\ d\ e\}$  的非线性函数，且该函数关系难以用显式表述。

本节借助于计算机 Monte Carlo 仿真，并利用参数稳定性、灵敏度和鲁棒性的概念来求解最优组合参数和确定关键性能参数。

50 次 Monte Carlo 仿真得出的关于  $E_{DAP}$  与  $\{a\ b\ c\ d\ e\}$  的平均拟合关系曲线如图 4.1~图 4.5 所示。由图可以看出，在  $E_{DAP}$  的稳定区域内，参数  $a$ 、 $b$  和  $c$  对  $E_{DAP}$  的影响较小，即  $a$ 、 $b$  和  $c$  对  $E_{DAP}$  的灵敏度较小，在性能指标 ( $E_{DAP}$ ) 最优条件下，可选初值为  $a=6.0 \sim 8.0$ ,  $b=30.0 \sim 70.0$ ,  $c=800.0 \sim 1000.0$ ; 参数  $d$  对  $E_{DAP}$  的影响在一定区域内较小，即在该区域内， $d$  对  $E_{DAP}$  的灵敏度较小，在性能指标最优条件下，可选初值为  $d=15.0 \sim 30.0$ ; 参数  $e$  对  $E_{DAP}$  的影响最大，即其参数灵敏度最大，但在  $3.0 \sim 10.0$  附近，曲线斜率

变小, 相对来讲, 参数灵敏度小一些, 故可选初值为  $e = 3.0 \sim 10.0$ 。

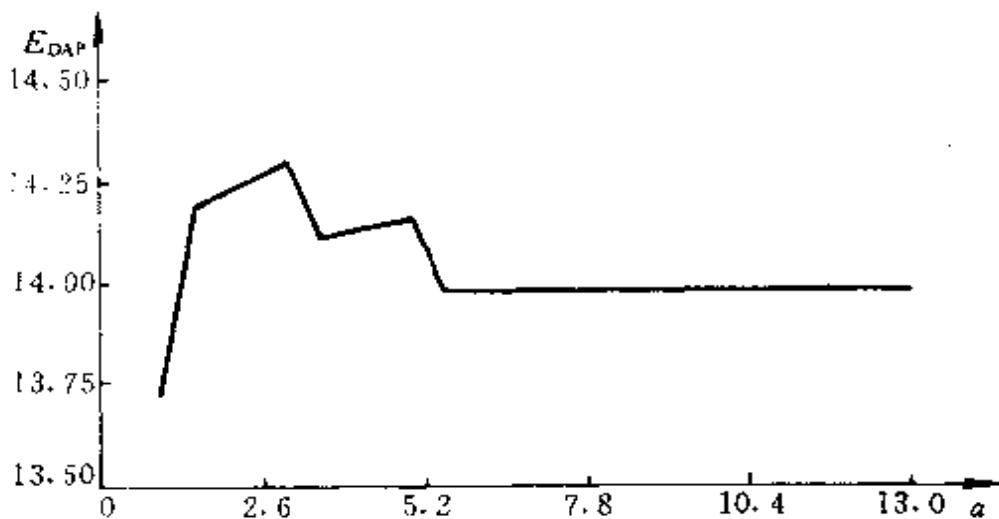


图 4.1  $E_{DAP}-a$  关系曲线

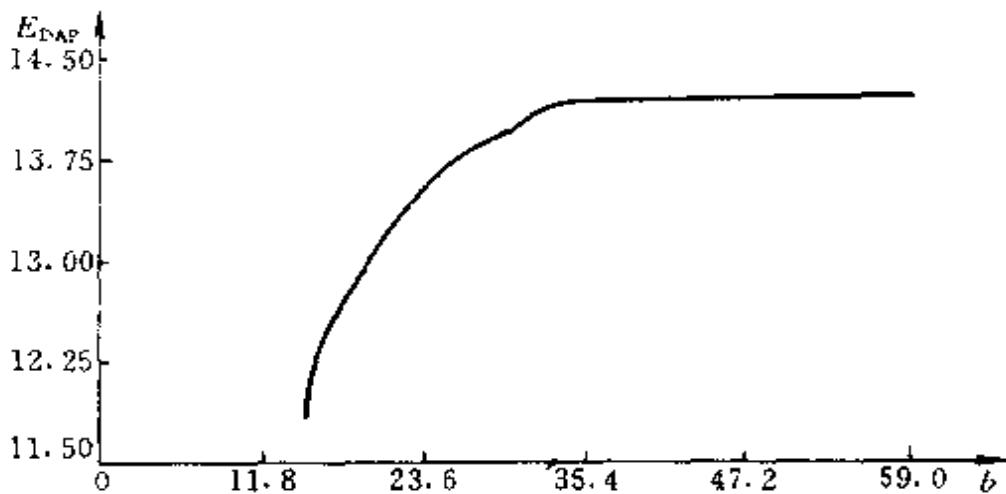
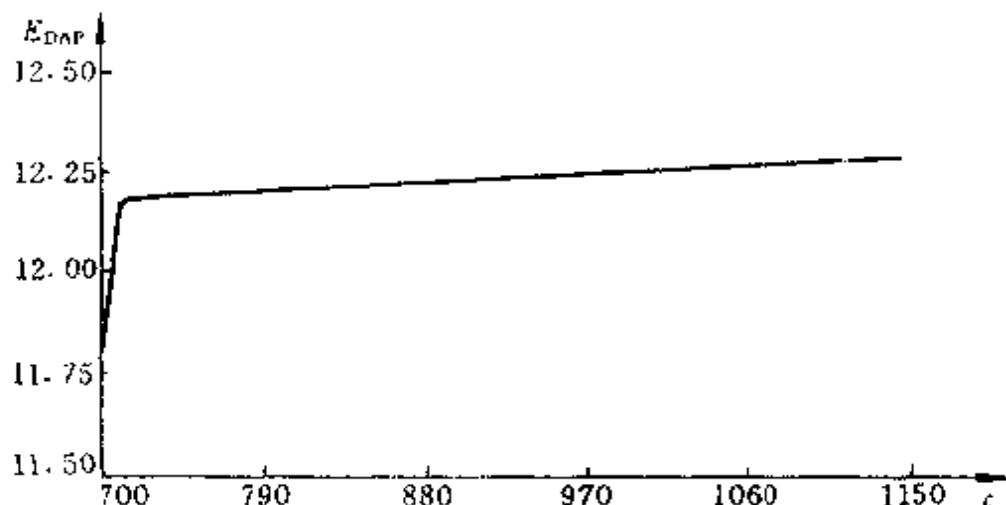
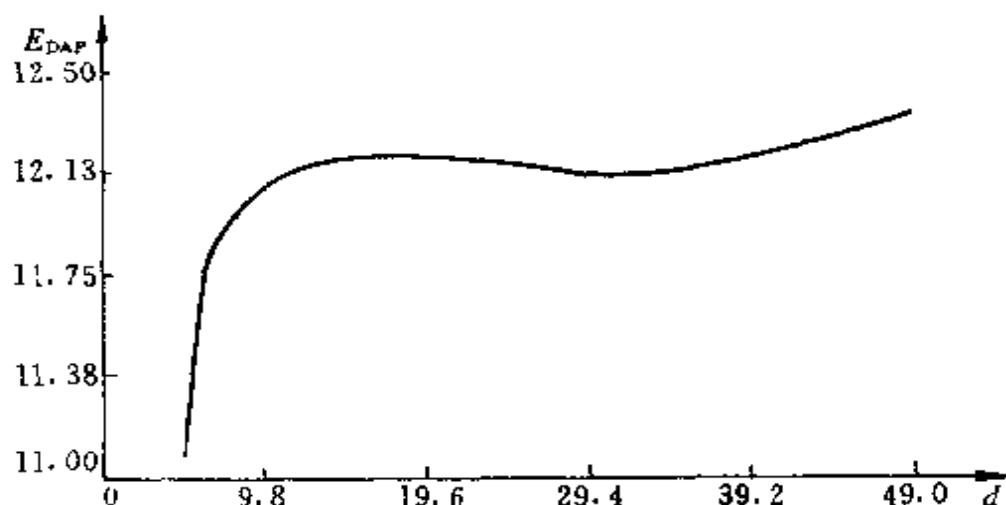


图 4.2  $E_{DAP}-b$  关系曲线

在进行上述参数初选后, 在初选区域内离散取值, 当目标数  $T$  从 1 变化为 14, 杂波密度  $\lambda$  从 0 变化为  $1.0 \text{ km}^{-2}$  时, 考察组合参数  $\{a\ b\ c\ d\ e\}$  对数据关联性能的影响, 可得出如下规律:

1. 在给定初值条件下,  $T$  和  $\lambda$  的大范围变化对  $E_{DAP}$  的影响甚微, 也就是说参数  $a$ 、 $b$  和  $c$  具有很强的鲁棒性。此外,  $a$ 、 $b$  和  $c$  在初

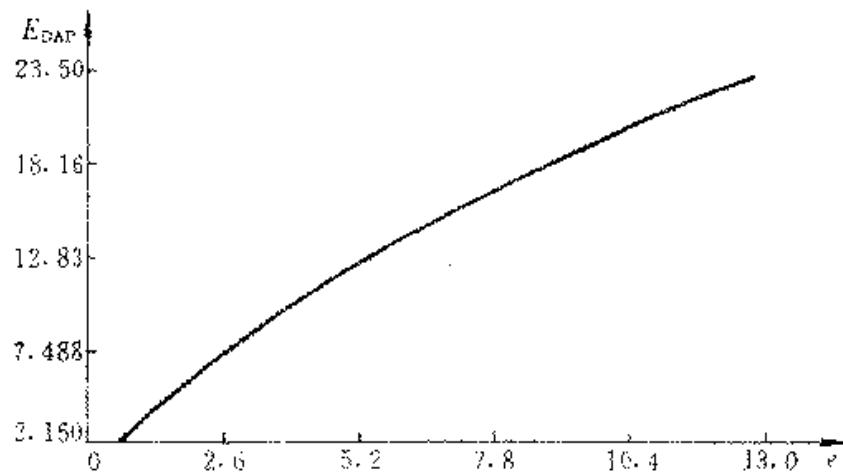
图 4.3  $E_{DAP}-c$  关系曲线图 4.4  $E_{DAP}-d$  关系曲线

选区间内具有较小的参数灵敏度,故选定  $a=6.0, b=45.0, c=890.0$ ;

2. 当  $d$  在  $[15.0, 30.0]$  区间变化时,较小一些的  $d$  值关联效果好,故选定  $d=20.0$ ;

3. 当  $c$  在  $[3.0, 10.0]$  区间变化时,在子区间  $[5.0, 7.0]$  内关联效果最好,故选  $e=5.0$ 。

在  $E_{DAP}$  中,与参数  $d$  和  $e$  相联系的项正是 JPDA 区别于其他

图 4.6  $E_{DAP}$ -e 关系曲线

传统跟踪方法所独有的特征,表现为  $d$  对  $E_{DAP}$  的影响较大,  $e$  对  $E_{DAP}$  的影响最大。因而,在确定最优组合参数时,应该更加重视参数  $d$  和  $e$  的选取。参数  $d$  和  $e$  是影响 FSNJPDA 性能的关键性能参数。

最优随机神经网络组合参数为

$$\{a\ b\ c\ d\ e\} = \{6.0\ 45.0\ 896.0\ 20.0\ 5.0\}$$

#### 4.4 结论

本章基于参数稳定性、灵敏度和鲁棒性分析理论,借助于计算机 Monte Carlo 仿真,研究了 FSNJPDA 中随机神经网络组合参数的优化问题,给出了最优参数组合,指出了影响系统性能的关键因素。仿真结果表明,所选定的最优组合参数具有较小的参数灵敏度,对目标数和杂波密度的大范围变化具有很高的性能鲁棒性。鉴于尚无该方面的文献可资利用,因而上述优化方法不失为一种有效的参数优化工具。

## 第五章 基于随机神经网络的机动 多目标跟踪维持

### 5.1 引言

跟踪维持即保持对目标的连续跟踪,它包括机动识别和自适应滤波与预测两部分。

在第三章和第四章基于随机神经网络的多目标数据关联成果基础上,本章引入机动目标“当前”统计模型和均值与方差自适应跟踪方法,提出一种新的在密集回波环境下跟踪机动多目标的跟踪维持算法——快速随机神经联合概率数据关联自适应滤波算法(FSNJPDAAF)。仿真结果证明了该算法的有效性。

### 5.2 机动目标“当前”统计模型 和均值与方差自适应算法

在每一种具体的战术场合,人们所关心的仅是机动加速度的“当前”概率密度,即目标机动的当前可能性,当目标现时正以其一加速度机动时,它在下一瞬时的加速度取值范围是有限的,而且只能在“当前”加速度的邻域内。因此,在描述机动加速度的概率密度时,完全没有必要考虑机动加速度取值的所有可能性。另一方面,在每一瞬时,一种时变的机动加速度概率密度函数将对应于目标“当前”加速度的变化。机动目标“当前”统计模型<sup>[13]</sup>假定机动加速度的概率密度服从修正的瑞利分布。

当目标“当前”加速度为正时,概率密度函数为

$$P_r(a) = \begin{cases} \frac{(a_{\max} - a)}{\mu^2} \exp\left(-\frac{(a_{\max} - a)^2}{2\mu^2}\right) & (0 < a < a_{\max}) \\ 0 & (a \geq a_{\max}) \end{cases} \quad (5.1)$$

式中,  $a_{\max}$  为已知的加速度正上限;  $a$  为随机加速度;  $\mu > 0$  为一常数。 $a$  的均值和方差分别为

$$E(a) = a_{\max} - \sqrt{\frac{\pi}{2}}\mu \quad (5.2)$$

$$\sigma_a^2 = \frac{4-\pi}{2}\mu^2 = \frac{4-\pi}{\pi}[a_{\max} - E(a)]^2 \quad (5.3)$$

当目标“当前”加速度为负时, 概率密度函数

$$P_r(a) = \begin{cases} \frac{(a - a_{-\max})}{\mu^2} \exp\left(-\frac{(a - a_{-\max})^2}{2\mu^2}\right) & (a_{-\max} < a < 0) \\ 0 & (a \leq a_{-\max}) \end{cases} \quad (5.4)$$

式中  $a_{-\max}$  为已知的加速度负下限。 $a$  的均值和方差分别为

$$E(a) = a_{-\max} + \sqrt{\frac{\pi}{2}}\mu \quad (5.5)$$

$$\sigma_a^2 = \frac{4-\pi}{2}\mu^2 = \frac{4-\pi}{\pi}[a_{-\max} - E(a)]^2 \quad (5.6)$$

当目标“当前”加速度为零时, 概率密度函数为

$$P_r(a) = \delta(a) \quad (5.7)$$

式中  $\delta(\cdot)$  为狄拉克函数。

再假定机动加速度  $a(t)$  在时间轴上符合非零均值一阶时间相关过程, 即

$$\begin{aligned} \ddot{x}(t) &= \ddot{a} + a_1(t) \\ a_1(t) &= -\alpha a_1(t) + \omega(t) \end{aligned} \quad \left. \right\} \quad (5.8)$$

式中,  $\ddot{a}$  为  $a(t)$  的均值;  $a_1(t)$  为零均值有色加速度噪声;  $\alpha$  为机动频率;  $\omega(t)$  是均值为零, 方差为  $\sigma_\omega^2 = 2\alpha\sigma_a^2$  的白噪声。

令  $a(t) = \ddot{a} + a_1(t)$ , 式(5.8)可写为

$$\left. \begin{array}{l} \dot{x}(t) = a(t) \\ \dot{a}(t) = -\alpha a(t) + \alpha \bar{a} + \omega(t) \end{array} \right\} \quad (5.9)$$

将上式写为状态方程,有

$$\begin{bmatrix} \dot{x} \\ \dot{\bar{a}} \\ \ddot{x} \\ \ddot{\bar{a}} \end{bmatrix} = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & -\alpha \end{bmatrix} \begin{bmatrix} x \\ \bar{a} \\ \dot{x} \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \\ \alpha \end{bmatrix} \bar{a} + \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \omega(t) \quad (5.10)$$

设采样周期为  $T$ , 式(5.10)的离散化形式为

$$X(k+1) = \Phi X(k) + U \bar{a} + W(k) \quad (5.11)$$

式中

$$X(k) = [x(k) \ \dot{x}(k) \ \ddot{x}(k)]^T \quad (5.12)$$

$$\Phi = \begin{bmatrix} 1 & T & \frac{1}{\alpha^2}(-1 + \alpha T + e^{-\alpha T}) \\ 0 & 1 & \frac{1}{\alpha}(1 - e^{-\alpha T}) \\ 0 & 0 & e^{-\alpha T} \end{bmatrix} \quad (5.13)$$

$$U = \begin{bmatrix} \frac{1}{\alpha}(-T + \frac{\alpha T^2}{2} + \frac{1 - e^{-\alpha T}}{\alpha}) \\ T - \frac{1 - e^{-\alpha T}}{\alpha} \\ 1 - e^{-\alpha T} \end{bmatrix} \quad (5.14)$$

$W(k)$  为离散时间白噪声序列, 其方差阵为

$$\begin{aligned} Q(k) &= 2\alpha\sigma_w^2 Q_0 \\ &= 2\alpha\sigma_w^2 \begin{bmatrix} q_{11} & q_{12} & q_{13} \\ q_{12} & q_{22} & q_{23} \\ q_{13} & q_{23} & q_{33} \end{bmatrix} \end{aligned} \quad (5.15)$$

其中

$$q_{11} = \frac{1}{2\alpha^5} (1 - e^{-2\alpha T} + 2\alpha T + \frac{2\alpha^2 T^3}{3} - 2\alpha^2 T^2 - 4\alpha T e^{-\alpha T})$$

$$q_{12} = \frac{1}{2\alpha^4} (e^{-2\alpha T} + 1 - 2e^{-\alpha T} + 2\alpha T e^{-\alpha T} - 2\alpha T + \alpha^2 T^2)$$

$$q_{13} = \frac{1}{2\alpha^3} (1 - e^{-2\alpha T} - 2\alpha T e^{-\alpha T})$$

$$q_{22} = \frac{1}{2\alpha^3} (4e^{-\alpha T} - 3 - e^{-2\alpha T} + 2\alpha T)$$

$$q_{23} = \frac{1}{2\alpha^2} (e^{-2\alpha T} + 1 - 2e^{-\alpha T})$$

$$q_{33} = \frac{1}{2\alpha} (1 - e^{-2\alpha T})$$

量测方程为

$$Z(k) = H(k)X(k) + V(k) \quad (5.16)$$

其中当仅有含噪声的目标位置可观测时,有  $H = [1 \ 0 \ 0]$ ;  $V(k)$  是均值为零、方差为  $R(k)$  的高斯白噪声,且

$$V(k) = [\beta x(k) + \Delta x_0] \omega(k) \quad (5.17)$$

$$R(k) = [\beta x(k) + \Delta x_0]^2 \quad (5.18)$$

式中,  $\beta$  为相对误差系数;  $\Delta x_0$  为探测器量测偏差;  $\omega(k)$  是均值为零、方差为 1 的正态伪随机数。

基于上述机动目标“当前”统计模型的均值和方差自适应滤波方程为

$$\hat{X}(k/k) = \hat{X}(k/k-1) + K(k)[Z(k) - H(k)\hat{X}(k/k-1)] \quad (5.19)$$

$$\hat{X}(k/k-1) = \Phi \hat{X}(k-1/k-1) + U \bar{a}(k) \quad (5.20)$$

$$K(k) = P(k/k-1)H(k)^T[H(k)P(k/k-1)H(k)^T + R(k)]^{-1} \quad (5.21)$$

$$P(k/k-1) = \Phi P(k-1/k-1) \Phi^T + Q(k-1) \quad (5.22)$$

$$P(k/k) = [I - K(k)H(k)]P(k/k-1) \quad (5.23)$$

$$\bar{a}(k) = \ddot{x}(k/k-1) \quad (5.24)$$

式中加速度均值自适应由式(5.20)和式(5.24)实现,加速度方差自适应由式(5.22)和式(5.15)实现。

### 5.3 快速随机神经联合概率数据 关联自适应滤波算法

利用随机神经网络求得的关联概率  $\beta_i(k)$ ,结合机动目标“当

前”统计模型和均值与方差自适应算法,在此给出快速随机神经联合概率数据关联自适应滤波算法(FSNJPDAAF)基本方程如下。

设密集回波环境下目标 $t$ 的状态方程如式(5.11)所示,量测方程如式(3.2)所示,在第 $l$ 个候选回波 $Z_l(k)$ 来自第 $t$ 个目标的假设下,状态更新方程为

$$\begin{aligned}\hat{\mathbf{X}}_l^t(k/k) &= \hat{\mathbf{X}}^t(k/k-1) + \mathbf{P}^t(k/k-1) \mathbf{H}^T(k) S^t(k)^{-1} \\ &\quad [Z_l(k) - \mathbf{H}(k) \hat{\mathbf{X}}^t(k/k-1)] \quad (l=1,2,\dots,m(k))\end{aligned}\quad (5.25)$$

协方差阵更新方程为

$$\mathbf{P}_l^t(k/k)^{-1} = \mathbf{P}^t(k/k-1)^{-1} - \mathbf{H}^T(k) R(k)^{-1} \mathbf{H}(k) \quad (l=1,2,\dots,m(k)) \quad (5.26)$$

若跟踪门内回波数为零,则视为一特殊事件,其更新方程为

$$\hat{\mathbf{X}}_0^t(k/k) = \hat{\mathbf{X}}^t(k/k-1) \quad (5.27)$$

$$\mathbf{P}_0^t(k/k)^{-1} = \mathbf{P}^t(k/k-1)^{-1} \quad (5.28)$$

整个状态估计是各种假设下估计的加权和,

$$\hat{\mathbf{X}}^t(k/k) = \sum_{l=0}^{m(k)} \beta_l^t(k) \hat{\mathbf{X}}_l^t(k/k) \quad (5.29)$$

式中,权值 $\beta_l^t(k)$ 是第 $l$ 个候选回波来自第 $t$ 个目标的关联概率,由第三章给出的FSNJPDA算法求得。

整个协方差矩阵更新方程为

$$\begin{aligned}\mathbf{P}^t(k/k) &= \sum_{l=0}^{m(k)} \beta_l^t(k) [\mathbf{P}_l^t(k/k) + \hat{\mathbf{X}}_l^t(k/k) \hat{\mathbf{X}}_l^t(k/k)^T] \\ &\quad - \hat{\mathbf{X}}^t(k/k) \hat{\mathbf{X}}^t(k/k)^T\end{aligned}\quad (5.30)$$

整个状态和协方差预测方程为

$$\hat{\mathbf{X}}^t(k+1/k) = \Phi^t(k) \hat{\mathbf{X}}^t(k/k) + U^t(k) \bar{a}^t(k) \quad (5.31)$$

$$\mathbf{P}^t(k+1/k) = \Phi^t(k) \mathbf{P}^t(k/k) \Phi^t(k)^T + Q^t(k) \quad (5.32)$$

新息为

$$S^t(k) = \mathbf{H}(k) \mathbf{P}^t(k/k-1) \mathbf{H}^T(k) + R^t(k) \quad (5.33)$$

目标 $t$ 的加速度均值为

$$\bar{a}^t(k) = \ddot{x}^t(k/k-1) \quad (5.34)$$

加速度方差满足下列关系：

$$(\sigma_a^t)^2 = \begin{cases} \frac{4-\pi}{\pi} [a_{\max} - \bar{a}^t(k)]^2 & (0 \leq \bar{a}^t(k) \leq a_{\max}) \\ \frac{4-\pi}{\pi} [a_{\min} - \bar{a}^t(k)]^2 & (a_{\min} \leq \bar{a}^t(k) < 0) \end{cases} \quad (5.35)$$

$$Q^t(k) = 2\alpha(\sigma_a^t)^2 Q_0^t \quad (5.36)$$

式中,  $Q_0^t$  即式(5.15)中的  $Q_0$ ,  $R^t(k)$  如式(5.18)所示。式(5.25)~(5.36)便构成 FSNJPDAAF 算法。我们称未采用随机神经网络 Boltzmann 机和增益模拟退火方法的相应算法为 NJPDAAF 算法。

#### 5.4 计算机仿真

仿真中主要关心目标分辨、误跟、目标丢失和跟踪精度。机动时考虑多个机动目标编队飞行和轨迹交叉两种典型情况;非机动时,着重考察多个目标的轨迹交叉情况。

参数选取如下:机动频率  $\alpha=0.1$ , 相对误差系数  $\beta=0.01$ , 探测器量测偏差  $\Delta x_t = 30m$ , 采样周期  $T=1s$ , 目标最大加速度  $a_{\max} = 80m/s^2$ , 杂波密度为  $\lambda=0.2km^{-2}$ , 检测概率  $P_D=0.95$ ; 增益模拟退火中的温度参数  $\alpha_i = 0.02 \times 0.995^i$ ,  $i$  为迭代次数; 随机神经网络的最优组合参数为  $\{a \ b \ c \ d \ e\} = \{6.0 \ 45.0 \ 890.0 \ 20.0 \ 5.0\}$ 。仿真时, 取式(3.59)和式(3.60)迭代 200 步的神经元电压  $V_i^t$  为关联概率  $\beta_i^t(k)$ 。跟踪门限  $\gamma$  取为 8, 这相当于接收正确回波的概率为 0.985。

图 5.1~图 5.3 分别给出了 FSNJPDAAF 和 NJPDAAF 两种算法对机动多目标编队飞行的跟踪曲线; 表 5.1~表 5.3 分别给出了两种算法相应的位置、速度和加速度估计的均值误差和均方根误差。不难看出, FSNJPDAAF 比 NJPDAAF 具有更高的目标分辨率和更好的跟踪精度。

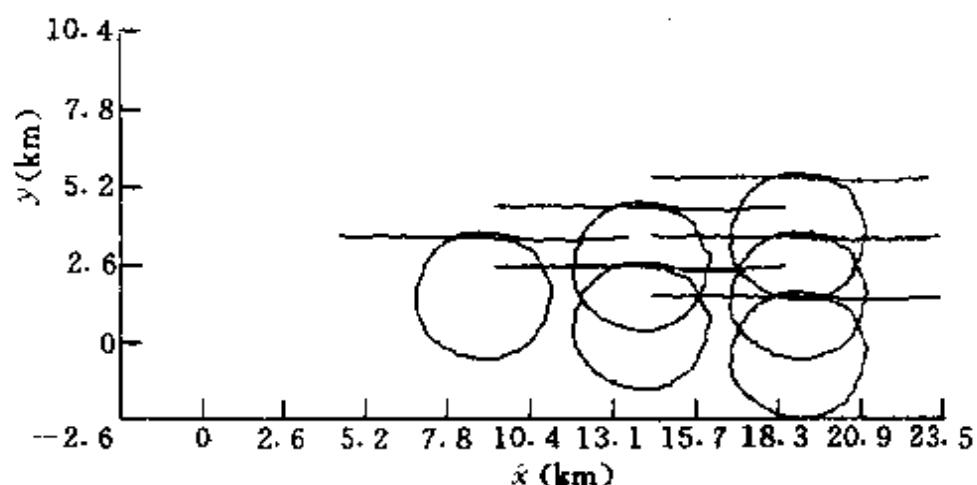


图 5.1 FSNJPDAAF 对 6 个编队飞行机动目标的跟踪曲线

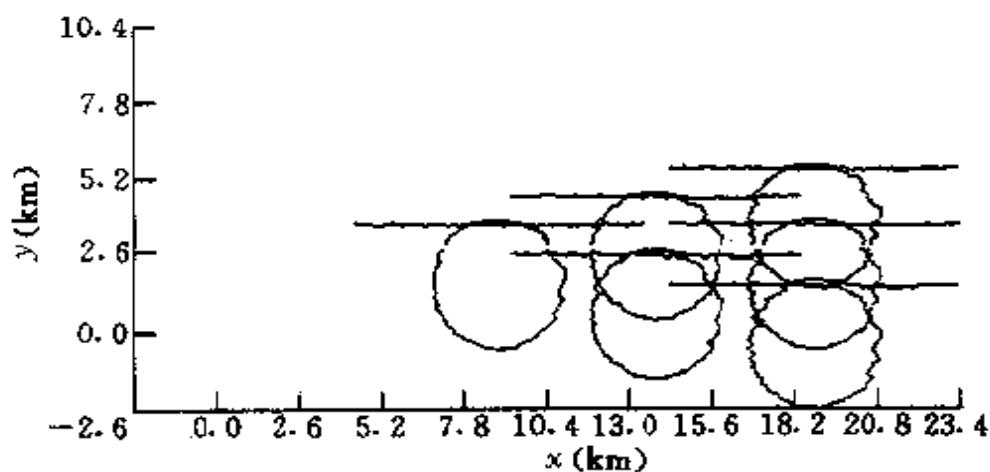


图 5.2 NJPDAAF 对 6 个编队飞行机动目标的跟踪曲线

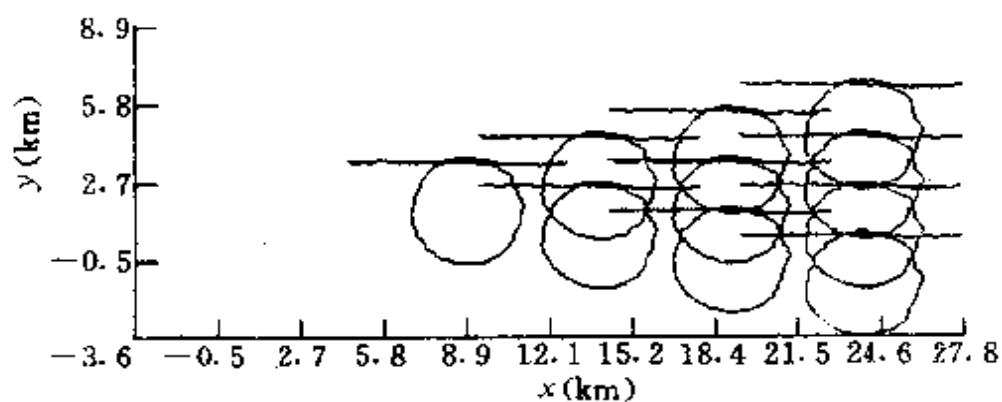


图 5.3 FSNJPDAAF 对 10 个编队飞行机动目标的跟踪曲线

表 5.1 FSNJPDAAF 跟踪 6 个编队飞行机构目标的  
估计均值误差和均方根误差

目标	距离 (km)		速度 (km/s)		加速度 (km/s <sup>2</sup> )	
	均值误差	均方根误差	均值误差	均方根误差	均值误差	均方根误差
1	$6.398125 \times 10^{-2}$	$8.971385 \times 10^{-2}$	$3.658044 \times 10^{-2}$	$7.287051 \times 10^{-2}$	$1.053226 \times 10^{-2}$	$1.823023 \times 10^{-2}$
2	$7.269745 \times 10^{-2}$	$9.327485 \times 10^{-2}$	$5.862968 \times 10^{-2}$	$7.426695 \times 10^{-2}$	$1.106442 \times 10^{-2}$	$1.918568 \times 10^{-2}$
3	$7.096188 \times 10^{-2}$	$9.054147 \times 10^{-2}$	$5.852932 \times 10^{-2}$	$7.406329 \times 10^{-2}$	$1.089284 \times 10^{-2}$	$1.886112 \times 10^{-2}$
4	$7.793088 \times 10^{-2}$	$9.758034 \times 10^{-2}$	$6.068407 \times 10^{-2}$	$7.598868 \times 10^{-2}$	$1.162868 \times 10^{-2}$	$2.035868 \times 10^{-2}$
5	$7.591788 \times 10^{-2}$	$9.531476 \times 10^{-2}$	$6.058107 \times 10^{-2}$	$7.578416 \times 10^{-2}$	$1.147413 \times 10^{-2}$	$2.003308 \times 10^{-2}$
6	$7.362632 \times 10^{-2}$	$9.321115 \times 10^{-2}$	$6.048480 \times 10^{-2}$	$7.560018 \times 10^{-2}$	$1.133146 \times 10^{-2}$	$1.974267 \times 10^{-2}$

表 3.2 NJPDA AF 跟踪 6 个编队飞行机动目标的  
估计均值误差和均方根误差

目标	距离 (km)		速度 (km/s)		加速度 (km/s <sup>2</sup> )	
	均值误差	均方根误差	均值误差	均方根误差	均值误差	均方根误差
1	$6.325675 \times 10^{-2}$	$7.7875855 \times 10^{-2}$	$1.580703 \times 10^{-1}$	$2.024344 \times 10^{-1}$	$1.9865559 \times 10^{-2}$	$2.324871 \times 10^{-2}$
2	$9.533148 \times 10^{-2}$	$11.1441135 \times 10^{-1}$	$2.282017 \times 10^{-1}$	$2.733479 \times 10^{-1}$	$2.145851 \times 10^{-2}$	$2.342711 \times 10^{-2}$
3	$9.047147 \times 10^{-2}$	$1.084214 \times 10^{-1}$	$2.227101 \times 10^{-1}$	$2.617851 \times 10^{-1}$	$2.059179 \times 10^{-2}$	$2.232011 \times 10^{-2}$
4	$1.271118 \times 10^{-1}$	$1.496060 \times 10^{-1}$	$3.233181 \times 10^{-1}$	$3.588282 \times 10^{-1}$	$2.265300 \times 10^{-2}$	$2.411385 \times 10^{-2}$
5	$1.224850 \times 10^{-1}$	$1.441341 \times 10^{-1}$	$3.169245 \times 10^{-1}$	$3.462821 \times 10^{-1}$	$2.195229 \times 10^{-2}$	$2.318487 \times 10^{-2}$
6	$1.193532 \times 10^{-1}$	$1.403437 \times 10^{-1}$	$3.100452 \times 10^{-1}$	$3.314169 \times 10^{-1}$	$2.097823 \times 10^{-2}$	$2.208663 \times 10^{-2}$

表 6.3 FSNJPDAAF 跟踪 10 个编队飞行机动目标的  
估计均值误差和均方根误差差

目标	距离 (km)		速度 (km/s)		加速度 (km/s <sup>2</sup> )	
	均值误差	均方根误差	均值误差	均方根误差	均值误差	均方根误差
1	$7.815714 \times 10^{-2}$	$9.819221 \times 10^{-2}$	$6.168890 \times 10^{-2}$	$7.679824 \times 10^{-2}$	$1.119496 \times 10^{-2}$	$1.952726 \times 10^{-2}$
2	$8.495768 \times 10^{-2}$	$1.054516 \times 10^{-1}$	$6.517680 \times 10^{-2}$	$2.143374 \times 10^{-2}$	$1.215126 \times 10^{-2}$	$2.143374 \times 10^{-2}$
3	$8.211229 \times 10^{-2}$	$1.01817 \times 10^{-1}$	$6.505027 \times 10^{-2}$	$7.92899 \times 10^{-2}$	$1.185302 \times 10^{-2}$	$2.081034 \times 10^{-2}$
4	$9.252311 \times 10^{-2}$	$1.140051 \times 10^{-1}$	$6.862359 \times 10^{-2}$	$8.290156 \times 10^{-2}$	$1.318722 \times 10^{-2}$	$2.387946 \times 10^{-2}$
5	$9.632388 \times 10^{-2}$	$1.109637 \times 10^{-1}$	$6.852796 \times 10^{-2}$	$8.265158 \times 10^{-2}$	$1.292564 \times 10^{-2}$	$2.326714 \times 10^{-2}$
6	$8.781125 \times 10^{-2}$	$1.081490 \times 10^{-1}$	$6.842061 \times 10^{-2}$	$8.241895 \times 10^{-2}$	$1.269858 \times 10^{-2}$	$2.275001 \times 10^{-2}$
7	$1.003769 \times 10^{-1}$	$1.234893 \times 10^{-1}$	$7.200875 \times 10^{-2}$	$8.702763 \times 10^{-2}$	$1.426610 \times 10^{-2}$	$2.671665 \times 10^{-2}$
8	$9.854141 \times 10^{-2}$	$1.207605 \times 10^{-1}$	$7.195292 \times 10^{-2}$	$8.685654 \times 10^{-2}$	$1.403099 \times 10^{-2}$	$2.612265 \times 10^{-2}$
9	$9.651164 \times 10^{-2}$	$1.182375 \times 10^{-1}$	$7.188268 \times 10^{-2}$	$8.670268 \times 10^{-2}$	$1.382360 \times 10^{-2}$	$2.561403 \times 10^{-2}$
10	$9.444886 \times 10^{-2}$	$1.159632 \times 10^{-1}$	$7.179575 \times 10^{-2}$	$8.655559 \times 10^{-2}$	$1.364573 \times 10^{-2}$	$2.519588 \times 10^{-2}$

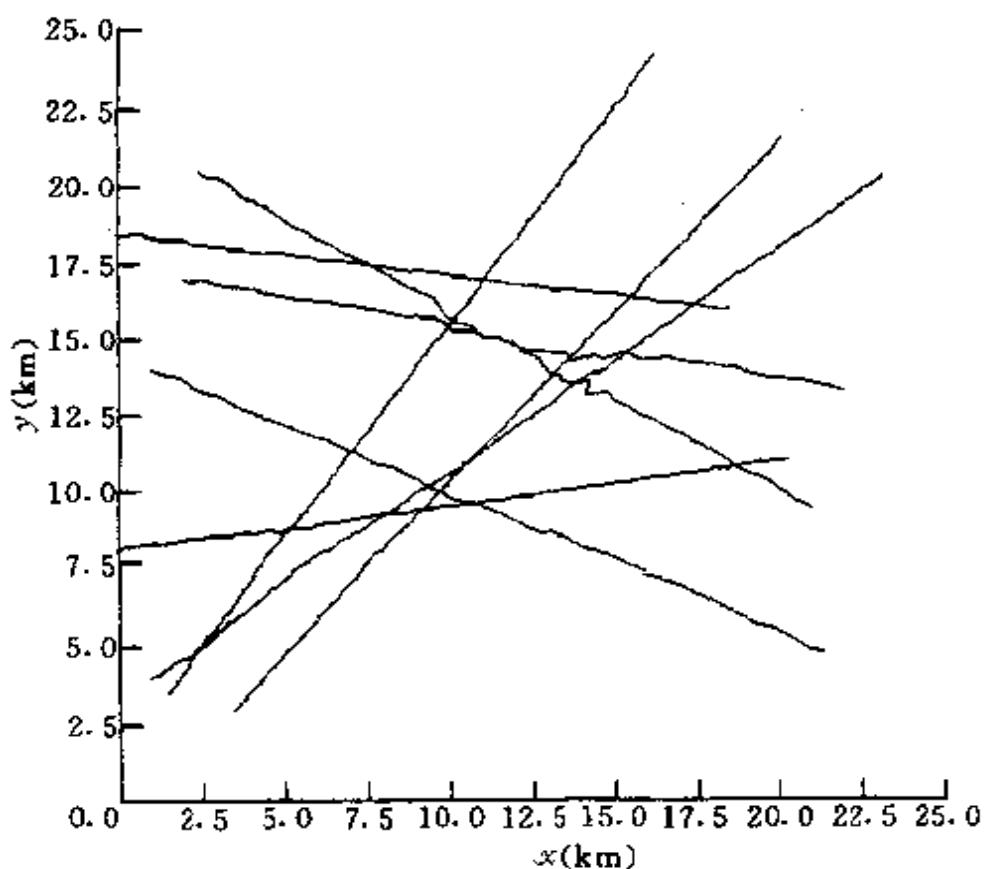


图 5.4 FSNJPDAAF 对 8 个交叉飞行非机动目标的跟踪曲线

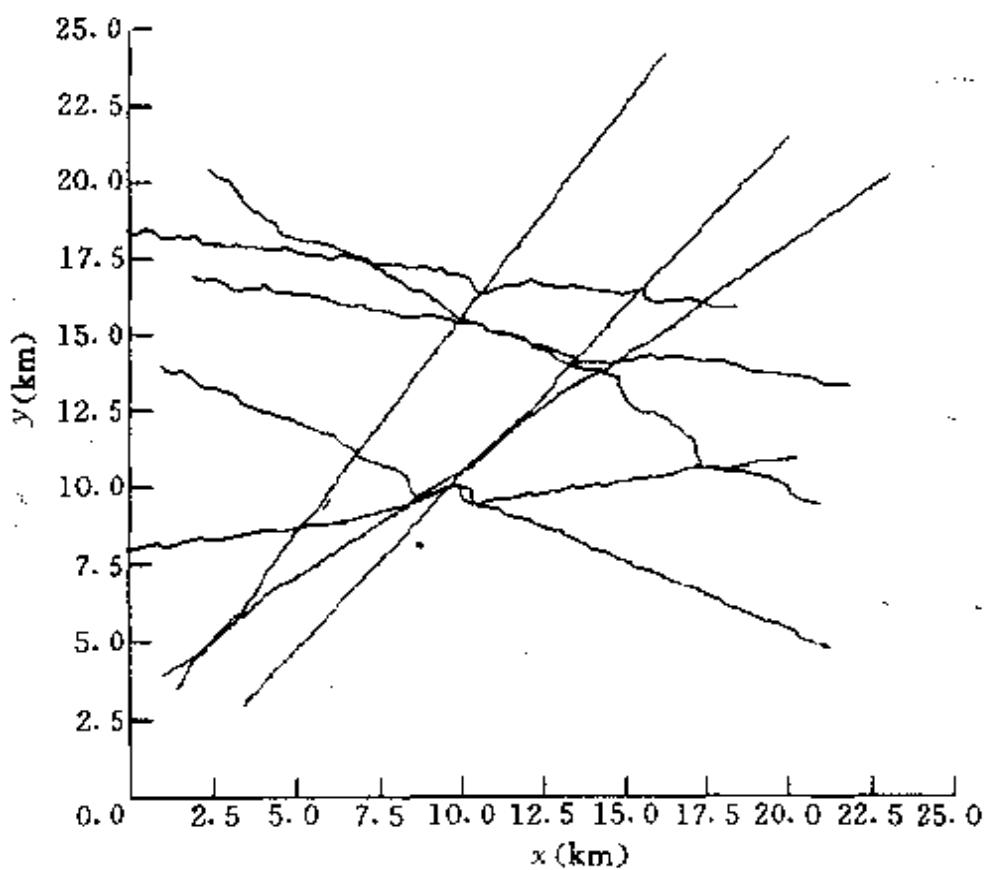


图 5.5 NJPDAAF 对 8 个交叉飞行非机动目标的跟踪曲线

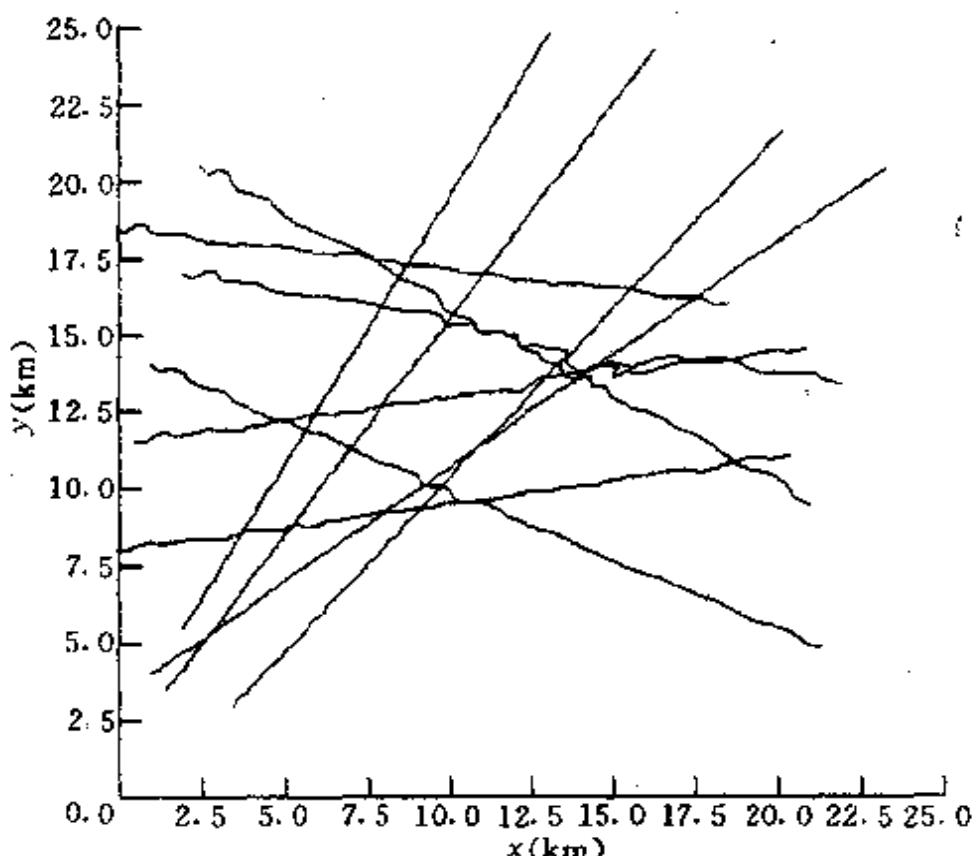


图 5.6 FSNJPDAAF 对 10 个交叉飞行非机动目标的跟踪曲线

图 5.4~图 5.6 分别给出了两种算法对非机动轨迹交叉目标的跟踪曲线;表 5.4~表 5.6 分别给出了两种算法相应的位置和速度估计的均值误差和均方根误差。同样不难看出,FSNJPDAAF 对轨迹交叉的目标分辨率和跟踪精度比 NJPDAAF 都高得多。

仿真还发现,由于 FSNJPDAAF 算法采用了随机神经网络 Boltzmann 机和增益模拟退火技术,它具有相当快的收敛速度,而且跟踪稳定性好。

表 5.4 FSNJPDAAF 跟踪 8 个交叉飞行机动目标的  
估计均值误差和均方根误差

目标	距离(km)		速度(km/s)	
	均值误差	均方根误差	均值误差	均方根误差
1	$3.765430 \times 10^{-3}$	$5.629599 \times 10^{-2}$	$1.735000 \times 10^{-2}$	$2.350885 \times 10^{-2}$
2	$1.304803 \times 10^{-1}$	$2.084043 \times 10^{-1}$	$1.296507 \times 10^{-2}$	$1.696507 \times 10^{-2}$
3	$2.755112 \times 10^{-2}$	$3.836030 \times 10^{-2}$	$6.575066 \times 10^{-2}$	$1.090908 \times 10^{-2}$
4	$1.268576 \times 10^{-1}$	$2.109594 \times 10^{-2}$	$9.338787 \times 10^{-3}$	$9.373761 \times 10^{-3}$
5	$7.196745 \times 10^{-2}$	$1.166629 \times 10^{-1}$	$9.361260 \times 10^{-3}$	$1.502863 \times 10^{-2}$
6	$2.237999 \times 10^{-2}$	$2.926739 \times 10^{-2}$	$4.706818 \times 10^{-3}$	$8.117738 \times 10^{-3}$
7	$7.141963 \times 10^{-2}$	$1.160753 \times 10^{-1}$	$4.323494 \times 10^{-3}$	$6.521754 \times 10^{-3}$
8	$3.005034 \times 10^{-2}$	$4.607544 \times 10^{-2}$	$3.312767 \times 10^{-3}$	$4.872479 \times 10^{-3}$

表 5.5 NJPDAAF 跟踪 8 个交叉飞行非机动目标的  
估计均值误差和均方根误差

目标	距离(km)		速度(km/s)	
	均值误差	均方根误差	均值误差	均方根误差
1	$1.133584 \times 10^{-1}$	$1.373432 \times 10^{-1}$	$3.062744 \times 10^{-2}$	$3.183834 \times 10^{-2}$
2	$2.705278 \times 10^{-1}$	$3.761431 \times 10^{-2}$	$1.279040 \times 10^{-2}$	$1.704875 \times 10^{-2}$
3	$1.564100 \times 10^{-1}$	$2.429660 \times 10^{-1}$	$1.495427 \times 10^{-2}$	$1.982194 \times 10^{-2}$
4	$2.427947 \times 10^{-1}$	$3.167325 \times 10^{-1}$	$1.013167 \times 10^{-2}$	$1.235330 \times 10^{-2}$
5	$2.007338 \times 10^{-1}$	$2.980717 \times 10^{-1}$	$2.093872 \times 10^{-2}$	$2.318839 \times 10^{-2}$
6	$1.451600 \times 10^{-1}$	$1.991960 \times 10^{-1}$	$8.893675 \times 10^{-3}$	$1.183542 \times 10^{-2}$
7	$3.011992 \times 10^{-1}$	$3.772486 \times 10^{-1}$	$1.543435 \times 10^{-2}$	$1.937408 \times 10^{-2}$
8	$1.479064 \times 10^{-1}$	$2.067456 \times 10^{-1}$	$1.485983 \times 10^{-2}$	$1.795647 \times 10^{-2}$

表 5.6 FSNJPDAAF 跟踪 10 个交叉飞行非机动目标的  
估计均值误差和均方根误差

目标	距离(km)		速度(km/s)	
	均值误差	均方根误差	均值误差	均方根误差
1	$3.762248 \times 10^{-2}$	$4.815927 \times 10^{-2}$	$1.386386 \times 10^{-2}$	$2.219121 \times 10^{-2}$
2	$3.827975 \times 10^{-2}$	$4.955060 \times 10^{-2}$	$1.267612 \times 10^{-2}$	$2.062167 \times 10^{-2}$
3	$6.317732 \times 10^{-2}$	$8.874944 \times 10^{-2}$	$1.239146 \times 10^{-2}$	$1.866096 \times 10^{-2}$
4	$2.330996 \times 10^{-1}$	$3.818414 \times 10^{-2}$	$1.099269 \times 10^{-2}$	$1.596088 \times 10^{-2}$
5	$9.435448 \times 10^{-2}$	$1.306520 \times 10^{-1}$	$1.574626 \times 10^{-2}$	$2.439373 \times 10^{-2}$
6	$5.435839 \times 10^{-2}$	$7.170668 \times 10^{-2}$	$7.900470 \times 10^{-3}$	$1.258183 \times 10^{-2}$
7	$1.009239 \times 10^{-1}$	$1.317682 \times 10^{-1}$	$7.865381 \times 10^{-3}$	$1.132561 \times 10^{-2}$
8	$5.826130 \times 10^{-2}$	$7.456251 \times 10^{-2}$	$6.453692 \times 10^{-3}$	$8.410813 \times 10^{-3}$
9	$5.300538 \times 10^{-2}$	$7.347570 \times 10^{-2}$	$1.796752 \times 10^{-2}$	$2.574050 \times 10^{-2}$
10	$1.073320 \times 10^{-1}$	$1.788339 \times 10^{-1}$	$1.336970 \times 10^{-2}$	$2.113625 \times 10^{-2}$

## 5.5 结论

仿真结果表明,本章提出的快速随机神经联合概率数据关联滤波算法(FSNJPDAAF)对机动和非机动多目标均具有很高的收敛速度和跟踪精度,对杂波环境和目标的不确定性具有良好的鲁棒性能。由于神经网络具有高度并行处理的特点,使得这种方法在不损失 JPDA 优良性能的前提下,克服了传统跟踪方法难以克服的计算组合爆炸现象,大大降低了计算量,为实际应用开辟了一条新途径。

当对目标速度和加速度跟踪精度要求较高时,可采用第三章提出的基于神经网络的机动目标信息融合与并行自适应跟踪算法

(NIFPAT)代替机动目标“当前”统计模型和均值与方差自适应算法。

当目标数和杂波密度大幅度增高,譬如跟踪 600 个目标时,为进一步降低神经网络的维数和计算量,可采用第三章所述的将跟踪空间  $V_T$  合理论分为  $L$  个子空间,使得在每个子空间  $V_L$  中能用 FSNJPDAAF,然后再将各子空间的结果综合起来的方法。或者对相互关联的目标聚类应用 FSNJPDAF,而对互不相关目标应用 PDAF。

## 第六章 基于随机神经网络和 Bayes 后验 推理的机动多目标跟踪起始与终结

### 6.1 引言

密集回波环境下的多目标跟踪起始与终结问题,是机动多目标跟踪的重要组成部分,也是该领域的一大难题,迫切需要进一步的研究。

在密集回波环境下,来自探测器的量测数据一般是目标回波和杂波的集合。当某些回波不与已建立轨迹的目标相关联时,跟踪空间内就有可能出现新的目标。如何建立新的目标档案,消除多余目标档案,即解决跟踪起始与终结问题,便成为本章的研究重点。

就目前的跟踪起始与终结技术而言,主要的方法不外乎两大类:一类是面向量测的批处理方法;另一类是面向目标的递推方法。前一类方法能同时处理假定轨迹初始化和轨迹确定与终结问题,不足的是在密集回波环境下计算量很大,实现较困难;后一类方法的优点,是将假定轨迹初始化和轨迹确定与终结问题分开来处理,并以递推形式出现,易于工程实现,缺点是该方法属于“最近邻”相关方法,仅适合于稀疏回波环境。在密集回波环境下辨别目标与虚警的能力较差,并且两类方法仅限于独立非机动多目标跟踪情况。

本章分别研究假定轨迹初始化和轨迹确定与终结问题,首先提出主跟踪子空间和边缘跟踪子空间的概念,然后修正 Bayes 轨迹确定与终结方法(BTCT),并将其与上一章提出的快速随机神经联合概率数据关联自适应滤波有机地结合起来,提出一种基于随机神经网络并适合密集回波环境的机动多目标“全邻”Bayes 跟

踪起始与终结算法(SNABTIT)。仿真结果表明,本章提出的算法,不仅克服了一类“全邻”概率数据关联滤波方法缺乏跟踪起始与终结机理的缺陷,而且进一步发展和完善了机动多目标跟踪理论。

## 6.2 主跟踪子空间与边缘跟踪子空间

设跟踪空间的大小为  $V_T$ ,各目标关联区域或跟踪门的大小为  $V_j$  ( $j=1, 2, \dots, n$ ),其中  $n$  为跟踪空间内当前被跟踪的目标个数。定义主跟踪子空间  $V_{T1}$  为所有  $V_j$  的并集,边缘跟踪子空间  $V_{T2}$  为  $V_T$  与  $V_{T1}$  的差集。即

$$V_{T1} \triangleq \bigcup_{j=1}^n V_j \quad (6.1)$$

$$V_{T2} \triangleq V_T - V_{T1} = V_T - \bigcup_{j=1}^n V_j \quad (6.2)$$

由于目标运动时,其空间位置和机动水平是时变的,很显然,  $V_{T1}$  和  $V_{T2}$  的大小和空间位置也是时变的。在  $V_{T1}$  内,目标已被稳定地跟踪,信噪比足够高,以致于新目标出现的可能性很小;另一方面,若目标逃离  $V_{T1}$ ,就存在着目标在  $V_T$  内消失的可能性。因此,关于  $V_{T1}$  仅需考虑跟踪终结问题。 $V_{T2}$  是一个应特别重视的区域,位于该区域内的目标信噪比很小,虚警率相当高;同时,新目标也有可能从跟踪空间外进入该区域。因此,任何位于  $V_{T2}$  内而原先又没有目标档案的回波,都应作为潜在的新目标加以考虑,即解决跟踪起始问题。

## 6.3 Bayes 轨迹确定与终结方法(BTCT)

正如第一章所指出的那样,BTCT 方法的核心是计算量测集合  $D_k$  条件下轨迹为真的后验概率

$$P(T/D_k) = \frac{L_k P(T/D_{k-1})}{L_k P(T/D_{k-1}) + 1 - P(T/D_{k-1})} \quad (6.3)$$

式中数据似然比  $L_k$  的计算方法为

$$L_k = \begin{cases} \frac{P_D \cdot V_G \cdot \exp(-g/2)}{P_F (2\pi)^{M/2} \sqrt{|\mathbf{S}(k)|}} & (\text{不漏检}) \\ \frac{1-P_D}{1-P_F} & (\text{漏检}) \end{cases} \quad (6.4)$$

$$P_F = \beta_{FT} \cdot V_G \quad (6.5)$$

式中,  $P_D$  为在检测概率;  $V_G$  为目标关联区域体积;  $g$  为目标准回波的“最近邻”残差范数;  $|\mathbf{S}(k)|$  为残差协方差矩阵的行列式;  $M$  为量测维数;  $P_F$  和  $\beta_{FT}$  分别为虚警概率和虚警密度。

真实目标的初始概率为

$$P_0 = \frac{\beta_{NT}}{\beta_{NT} + \beta_{FT}} \quad (6.6)$$

式中,  $\beta_{NT}$  为真实目标密度。

设轨迹确定门限为  $P_{TC}$ , 轨迹终结门限为  $P_{TR}$ , 当且仅当

$$P(T/D_k) \geq P_{TC} \quad (6.7)$$

时, 轨迹为真; 当且仅当

$$P(T/D_k) \leq P_{TR} \quad (6.8)$$

时, 轨迹为假, 即轨迹终结。

式(6.3)~(6.8)构成 BTCT 方法。遗憾的是, 该方法属“最近邻”相关法, 在密集回波环境下决策功能失效<sup>[37,49]</sup>。

## 6.4 基于随机神经网络的“全邻”Bayes 跟踪起始与终结算法(SNABTIT)

落在  $V_{T_2}$  内而不在  $V_{T_1}$  中的由“粗门”预选的量测集合, 称为假定轨迹。在跟踪维持之前, 必须对假定轨迹进行初始化和轨迹确定处理, 进而获得新目标数目。这里在  $V_{T_2}$  中研究跟踪起始问题, 在  $V_{T_1}$  中研究跟踪终结问题。

### 6.4.1 假定轨迹初始化及其对滤波性能的影响

这里采用外推方法确定假定轨迹的初始状态。外推法的基本

思想是：要获得假定轨迹的距离、速度和加速度的初始信息，需要经过两次外推，一次外推获得速度信息，下一次外推获得加速度信息。

在一维量测情况下，设  $y(0)$  和  $y(1)$  分别为第一次扫描和第二次扫描所获得的位置量测，则假定轨迹的初始状态和初始协方差矩阵各元素分别取为<sup>[17]</sup>

$$\left. \begin{array}{l} \hat{x}_0(0) = y(1) \\ \dot{\hat{x}}_0(0) = [y(1) - y(0)]/T \\ \ddot{\hat{x}}_0(0) = 0 \end{array} \right\} \quad (6.9)$$

$$\left. \begin{array}{l} p_{11}(0) = \sigma_R^2 \\ p_{12}(0) = p_{21}(0) = \sigma_R^2/T \\ p_{13}(0) = p_{31}(0) = 0 \\ p_{22}(0) = 2\sigma_R^2/T^2 + \frac{\sigma_a^2}{\alpha^2 T^2} (2 - \alpha^2 T^2 + \frac{2\alpha^2 T^2}{3} - 2e^{-\alpha T} - 2\alpha T e^{-\alpha T}) \\ p_{23}(0) = p_{32}(0) = \frac{\sigma_a^2}{\alpha^2 T} (e^{-\alpha T} + \alpha T - 1) \\ p_{33}(0) = \sigma_a^2 \end{array} \right\} \quad (6.10)$$

式中， $\sigma_R^2$  为位置量测噪声方差； $\sigma_a^2$  为随机加速度方差； $\alpha$  为机动频率； $T$  为采样周期。

当采用“当前”统计模型时，不难验证系统是一致完全可控和一致完全可观测的，最佳滤波满足稳定性条件。因此，当量测时间足够长时，滤波将逐渐地不依赖于初始状态的选择，而且有界的输入必将产生有界的输出。

#### 6.4.2 SNABTIT 算法

为了解决密集回波环境下的机动多目标跟踪起始与终结问题，关键是修正 BTCT 方法，并用基于随机神经网络 Boltzmann 机的 FSNJPDAAF 算法中的“全邻”等效残差代替修正的 BTCT 方法中的“最近邻”残差，产生出新的数据似然比计算方法。

给定量测集合  $D_i$  条件下轨迹为真的后验概率仍为

$$P(T/D_k) = \frac{L_k P(T/D_{k-1})}{L_k P(T/D_{k-1}) + 1 - P(T/D_{k-1})} \quad (6.11)$$

改进后的数据似然比为

$$L_k = \begin{cases} \frac{P_p \cdot V_j \cdot \exp[-g_j^*(k)/2]}{(2\pi)^{M/2} \sqrt{|S_j^*(k)|}} & (\text{不漏检}) \\ \frac{1 - P_p}{1 - P_s} & (\text{漏检}) \end{cases} \quad (6.12)$$

式中,  $V_j$  为目标  $j$  的关联区域体积;  $g_j^*(k)$  和  $S_j^*(k)$  分别为 FSNJP-DAAF 算法中的“全邻”等效回波残差范数和其协方差矩阵。

由于杂波在  $V_T$  内服从均匀分布, 重新定义  $P_F$  如下:

$$P_F = \frac{V_j}{V_T} \quad (6.13)$$

真实目标的初始概率为

$$P_0 = \frac{\beta_{\text{NT}}}{\beta_{\text{NT}} + \beta_{\text{TT}}} \quad (6.14)$$

当且仅当

$$P(T/D_k) \geq P_{TC} \quad (6.15)$$

时, 接受跟踪起始假设。一旦进入跟踪维持,  $P(T/D_k)$  保持为 1.0,

当且仅当

$$P(T/D_k) \leq P_{TR} \quad (6.16)$$

时, 接受跟踪终结假设。

式(6.11)~(6.16)便构成 SNABTIT 算法, 其显著特点是逐次批处理假定轨迹关联区域内的量测子集, 而不需要对每一回波进行处理, 避免了“最近邻”相关方法的不足, 大大降低了计算量, 同时也使“全邻”相关方法建立起了跟踪起始与终结功能。

## 6.5 计算机仿真

考虑多个机动目标的相对运动, 以两目标编队飞行(FF)为例。跟踪门限取为 8, 机动发生时刻  $t = 30s$ , 机动消失时刻为  $t_2 =$

101s,  $P_0=0.01$ (相当于在  $V_T$  内有两个目标回波和 198 个杂波)。图 6.1~图 6.3 分别给出了目标和虚警跟踪起始以及目标跟踪终结时  $P(T/D_k)$  的变化曲线;图 6.4~图 6.6 分别给出了  $P(T/D_k)$  随参数  $P_D$ 、 $P_0$  和目标间距  $\Delta y$  的变化曲线。可以看出,在跟踪起始阶段,  $P(T/D_k)$  很快上升到 1.0; 在跟踪维持阶段,  $P(T/D_k)$  保持为 1.0; 在跟踪终结阶段,  $P(T/D_k)$  又迅速衰减至 0.0; 在  $P_0=0.01$  即高密集回波环境下, 跟踪起始和终结时间分别为 9s 和 5s; 从而表明, 本章提出的 SNABTIT 算法不仅能可靠地建立新目标档案, 消除多余目标档案, 而且能有效地监视跟踪维持过程。

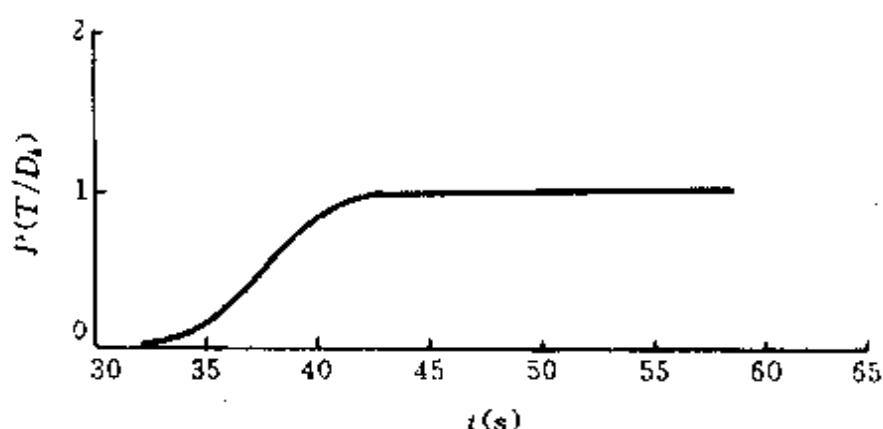


图 6.1 目标跟踪起始时  $P(T/D_k)$  变化曲线

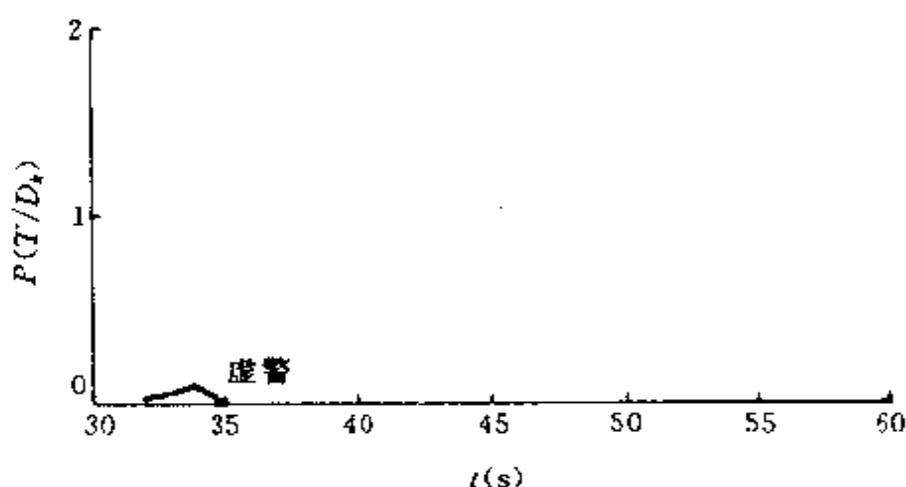


图 6.2 虚警跟踪起始时  $P(T/D_k)$  变化曲线

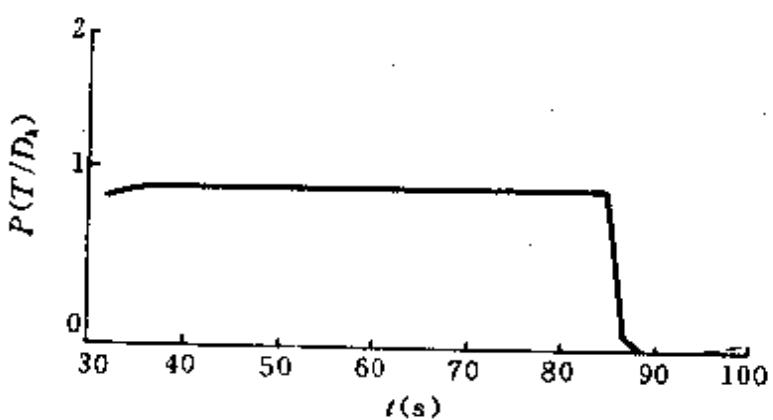


图 6.3 目标跟踪终结时  $P(T/D_k)$  变化曲线

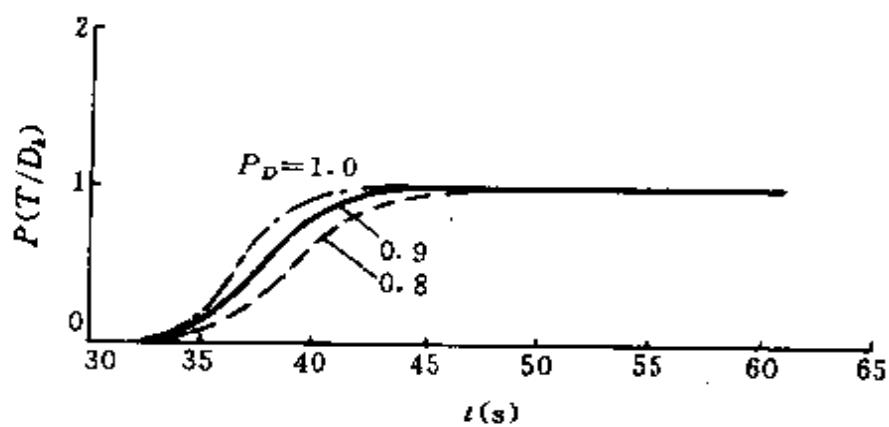


图 6.4  $P_D$  变化时  $P(T/D_k)$  变化曲线

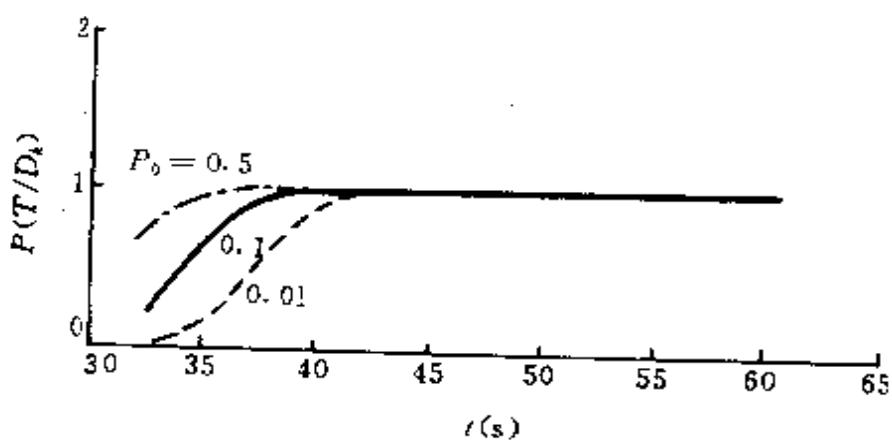


图 6.5  $P_0$  变化时  $P(T/D_k)$  变化曲线

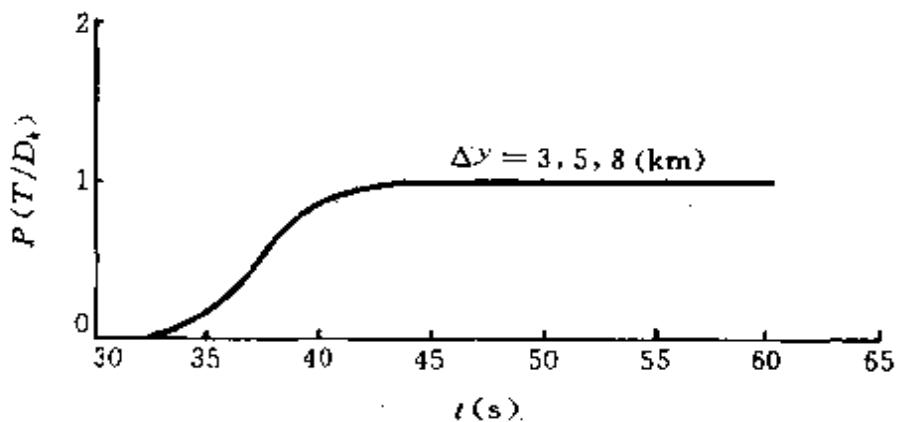


图 6.6  $\Delta y$  变化时  $P(T/D_k)$  变化曲线

## 6.6 结论

本章研究表明,修正的 BTCT 方法与基于随机神经网络的 FSNJPDAAF 算法相结合而产生的 SNABTIT 算法,有效地解决了密集回波环境下的机动多目标跟踪起始与终结问题,进一步发展了机动多目标跟踪理论。

SNABTIT 算法的特点为:

- (1) 用“全邻”相关代替“最近邻”相关方法,克服了后者的固有弊端,而且辨别目标和虚警的能力很强;
- (2) 由于引入随机神经网络数据关联方法,特别适用于密集回波环境和机动多目标跟踪场合;
- (3) 克服了“全邻”相关方法缺乏跟踪起始与终结的缺陷,建立了相应的决策功能;
- (4) 综合了面向目标和面向量测两类方法的优点,并且算法呈递推形式,计算量小,有效可靠,易于工程实现。

## 第二篇 应用

---

### 第七章 三维空间中的机动目标建模 与自适应跟踪

#### 7.1 引言

本章研究三维空间中的机动目标建模与跟踪问题。文中基于相控阵雷达,采用混合状态变量,推导了一种新的在余弦坐标系下状态方程形式上解耦的线性目标运动模型,并根据对加速度的不同描述建立了相应的四类目标模型。在此基础上导出了 11 种跟踪滤波算法,给出了性能评价方法,并通过 Monte Carlo 仿真对滤波性能进行了比较分析。结果表明,采用这种新的状态方程形式上解耦的线性目标运动模型,不仅能大大减小计算量,而且可以避免非线性模型小扰动线性化带来的滤波精度下降;在所有滤波算法中,以 NIFPAT 算法的综合跟踪性能为最好。

#### 7.2 目标运动模型

在余弦坐标系下,相控阵雷达的目标量测为两个方向余弦  $\Lambda_x, \Lambda_y$ , 以及径距  $R$ 。以  $\Lambda_x$  通道为例,设  $\Lambda_x = \frac{x}{R}$ , 则

$$\dot{A}_r = \frac{1}{R} \dot{x} - \frac{R}{R} A_r \quad (7.1)$$

为了使状态方程三通道形式上解耦，并使模型线性化，选混合状态变量为  $X = [A_x \ \dot{x} \ \ddot{x}]^T$ ，根据对  $\dot{x}$  的不同描述可建立如下四类模型。

### 7.2.1 “当前”统计模型(CSM)

设  $\ddot{x} = -\alpha \dot{x} + \alpha \bar{a}_x + \omega(t)$ ，有

$$\begin{bmatrix} \dot{A}_x \\ \dot{x} \\ \ddot{x} \end{bmatrix} = \begin{bmatrix} -\frac{R}{R} & \frac{1}{R} & 0 \\ 0 & 0 & 1 \\ 0 & 0 & -\alpha \end{bmatrix} \begin{bmatrix} A_x \\ \dot{x} \\ \ddot{x} \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \\ \alpha \end{bmatrix} \bar{a}_x + \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \omega_{A_x}(t) \quad (7.2)$$

同理有

$$\begin{bmatrix} \dot{A}_y \\ \dot{y} \\ \ddot{y} \end{bmatrix} = \begin{bmatrix} -\frac{R}{R} & \frac{1}{R} & 0 \\ 0 & 0 & 1 \\ 0 & 0 & -\alpha \end{bmatrix} \begin{bmatrix} A_y \\ \dot{y} \\ \ddot{y} \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \\ \alpha \end{bmatrix} \bar{a}_y + \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \omega_{A_y}(t) \quad (7.3)$$

$$\begin{bmatrix} \dot{R} \\ \ddot{R} \end{bmatrix} = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & -\alpha \end{bmatrix} \begin{bmatrix} R \\ \dot{R} \\ \ddot{R} \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \\ \alpha \end{bmatrix} \bar{a}_R + \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \omega_R(t) \quad (7.4)$$

式中， $\alpha$  为机动频率； $\bar{a}_x, \bar{a}_y$  和  $\bar{a}_R$  分别为  $X, Y$  和  $R$  方向的加速度均值； $\omega_{A_x}(t), \omega_{A_y}(t)$  和  $\omega_R(t)$  分别是均值为零、方差为  $q_{A_x}, q_{A_y}$  和  $q_R$  的白噪声。

相应的离散状态方程和量测方程分别为

$$X(k+1) = \Phi(k+1, k)X(k) + U(k)\bar{a}(k) + W(k) \quad (7.5)$$

$$Z(k) = H(k)X(k) + V(k) \quad (7.6)$$

式中， $V(k)$  为量测噪声，其方差为  $R(k)$ ；对  $A_x, A_y$  通道，有

$$\Phi_A(k+1, k) = \begin{bmatrix} e^{-\frac{\dot{R}}{R}T} & \frac{1}{\dot{R}}(1 - e^{-\frac{\dot{R}}{R}T}) & \frac{1}{\dot{R}\alpha} - \frac{1}{\dot{R}\alpha - R\alpha^2}e^{-\alpha T} - \frac{R}{\dot{R}^2 - R\dot{R}\alpha}e^{-\frac{\dot{R}}{R}T} \\ 0 & 1 & \frac{1}{\alpha}(1 - e^{-\alpha T}) \\ 0 & 0 & e^{-\alpha T} \end{bmatrix}$$

$$U_A(k) = \begin{bmatrix} \frac{T}{\dot{R}} - \frac{1}{\dot{R}\alpha - R\alpha^2} - \frac{R^2\alpha}{\dot{R}^3 - \dot{R}^2R\alpha} + \frac{1}{\dot{R}\alpha - R\alpha^2}e^{-\alpha T} + \frac{R^2\alpha}{\dot{R}^3 - \dot{R}^2R\alpha}e^{-\frac{\dot{R}}{R}T} \\ T - \frac{1 - e^{-\alpha T}}{\alpha} \\ 1 - e^{-\alpha T} \end{bmatrix}$$

$$Q_A(k) = [\mathbf{W}(k)\mathbf{W}^T(k)] = 2\alpha\sigma_a^2 \begin{bmatrix} q_{11}/R^2 & q_{12}/R & q_{13}/R \\ q_{12}/R & q_{22} & q_{23} \\ q_{13}/R & q_{23} & q_{33} \end{bmatrix}$$

式中,  $q_{ij}$  与直角坐标系下 Singer 模型状态噪声方差阵  $\mathbf{Q}(k)$  中的相同项相同<sup>[13]</sup>;  $\sigma_a^2$  为加速度方差。

对  $R$  通道, 有

$$\Phi_R(k+1, k) = \begin{bmatrix} 1 & T & \frac{1}{\alpha^2}(-1 + \alpha T + e^{-\alpha T}) \\ 0 & 1 & \frac{1}{\alpha}(1 - e^{-\alpha T}) \\ 0 & 0 & e^{-\alpha T} \end{bmatrix}$$

$$U_R(k) = \begin{bmatrix} \frac{1}{\alpha}(-T + \frac{\alpha T^2}{2} + \frac{1 - e^{-\alpha T}}{\alpha}) \\ T - \frac{1 - e^{-\alpha T}}{\alpha} \\ 1 - e^{-\alpha T} \end{bmatrix}$$

$$Q_R(k) = 2\alpha\sigma_a^2 \begin{bmatrix} q_{11} & q_{12} & q_{13} \\ q_{12} & q_{22} & q_{23} \\ q_{13} & q_{23} & q_{33} \end{bmatrix}$$

### 7.2.2 Singer 模型(SM)

在式(7.2)~(7.4)中令  $\bar{a}_x = \bar{a}_y = \bar{a}_R = 0$ , 即式(7.5)中的  $\bar{a}(k)$

$\dot{a}(k) = 0$  时, 相应的模型为 Singer 模型。

### 7.2.3 常加速模型(CAM)

在“当前”统计模型中, 令  $\dot{a}(k) = 0$  和  $\alpha \rightarrow 0$ , 可得常加速模型为

$$\mathbf{X}(k+1) = \Phi(k+1, k)\mathbf{X}(k) + \mathbf{G}(k)\omega(k) \quad (7.7)$$

$$\mathbf{Z}(k) = \mathbf{H}(k)\mathbf{X}(k) + \mathbf{V}(k) \quad (7.8)$$

式中,  $\omega(k)$  是均值为零、方差为  $q$  的白噪声。

对  $A_x$  和  $A_y$  通道, 有

$$\Phi_A(k+1, k) = \begin{bmatrix} e^{-\frac{\dot{R}}{R}T} & \frac{1}{\dot{R}}(1 - e^{-\frac{\dot{R}}{R}T}) & -\frac{R}{\dot{R}^2} + \frac{1}{\dot{R}}T + \frac{R}{\dot{R}^2}e^{-\frac{\dot{R}}{R}T} \\ 0 & 1 & T \\ 0 & 0 & 1 \end{bmatrix}$$

$$\mathbf{G}_A(k) = \begin{bmatrix} -\frac{R}{\dot{R}^2}T + \frac{1}{2\dot{R}}T^2 + \frac{R^2}{\dot{R}^3} - \frac{R^2}{\dot{R}^3}e^{-\frac{\dot{R}}{R}T} \\ \frac{1}{2}T^2 \\ T \end{bmatrix}$$

对  $R$  通道, 有

$$\Phi_R(k+1, k) = \begin{bmatrix} 1 & T & T^2/2 \\ 0 & 1 & T \\ 0 & 0 & 1 \end{bmatrix} \quad \mathbf{G}_R(k) = \begin{bmatrix} T^3/6 \\ T^2/2 \\ T \end{bmatrix}$$

### 7.2.4 常速模型(CVM)

此时, 状态向量  $X$  中不含加速度分量, 目标模型形式上与式(7.7)和式(7.8)相同。

对  $A_x$  和  $A_y$  通道, 有

$$\Phi_A(k+1, k) = \begin{bmatrix} e^{-\frac{\dot{R}}{R}T} & \frac{1}{\dot{R}}(1 - e^{-\frac{\dot{R}}{R}T}) \\ 0 & 1 \end{bmatrix}$$

$$\mathbf{G}_A(k) = \begin{bmatrix} 1 & T - \frac{R}{\dot{R}} + \frac{R}{\dot{R}^2} e^{-\frac{\dot{R}T}{2}} \\ \dot{R} & \dot{R}^2 \\ 0 & T \end{bmatrix}$$

对  $R$  通道, 有

$$\Phi_R(k+1, k) = \begin{bmatrix} 1 & T \\ 0 & 1 \end{bmatrix} \quad G_R(k) = \begin{bmatrix} T^2/2 \\ T \end{bmatrix}$$

在上述模型中, 当仅有径距和方向余弦量测量时,  $\mathbf{H}_R = \mathbf{H}_A = [1 \ 0 \ 0]$ 。

### 7.3 目标量测噪声

下面给出精确跟踪过程中近似的目标量测噪声<sup>[90]</sup>。

#### 7.3.1 热噪声标准差

$$\sigma_b = \frac{\theta_0}{\sqrt{2} K_m \sqrt{(S/N)}} = \frac{\theta_0}{\sqrt{2} K_m R_0^2 \sqrt{(S/N)_0}} \quad (7.9)$$

式中,  $S/N$  为信噪比;  $K_m = 1.89$ ; 波束宽度  $\theta_0 = 1^\circ \sim 2^\circ$ 。

如以法向跟踪距离  $R_0 = 105\text{km}$ , 目标反射面积  $\sigma = 2\text{m}^2$ ,  $S/N = 13\text{dB}$ ,  $\theta_0 = 2^\circ$ , 算得  $10\lg S/N = 13$ ,  $(S/N)_0 = 19.953$ , 故有

$$\sigma_b = \frac{2 \times 0.01745}{1.89 \sqrt{2}} \frac{1}{105^2 \sqrt{19.953}} = R^2 = 2.659 \times 10^{-7} R^2 (\text{rad}) \quad (7.10)$$

式中  $R$  以 km 计。

#### 7.3.2 距离噪声标准差

$$\sigma_R = \frac{c\tau}{2 \sqrt{2}} \frac{1}{\sqrt{S/N}} = \frac{c\tau}{2 \sqrt{2} R_0^2 \sqrt{(S/N)_0}} \quad (7.11)$$

式中,  $\tau$  为脉宽;  $c$  为光速。如取  $\tau = 0.2\mu\text{s} = 2 \times 10^{-9}\text{s}$ , 其余参数与式(7.10)中参数相同, 有

$$\sigma_R = \frac{3 \times 10^8 \times 2 \times 10^{-7}}{2 \times 1.414} \frac{1}{105^2 \sqrt{19.953}} R^2 = 4.3082 \times 10^{-4} R^2 \quad (7.12)$$

式中,  $R$  以 km 计。

### 7.3.3 角闪烁标准差

$$\sigma_{\text{角闪}} = \frac{0.35L}{R} \quad (7.13)$$

式中  $L$  为飞机翼展。如取  $L=16m$ , 有

$$\sigma_{\text{角闪}}^2 = \frac{5.6}{10^3 R} (\text{rad}) \quad (7.14)$$

式中,  $R$  以 km 计。

### 7.3.4 合成的方向余弦量测噪声标准差

近似认为

$$\sigma_{A_x} = \sigma_{A_y} \approx \sigma_{\text{热}} + \sigma_{\text{角闪}} + \sigma_c \quad (7.15)$$

式中,  $\sigma_c$  为余弦通道固定量测噪声标准差分量。

## 7.4 跟踪滤波算法

### 7.4.1 $\alpha-\beta$ 和 $\alpha-\beta-\gamma$ 滤波

在仅有位置量测情况下, 基于各种模型的滤波方程为

$$\hat{X}(k/k) = \hat{X}(k/k-1) + K[Z(k) - H(k)\hat{X}(k/k-1)] \quad (7.16)$$

$$\hat{X}(k/k-1) = \Phi(k, k-1)\hat{X}(k-1/k-1) \quad (7.17)$$

或  $\hat{X}(k/k-1) = \Phi(k, k-1)\hat{X}(k-1/k-1) + U(k)\hat{x}(k/k-1) \quad (7.18)$

其中式(7.18)为在“当前”统计模型下的状态预测公式。

对基于 CVM 的  $\alpha-\beta$  滤波,  $K = [\alpha \ \beta]^T$ ,  $\alpha = \sqrt{2h}$ ,  $\beta = Th$ ,  $h = \sqrt{q/r}$ ,  $q$  和  $r$  分别为状态噪声方差和量测噪声方差,  $T$  为采样周期。

对基于 CAM、SM 和 CSM 的  $\alpha-\beta-\gamma$  滤波,  $K = [\alpha \ \beta \ \gamma]^T$ ,  $\alpha = 2\sqrt[3]{h}$ ,  $\beta = 2T\sqrt[3]{h^2}$ ,  $\gamma = T^3h$ 。

对 SM, 有  $q = \frac{\alpha_{\max}^2}{3}(1 + 4P_{\max} - P_0)$ , 其中  $\alpha_{\max}$  为最大机动加速度,  $P_{\max}$  为其发生概率,  $P_0$  为非机动发生概率。

对 CSM, 有  $q = \frac{2\alpha(4-\pi)}{\pi}[\alpha_{\max} - \hat{x}(k/k-1)]^2$ , 其中  $\alpha$  为机动频率。

#### 7.4.2 卡尔曼滤波(KF)

滤波方程为

$$\hat{X}(k/k) = \hat{X}(k/k-1) + K(k)[Z(k) - H(k)\hat{X}(k/k-1)] \quad (7.19)$$

$$\hat{X}(k/k-1) = \Phi(k, k-1)\hat{X}(k-1/k-1) \quad (7.20)$$

或  $\hat{X}(k/k-1) = \Phi(k, k-1)\hat{X}(k-1/k-1) + U(k)\hat{x}(k/k-1) \quad (7.21)$

$$K(k) = P(k/k-1)H^T(k)[H(k)P(k/k-1)H^T(k) + R(k)]^{-1} \quad (7.22)$$

$$P(k/k-1) = \Phi(k, k-1)P(k-1/k-1)\Phi^T(k, k-1) + Q(k-1) \quad (7.23)$$

$$P(k/k) = [I - K(k)H(k)]P(k/k-1) \quad (7.24)$$

其中式(7.21)为在“当前”统计模型下的状态预测公式。

当采用 CVM、CAM 和 SM 时可得相应的状态方程三通道形式上解耦的 KF 算法;当采用 CSM 时可得到状态方程三通道形式上解耦的自适应 KF 算法。

#### 7.4.3 交互式多模型滤波(IMMF)

由全概率公式, 状态向量  $X$  在量测集合  $Z^k$  下的条件概率密度函数在模型样本空间上的展开式为

$$P(X(k)|Z^k) = \sum_{j=1}^J P(X(k)|M_j(k), Z^k)P(M_j(k)|Z^k)$$

$$= \sum_{j=1}^r P(X(k) | M_j(k), Z(k), Z^{k-1}) \mu_j(k) \quad (7.25)$$

即有  $r$  个滤波器并行工作,  $M_j(k)$  表示模型  $j$  在零到  $k$  时刻有效。设  $M_j(k)$  是一个取值在  $\{1, 2, \dots, r\}$  中的有限状态马尔可夫链, 且模型间以概率矩阵  $\{P_{ij}\}$  转移, 则可导出具有马尔可夫开关系数的IMMF 算法<sup>[34~36]</sup>。具体计算过程如下。

第一步, 确定转移概率矩阵  $P$  和初始权概率  $\mu_j(0)$ :

当  $r=2$  时, 可取

$$P = [P_{ij}] = \begin{bmatrix} 0.97 & 0.03 \\ 0.03 & 0.97 \end{bmatrix} \quad \mu_j(0) = 0.5, j=1, 2$$

第二步, 计算各滤波器的交互输入值:

$$c_j = \sum_{i=1}^r P_{ij} \mu_i(k-1) \quad (7.26)$$

$$\hat{X}_i(k-1/k-1) = \sum_{j=1}^r P_{ij} \mu_j(k-1) \hat{X}_j(k-1/k-1) / c_i \quad (7.27)$$

$$\begin{aligned} P_i(k-1/k-1) = & \sum_{j=1}^r P_{ij} \mu_j(k-1) \{ P_j(k-1/k-1) \\ & + [\hat{X}_j(k-1/k-1) - \hat{X}_i(k-1/k-1)] \\ & \cdot [\hat{X}_j(k-1/k-1) - \hat{X}_i(k-1/k-1)]^T \} / c_i \end{aligned} \quad (7.28)$$

第三步, 计算加权状态估计:

$$\hat{X}(k/k) = \sum_{j=1}^r \hat{X}_j(k/k) \mu_j(k) \quad (7.29)$$

$$\begin{aligned} P(k/k) = & \sum_{j=1}^r \{ P_j(k/k) + [\hat{X}_j(k/k) - \hat{X}(k/k)] \\ & \cdot [\hat{X}_j(k/k) - \hat{X}(k/k)]^T \} \mu_j(k) \end{aligned} \quad (9.30)$$

第四步, 更新权概率:

$$\mu_j(k) = \frac{1}{c} c_j |S_j(k)|^{-\frac{1}{2}} \exp \left\{ -\frac{1}{2} v_j^T(k) S_j^{-1}(k) v_j(k) \right\} \quad (7.31)$$

式中,  $c$  为归一化常数;  $v_j(k)$  和  $S_j(k)$  分别为模型  $j$  的残差及其协方差。

第五步,返回到第二步,进行下一循环的递推计算。

在 CVM 和 CSM 交互作用下,当采用  $\alpha-\beta$  滤波和自适应  $\alpha-\beta-\gamma$  滤波时,可得到状态方程三通道形式上解耦的交互式自适应  $\alpha-\beta-\gamma$  滤波算法;当采用 KF 时,可得到状态方程三通道形式上解耦的交互式自适应滤波算法。

#### 7.4.4 NIFPAT 算法

当将第二章提出的 NIFPAT 算法应用于三维空间中的机动目标跟踪时,可给位置和余弦通道分别设计一个神经网络和一对滤波器,其中两个余弦通道( $\Lambda_x$  和  $\Lambda_y$ )的神经网络和滤波器结构完全相同。由于各通道状态维数均为 3,神经网络的输入层、隐层和输出层节点可分别选为 3,7 和 1。特征向量的选取,神经网络的离线训练方法以及各通道的信息融合与滤波方程,参见第二章中的相应内容。

根据各模型和算法的不同组合,可得如下 11 种跟踪滤波算法:

1. CVM; $\alpha-\beta$  滤波
2. CVM;KF
3. CAM; $\alpha-\beta-\gamma$  滤波
4. CAM;KF
5. SM; $\alpha-\beta-\gamma$  滤波
6. SM;KF(SMKF)
7. CSM;自适应  $\alpha-\beta-\gamma$  滤波
8. CSM;自适应 KF(CSMAF)
9. CVM+CSM;交互式多模型自适应  $\alpha-\beta-\gamma$  滤波
10. CVM+CSM;交互式多模型自适应 KF(IMMAF)
11. CSM+CSM;NIFPAT 算法

## 7.5 性能评价方法

设第*i*次仿真的目标距离真值和滤波值分别为 $x_{k,i}$ 和 $\hat{x}_{k/k,i}$ ,  
 $N_p$ 为单次仿真实现的拍数, $N$ 为Monte Carlo 仿真次数。

### 1. 估计均值误差和估计方差

设 $\Delta x_{k,i} = x_{k,i} - \hat{x}_{k/k,i}$ , 则估计均值误差和估计方差分别为

$$\bar{\Delta x}_k = \frac{1}{N} \sum_{i=1}^N \Delta x_{k,i} \quad (7.32)$$

$$\sigma_{\Delta x_k}^2 = \frac{1}{N-1} \sum_{i=1}^N (\Delta x_{k,i} - \bar{\Delta x}_k)^2 \quad (7.33)$$

### 2. 平均估计均值误差和平均估计方差

$$\bar{\Delta x} = \frac{1}{N_p} \sum_{k=1}^{N_p} \bar{\Delta x}_k \quad (7.34)$$

$$\bar{\sigma}_{\Delta x}^2 = \frac{1}{N_p} \sum_{k=1}^{N_p} \sigma_{\Delta x_k}^2 \quad (7.35)$$

### 3. 量测均值误差、方差与平均方差

设第*i*次仿真的距离量测误差为 $\Delta z_{k,i}$ , 则量测均值误差、方差和平均方差分别为

$$\bar{\Delta z}_k = \frac{1}{N} \sum_{i=1}^N \Delta z_{k,i} \quad (7.36)$$

$$\sigma_{\Delta z_k}^2 = \frac{1}{N-1} \sum_{i=1}^N (\Delta z_{k,i} - \bar{\Delta z}_k)^2 \quad (7.37)$$

$$\bar{\sigma}_{\Delta z}^2 = \frac{1}{N_p} \sum_{k=1}^{N_p} \sigma_{\Delta z_k}^2 \quad (7.38)$$

### 4. 误差压缩比

定义误差压缩比为

$$S_N \triangleq \sqrt{\frac{\sigma_{\Delta z}^2}{\sigma_{\Delta x}^2}} \quad (7.39)$$

从 $S_N$ 可计算出滤波相对于量测的平均性能改善程度。

## 7.6 Monte Carlo 仿真结果

仿真中,参数选为  $a_{R_{\max}} = 100 \text{m/s}^2$ ,  $a_{A_x^{\max}} = a_{A_y^{\max}} = 100 \text{rad/s}^2$ ,  $P_0 = 0.9$ ,  $P_{\max} = 0.1$ , 采样周期  $T = 0.5 \text{s}$ , 余弦通道固定量测标准差分量  $\sigma_r = 0$ , Monte Carlo 仿真次数为 30。目标在高度  $H = 5 \text{km}$  的水平面内作 S 形机动,速度  $v = 300 \text{m/s}$ ,过载  $n_z = 3g$ ,偏航角为  $49^\circ$ 。表 7.1 为四种典型滤波算法跟踪 S 形机动目标的误差压缩比  $S_N$ 。此外,当目标作常速、常加速、变加速、 $\frac{1}{2}$  转圈机动和 S 形机动等典型运动时,通过对 11 种算法的大量仿真分析比较和性能评估,可见:

(1) CVM 能对匀速直线运动目标保持良好跟踪,CAM 能对匀加速直线运动目标保持良好跟踪,SM 对机动目标的跟踪性能不如 CSM;

(2) 对机动目标,NIFPAT 算法跟踪性能最好,CSMAF 次之,IMMAF 算法再次之,SMKF 较差;

(3) 对非机动目标,基于 CVM 的滤波算法跟踪性能最好,NIFPAT 较好,IMMAF 算法次之,CSMAF 再次之;

(4) 在所有的滤波算法中,以 NIFPAT 算法的综合跟踪性能为最好。

表 7.1 四种典型滤波算法跟踪 S 形  
机动目标的误差压缩比

$S_N$ 算法	$R$	$A_x$	$A_y$
SMKF	0.4679	0.4322	0.4894
IMMAF	0.4210	0.4155	0.4532
CSMAF	0.3990	0.3722	0.3629
NIFPAT	0.3471	0.3238	0.3157

## 7.7 结论

本章研究表明,在三维空间中选取混合状态变量,所建立的状态方程形式上解耦的线性目标运动模型,不仅可以避免非线性模型线性化产生的滤波精度下降,而且相对于全耦合运动模型,可以大大减小滤波计算量。

在所给出的 11 种滤波算法中,由于 NIFFPAT 算法引入了基于神经网络的全状态信息融合和双滤波器并行结构,其综合跟踪性能最好,但这是以较高的离线计算代价换来的。

## 第八章 三维空间中的机动多目标 神经自适应跟踪

### 8.1 引言

本章研究三维余弦空间中的机动多目标跟踪问题。文中首先给出余弦坐标系下的目标运动描述,接着讨论三维空间中的跟踪门设计问题,最后将第一篇提出的基于随机神经网络的 FSNJP-DAAF 和 SNABTIT 算法推广到三维空间的机动多目标跟踪问题中。仿真中主要关心目标分辨、误跟、丢失和跟踪精度。大量的仿真结果再次证明了这种新的随机神经网络跟踪方法的有效性和可靠性。

### 8.2 三维空间中的目标运动描述

根据上一章导出的余弦坐标系下状态方程三通道形式上解耦的线性目标运动模型,并引入“当前”统计模型概念,设密集回波环境下目标  $t$  的离散状态方程和量测方程分别为

$$X_j^t(k+1) = \Phi_j(k+1, k)X_j^t(k) + U_j(k)\bar{a}_j^t(k) + W_j^t(k) \quad (t=1, 2, \dots, T; \quad j=R, A_x, A_y) \quad (8.1)$$

$$Z(k) = \begin{cases} \mathbf{H}_j(k)X_j^t(k) + V_j(k) & (\text{量测来自目标}) \\ u(k) & (\text{量测来自杂波}) \end{cases} \quad (8.2)$$

式中,  $j$  为通道号: 对  $R$  通道,  $X_R^t(k) = [R \ R \ \dot{R}]^T$ ; 对  $A_x$  通道,  $X_{A_x}^t(k) = [A_x \ \dot{x} \ \ddot{x}]^T$ ; 对  $A_y$  通道,  $X_{A_y}^t(k) = [A_y \ \dot{y} \ \ddot{y}]^T$ ; 当仅有位置和余弦量测时,  $\mathbf{H}_R = \mathbf{H}_{A_x} = \mathbf{H}_{A_y} = [1 \ 0 \ 0]^T$ ;  $W_j^t(k)$  是均值为零、协方差矩阵为  $Q_j(k)$  的高斯噪声序列;  $V_j(k)$  是与  $W_j^t(k)$  相互独立, 均值为

零、标准差为  $\sigma_j$  的量测噪声；对各通道， $\Phi_j(k+1, k)$ ,  $U_j(k)$ ,  $Q_j(k)$  的表示式与式(7.5)中的相应量相同， $\sigma_j$  的表示式与 7.3 节中的相应量相同； $u(k)$  为在跟踪门内均匀分布的杂波。

### 8.3 三维空间中的跟踪门设计

设状态方程三通道耦合情况下，九维状态的滤波残差向量及其协方差矩阵分别为  $d_M(k)$  和  $S_M(k)$ ，则在状态方程三通道形式上解耦情况下，有

$$\mathbf{d}(k) = [d_R(k) \ d_{A_x}(k) \ d_{A_y}(k)]^T \quad (8.3)$$

$$S(k) = \text{diag}[S_R(k) \ S_{A_x}(k) \ S_{A_y}(k)] \quad (8.4)$$

从而综合残差范数为

$$\begin{aligned} g(k) &= \mathbf{d}_M^T(k) S_M^{-1}(k) \mathbf{d}_M(k) \\ &= d_R^T(k) S_R^{-1}(k) d_R(k) + d_{A_x}^T(k) S_{A_x}^{-1} d_{A_x}(k) \\ &\quad + d_{A_y}^T(k) S_{A_y}^{-1}(k) d_{A_y}(k) \\ &= g_R(k) + g_{A_x}(k) + g_{A_y}(k) \end{aligned}$$

式中， $g_R(k)$ ,  $g_{A_x}(k)$  和  $g_{A_y}(k)$  分别为  $R$ ,  $A_x$  和  $A_y$  通道的残差范数。

当回波  $Z(k)$  满足

$$g(k) \leq \gamma \quad (8.5)$$

时，称为候选回波，此椭球跟踪门限为

$$\gamma = \sqrt{q_M(1 - P_G)} \quad (8.6)$$

式中， $P_G$  为跟踪门接收正确回波的概率； $q_M(1 - P_G)$  是自由度为  $M$  的  $\chi^2_M$  分布的第  $(1 - P_G)$  个四分点。

椭球跟踪门体积为

$$\begin{aligned} V'(k) &= \frac{\pi^{M/2}}{\Gamma(\frac{M}{2} + 1)} \gamma^M |S_M(k)| \\ &= \frac{\pi^{M/2}}{\Gamma(\frac{M}{2} + 1)} \gamma^M |S_R(k)| |S_{A_x}(k)| |S_{A_y}(k)| \quad (8.7) \end{aligned}$$

这里  $M=9$ 。

### 8.4 三维空间中的机动多目标快速随机神经自适应跟踪

本节同时考虑三维空间中的机动多目标数据关联、跟踪维持、跟踪起始与终结问题。快速随机神经自适应跟踪算法的基本方程如下。

在第  $l$  个候选回波来自第  $t$  个目标的假设下, 目标  $t$  的状态估计为

$$\begin{aligned}\hat{\mathbf{X}}_{jt}^t(k/k) = & \hat{\mathbf{X}}_j^t(k/k-1) + \mathbf{P}_j^t(k/k-1) \mathbf{H}_j^T(k) S_j^t(k)^{-1} \\ & \cdot [Z_t(k) - \mathbf{H}_j(k) \hat{\mathbf{X}}_j^t(k/k-1)] \\ (l = 1, 2, \dots, m(k))\end{aligned}\quad (8.8)$$

协方差修正为

$$\mathbf{P}_{jt}^t(k/k)^{-1} = \mathbf{P}_j^t(k/k-1)^{-1} + \mathbf{H}_j^T(k) S_j^t(k)^{-1} \mathbf{H}_j(k) \quad (8.9)$$

$t=0$  相应于聚矩阵  $\Omega(k)$  中第  $t$  列向量“1”范数  $c_j=0$ , 此时

$$\hat{\mathbf{X}}_{j0}^t(k/k) = \hat{\mathbf{X}}_j^t(k/k-1) \quad (c_j=0) \quad (8.10)$$

$$\mathbf{P}_{j0}^t(k/k)^{-1} = \mathbf{P}_j^t(k/k-1)^{-1} \quad (c_j=0) \quad (8.11)$$

在各种假设条件下, 目标  $t$  的状态估计为

$$\hat{\mathbf{X}}_j^t(k/k) = \sum_{l=0}^{m(k)} \beta_{jl}^t(k) \hat{\mathbf{X}}_{jl}^t(k/k) \quad (8.12)$$

式中,  $\beta_{jl}^t(k)$  为第  $l$  个候选回波来自第  $t$  个目标的后验概率, 由第三章提出的基于 Boltzmann 随机神经网络的 FSNJPDA 算法求出。协方差修正为

$$\begin{aligned}\mathbf{P}_j^t(k/k) = & \sum_{l=0}^{m(k)} \beta_{jl}^t(k) [\mathbf{P}_{jl}^t(k/k) + \hat{\mathbf{X}}_{jl}^t(k/k) \hat{\mathbf{X}}_{jl}^t(k/k)^T] \\ & - \hat{\mathbf{X}}_j^t(k/k) \hat{\mathbf{X}}_j^t(k/k)^T\end{aligned}\quad (8.13)$$

状态和协方差预测为

$$\begin{aligned}\hat{\mathbf{X}}_j^t(k+1/k) = & \Phi_j(k+1, k) \hat{\mathbf{X}}_j^t(k/k) + \mathbf{U}_j(k) \bar{\mathbf{a}}_j^t(k) \\ \mathbf{P}_j^t(k+1/k) = & \Phi_j(k+1, k) \mathbf{P}_j^t(k/k) \Phi_j(k+1, k)^T + \mathbf{Q}_j^t(k) \mathbf{Q}_j^t(k)^T\end{aligned}\quad (8.14)$$

$$\tilde{a}_j^t(k) = \tilde{a}_j^t(k+1/k) \quad (8.15)$$

基于 SNABTIT 算法的跟踪起始与终结逻辑为

$$P(T/D_k) = \frac{L_k P(T/D_{k-1})}{L_k P(T/D_{k-1}) + 1 - P(T/D_{k-1})} \\ \begin{cases} \geq P_{rc} & \text{(跟踪起始)} \\ \leq P_{rt} & \text{(跟踪终结)} \end{cases} \quad (8.16)$$

式中各符号意义见第六章。

## 8.5 计算机仿真

仿真中主要考察目标分辨、误跟、丢失和跟踪精度。假设多个目标在空中一定高度作轨迹交叉和编队飞行，其中 10 个目标分两组作 S 形机动编队飞行，6 个目标作轨迹同时交叉于一点的运动。

参数选取如下：飞行高度  $H = 5\text{km}$ ；目标速度  $v = 600\text{m/s}$ ；机动频率  $\alpha = 0.1$ ；采样周期  $T = 1\text{s}$ ；检测概率  $P_D = 0.99$ ； $a_{R\max} = 50\text{m/s}^2$ ； $a_{A_x\max} = a_{A_y\max} = 50\text{rad/s}^2$ ；跟踪门限  $\gamma = 8$ ；跟踪门接收正确回波的概率  $P_c = 0.985$ ；杂波密度  $\lambda = 0.05\text{km}^{-3}$ ，这相当于在每个跟踪门落入 1~2 个杂波；跟踪起始概率门限  $P_{rc} = 0.8$ ；跟踪终结概率门限  $P_{rt} = 0.4$ ；随机神经网络各参数选取与第三章中相同。网络演化迭代 200 步时可认为获得关联概率的满意解。

图 8.1~图 8.4 分别给出了 6 个目标同时相交于一点时跟踪曲线在 XY 水平面上的投影和  $R$ 、 $A_x$  及  $A_y$  的估计随时间的变化曲线；表 8.1 和表 8.2 分别给出了某一时刻目标的关联概率和估计的均值误差 MS、均方根误差 REMS 和误差压缩比  $S_N$ 。图 8.5~图 8.8 分别给出了 10 个目标作 S 形机动编队飞行时的跟踪曲线，表 8.3 给出相应的估计均值误差 MS、均方根误差 REMS 和误差压缩比  $S_N$ 。图 8.9 给出了整个跟踪过程中某目标轨迹概率的变化曲线，其中跟踪起始时间为 5s，终结时间为 3s。由图表不难看出，本章给出的三维空间中基于随机神经网络的快速自适应跟踪方法不仅具有很高的目标分辨力，而且关联效果好，跟踪精度高，跟踪

起始与终结决策可靠迅速,没有发生误跟和丢失目标的现象。

尽管这里只对 10 个目标的跟踪问题进行了仿真,但本方法可适用于密集回波环境下任意有限多个机动目标的数据关联与跟踪问题。

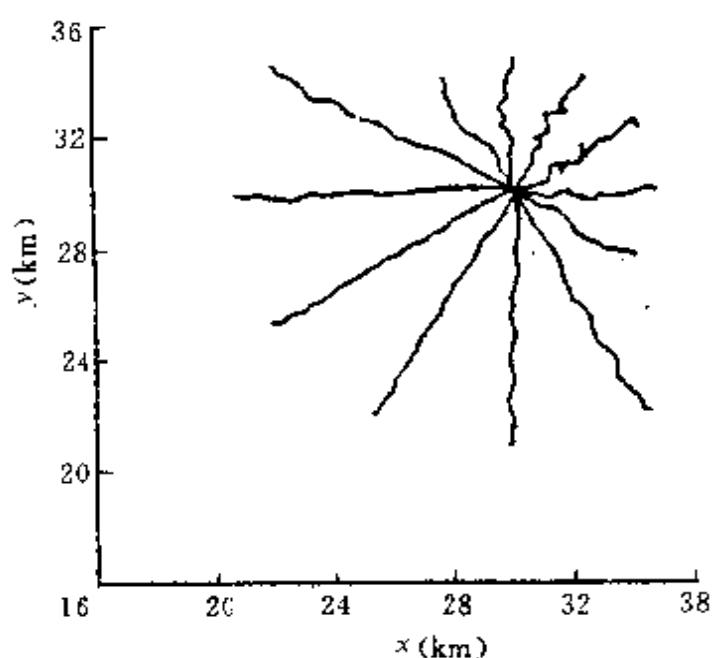


图 8.1 6 个目标同时相交于一点时的跟踪曲线

表 8.1 6 个目标同时相交于一点的关联概率

回波 目标 \ 目标	0	1	2	3	4	5	6	7	8	9
1	0.01	0.89	0.00	0.00	0.00	0.00	0.08	0.02	0.00	0.00
2	0.01	0.00	0.90	0.00	0.00	0.07				0.01
3	0.01	0.01	0.00	0.96	0.01	0.00	0.00	0.00		0.01
4	0.02	0.00	0.01	0.01	0.88	0.00	0.00	0.00		0.08
5	0.00	0.00	0.00	0.00	0.00	1.00				0.00
6	0.00	0.00	0.00	0.00	0.00	0.00	0.93	0.07	0.00	0.00

注:空格表示目标与回波不相关。

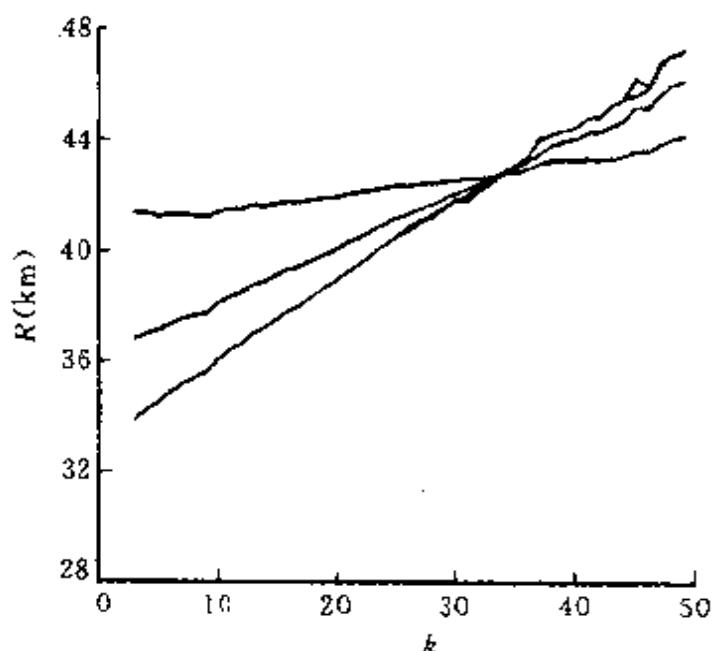


图 8.2 6 个目标同时相交于一点时的  $R$  估计曲线

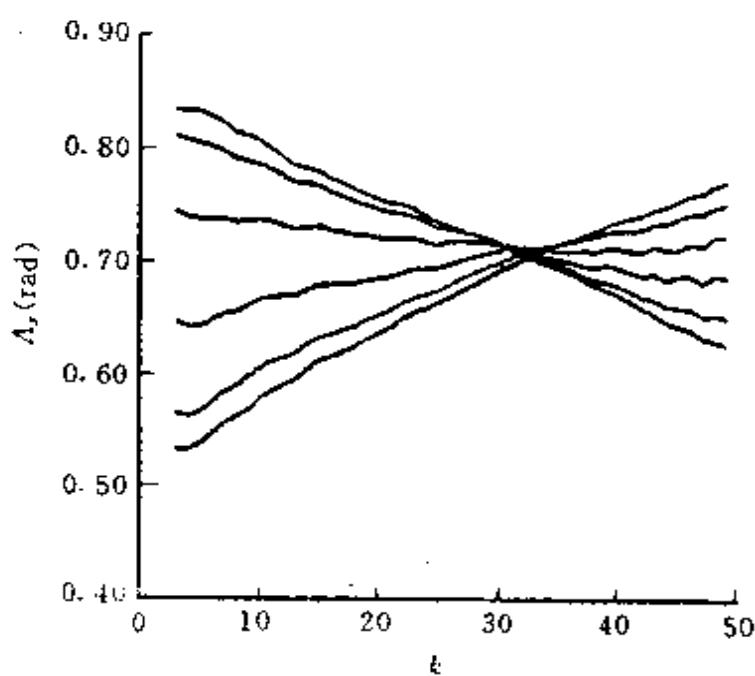


图 8.3 6 个目标同时相交于一点时的  $A_x$  估计曲线

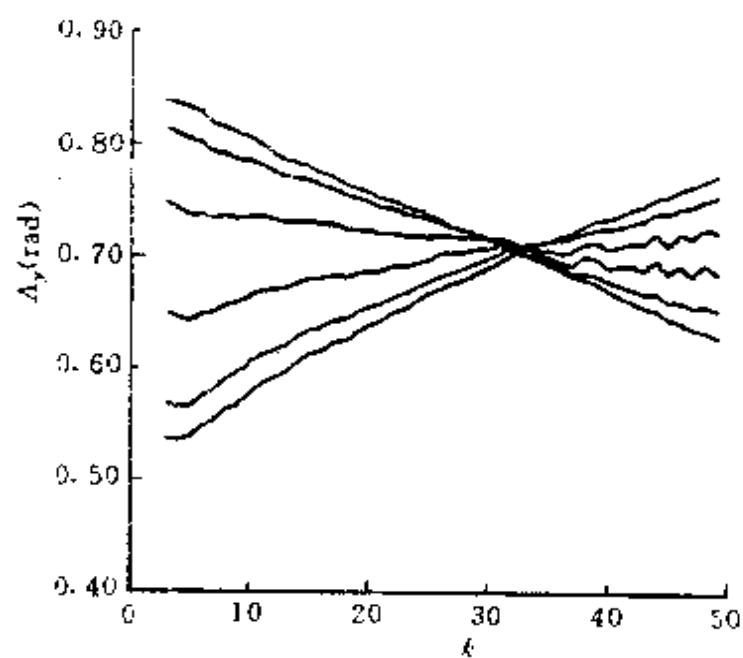


图 8.4 6 个目标同时相交于一点时的  $\Delta_y$  估计曲线

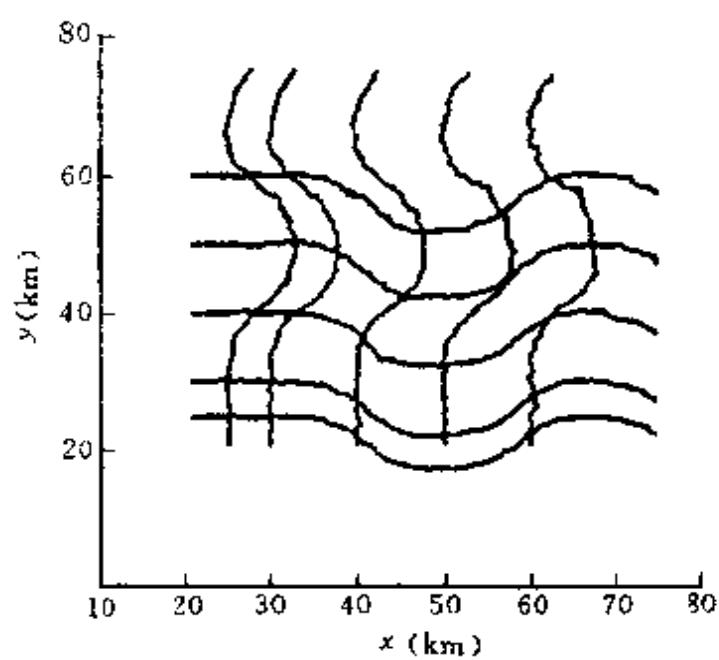


图 8.5 10 个目标作 S 形编队飞行时的跟踪曲线

表 8.2 跟踪 6 个交叉目标的估计均值误差、  
均方根误差和误差压缩比

目标	R 通道(m)			A <sub>x</sub> 通道(rad)			A <sub>y</sub> 通道(rad)		
	MS	REMS	S <sub>N</sub>	MS	REMS	S <sub>N</sub>	MS	REMS	S <sub>N</sub>
1	205.3	234.5	0.477	-0.00011	0.00458	0.514	-0.00321	0.00378	0.498
2	202.8	233.0	0.506	-0.00273	0.00342	0.413	-0.00047	0.00473	0.551
3	312.2	344.1	0.583	-0.00215	0.00359	0.498	-0.00417	0.00471	0.554
4	270.1	304.6	0.517	-0.00333	0.00458	0.524	-0.00244	0.00476	0.557
5	49.4	129.6	0.527	-0.00151	0.00363	0.361	0.00157	0.00398	0.373
6	51.5	130.1	0.522	0.00199	0.00400	0.358	-0.00174	0.00351	0.356

表 8.3 跟踪 10 个 S 形编队飞行机动目标的估计均值误差、  
均方根误差和误差压缩比

目标	R 通道(m)			A <sub>x</sub> 通道(rad)			A <sub>y</sub> 通道(rad)		
	MS	REMS	S <sub>N</sub>	MS	REMS	S <sub>N</sub>	MS	REMS	S <sub>N</sub>
1	220.9	280.3	0.505	0.000106	0.00393	0.582	-0.00286	0.00419	0.544
2	216.6	262.0	0.476	-0.00224	0.00374	0.527	0.00127	0.00345	0.549
3	165.0	245.7	0.482	0.00126	0.00383	0.534	-0.00253	0.00407	0.617
4	278.0	320.8	0.548	-0.00245	0.00384	0.575	0.000809	0.00305	0.446
5	153.8	256.4	0.481	0.00172	0.00363	0.510	-0.00238	0.00360	0.520
6	130.9	271.8	0.510	-0.00171	0.00340	0.593	0.00136	0.00362	0.537
7	200.2	281.7	0.493	0.00131	0.00362	0.551	-0.00224	0.00394	0.488
8	222.7	279.7	0.502	-0.00187	0.00370	0.538	0.00122	0.00316	0.518
9	193.2	256.7	0.445	0.00110	0.00354	0.535	-0.00189	0.00370	0.476
10	187.6	246.0	0.511	-0.00168	0.00327	0.502	-0.00118	0.00304	0.497

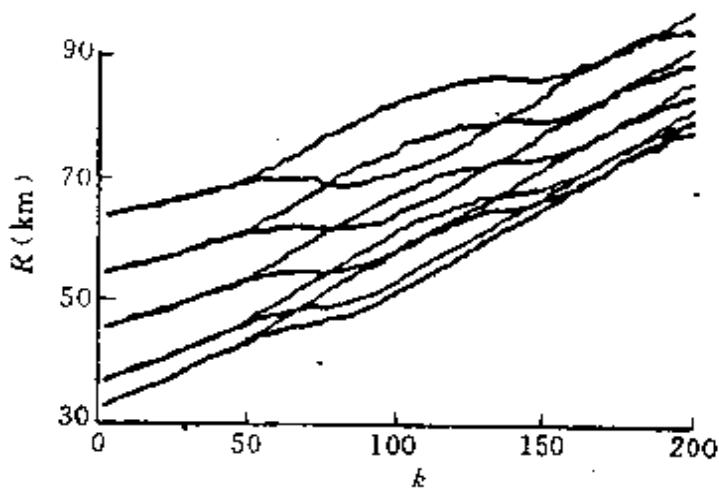


图 8.6 10 个目标作 S 形编队飞行时的  $R$  估计曲线

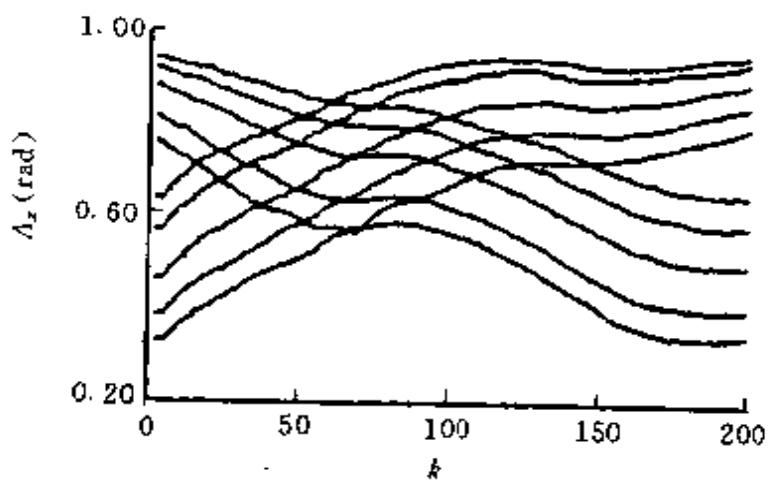


图 8.7 10 个目标作 S 形编队飞行时的  $A_x$  估计曲线

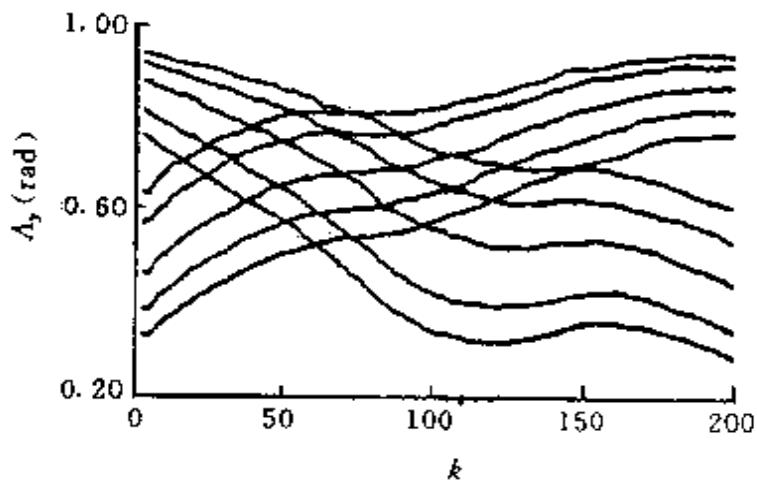


图 8.8 10 个目标作 S 形编队飞行时的  $A_y$  估计曲线

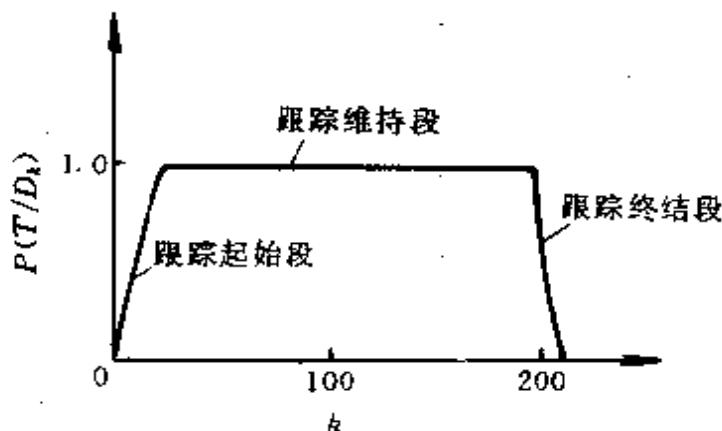


图 8.9 整个跟踪过程中的  $P(T/D_k)$  变化曲线

## 8.6 结论

本章的研究再次表明, 第一篇提出的基于随机神经网络的快速自适应跟踪算法 FSNJPDAAF 和 SNABTIT 能有效可靠地跟踪三维空间和密集回波环境下的机动多目标; 相对于 JPDAF, 本算法的计算量由  $O(n!)$  量级下降为  $O(n)$  量级, 其中  $n$  为被跟踪的目标数和候选回波数之和, JPDAF 的计算组合爆炸问题因而从根本上得到了解决。

在高密集目标环境下, 为了限制随机神经网络维数的增大, 进一步降低算法的计算量, 可行的途径是根据聚矩阵中列向量 ( $t = 1, 2, \dots$ ) 的“1”范数分析目标的相关态势, 对相互关联的目标群应用 FSNJPDAAF, 而对互不相关的目标分别应用 PDAF。这样, 跟踪系统的快速性将大大提高。

# 第九章 回顾与展望

## 9.1 引言

本文的研究工作表明,传统跟踪理论的数据关联计算组合爆炸问题已经基本解决,神经网络跟踪理论体系已经基本形成。

本章首先回顾本文的主要成果,并对未来的发展方向给予展望。

## 9.2 研究成果回顾

### 9.2.1 机动目标信息融合与并行自适应跟踪

机动目标“当前”统计模型及均值和方差自适应算法对高度机动目标具有良好的自适应跟踪性能,但对弱机动特别是非机动目标,由于系统方差的有限调整而带来跟踪精度下降;另一方面,该模型的系统方差自适应仅仅利用了加速度估计信息。为了克服此缺陷,本书基于前馈神经网络,利用全状态反馈,提出一种新的基于神经网络的机动目标信息融合与并行自适应跟踪算法,达到了对目标各种运动状态的良好自适应跟踪能力。

### 9.2.2 基于随机神经网络的多目标数据关联

JPDA 方法由于其优良的数据关联性能而受到人们的高度重视,但随着目标和回波数目的增加,计算量出现组合爆炸现象,限制了其广泛的实际应用。本书利用 Boltzmann 随机神经网络和增益模拟退火,克服了 JPDA 的计算组合爆炸、网络演化收敛慢和易于陷入局部极小等缺陷,所提出的 FSNJPDA 算法具有快速求解

数据关联组合优化的能力。

### 9.2.3 随机神经网络的组合参数优化

随机神经网络的组合参数优化,至今仍是一大难题,目前的文献仅采用试凑的经验方法,而且常常由于参数选取不当而产生网络不稳定现象。本书基于参数稳定性、灵敏度和鲁棒性理论,借助计算机仿真技术,提出了一种求解网络最优组合参数的方法,解决了这一设计中急需解决的问题。

### 9.2.4 机动多目标快速神经自适应跟踪维持

在 FSNJPDA 基础上,本书提出了一种新的适合密集回波环境和机动多目标的快速随机神经自适应跟踪维持算法 FSNJPDAAF。研究结果表明,该算法具有很高的收敛速度和跟踪精度,对杂波环境和目标的不确定性具有良好的自适应能力和鲁棒性能。

### 9.2.5 基于随机神经网络和 Bayes 后验推理的机动多目标跟踪起始与终结

本书基于 Bayes 后验推理和随机神经网络,提出了一种适合密集回波环境和机动多目标的随机神经全邻 Bayes 跟踪起始与终结算法 SNABTIT,克服了“全邻”相关方法缺乏跟踪起始与终结机理的缺陷,仿真结果证明了该算法的有效性和可靠性。

### 9.2.6 三维空间中的机动多目标神经自适应跟踪

本书在余弦坐标系下,采用混合状态变量,导出了一种新的状态方程——三通道形式上解耦的线性目标运动模型,避免了非线性模型线性化带来的模型误差,与耦合模型相比,大大降低了滤波计算量;同时将第一篇提出的 FSNJPDAAF 算法成功地应用于三维空间的机动多目标跟踪中,再次证明了该算法的有效性,为实际应用开辟了一条新的有效途径。

### 9.3 研究展望

本书工作应在下述几方面深入研究和探索。

#### 9.3.1 神经网络计算机实现方法

由于超大规模集成电路(VLSI)技术的日趋成熟,研究基于VLSI神经计算机的各种神经自适应跟踪器实现技术已成为可能<sup>[9]</sup>。开发模拟VLSI、数字VLSI、模/数混合和光电等实现技术,并基于矩阵形式、高度并行和规则模块化的体系结构是实现该技术的关键所在<sup>[93~95]</sup>。此外,光学神经计算机也是这种实现技术所追求的目标<sup>[96,97]</sup>。

#### 9.3.2 多处理机并行实现方法

利用现有大量的快速传统串行计算机构成并行阵列计算系统,附加大量的软件,实现神经网络的功能;或者在通用串行数字机上插入神经网络加速板形成神经计算机工作站,是多处理机并行实现的有效方法<sup>[98,99]</sup>。此外,采用虚拟实现、Systolic阵列和基于信息传输的多处理并行机也是目前适合于神经网络跟踪计算的体系结构<sup>[100]</sup>。

#### 9.3.3 多传感器多目标信息融合

多传感器多目标信息融合是集探测、控制、指挥、通信与情报为一体的大规模C<sup>3</sup>I系统的一个重要组成部分。将基于计算智能包括神经网络与传统人工智能技术相结合而产生的智能融合系统代表着该领域未来的发展方向<sup>[101~104]</sup>。

由于多传感器具有信息冗余、互补、及时和低成本等特点,易于获得被感知对象(多目标图象和环境)的一致性解释,尤其适合于现代战争中恶劣环境和全天候条件下的多目标识别与跟踪。主要内容包括在雷达、电视、激光测距、前视红外图象传感器、敌我识

别器和全球定位系统(GPS)等声光电传感器基础上,建立分布式集成化系统结构,研究多传感器多目标状态融合方法,建立合作与非合作式自动目标识别与分类融合专家系统,提出威胁判断和环境态势评估决策融合准则等,为指挥与决策者提供易于理解的信息和丰富生动的战场画面。

## 参考文献

- 1 Wax N. Signal-to-noise improvement and the statistics of tracking populations. *Journal of Applied Physics*, 1955, 26:586~595
- 2 Shiller R W. An optimal data association problem in surveillance theory. *IEEE Transactions on Military Electronics*, 1964, 8(2):125~139
- 3 Kalman R E. A new approach to linear filtering and prediction problems. *Journal of Basic Engineering*, 1960, 35~46
- 4 Jaffer A J, Bar-Shalom Y. On optimal tracking in multiple target environments. *Proceedings of the third Symposium on Non-Linear Estimation Theory and Its Applications*, San Diego, 1972, 112~117
- 5 Bar-Shalom Y, Tse E. Tracking in a cluttered environment with probabilistic data association. *Automatica*, 1975, 11(9):451~460
- 6 Singer R A, Stein J J. An optimal tracking filter for processing sensor data of imprecisely determined origin in surveillance systems. *Proceedings of the 1971 IEEE Conference on Decision and Control*, Miami Beach, 1971, 171~175
- 7 Singer R A, Sea R G, Housewright K B. Derivation and evaluation of improved tracking filters for use in dense multi-target environments. *IEEE Transactions on Information Theory*, 1974, 20(7):423~432
- 8 Aleksander I, Morton H. *An introduction to neural computing*. Padstow Corn wall: T. J. Press Ltd., 1990
- 9 Yoh-Han, Pao. *自适应模式识别与神经网络*. 北京: 科学出版社, 1992
- 10 斯蕃等. *神经网络与神经计算机*. 成都: 西南交通大学出版社, 1991
- 11 焦李成. *神经网络系统理论*. 西安: 西安电子科技大学出版社, 1990
- 12 何明一. *神经计算: 原理、语言、设计、应用*. 西安: 西安电子科技大学出版社, 1992
- 13 周宏仁, 敬忠良, 王培德. *机动目标跟踪*. 北京: 国防工业出版社, 1991
- 14 Bar-Shalom Y, Fortmann T E. *Tracking and data association*. New York: Academic Press Inc., 1988
- 15 Friedland B. Optimum steady-state position and velocity estimation using noisy sampled position data. *IEEE Transactions on Aerospace and Electronic Systems*, 1973, 9(6):906~111
- 16 Hampton R L T, Cooke J R. Unsupervised tracking of maneuvering Vehicles. *IEEE Transactions on Aerospace and Electronic Systems*, 1973, 9(2):197~207
- 17 Singer R A. Estimating optimal tracking filter performance for manned maneu-

- vering targets. *IEEE Transactions on Aerospace and Electronic Systems*, 1970, 6(4): 473~483
- 18 Moose R L. An adaptive state estimation solution to the maneuvering target problem. *IEEE Transactions on Automatic Control*, 1975, 20(6):359~362
- 19 Gholson N H, Moose R L. Maneuvering target tracking using adaptive state estimation. *IEEE Transactions on Aerospace and Electronic Systems*, 1977, 13(3): 310~316
- 20 Moose R L, Vanlandingham H F, McCabe D H. Modeling and estimation for tracking maneuvering targets. *IEEE Transactions on Aerospace and Electronic Systems*, 1979, 15(3):448~456
- 21 Howard R A. System analysis of semi-Markov processor. *IEEE Transactions on Military Electronics*, 1964, 8(2),114~124
- 22 Kendrick J D, Maybeck P S, Reid J G. Estimation of aircraft target motion using orientation measurements. *IEEE Transactions on Aerospace and Electronic Systems*, 1981, 17(2):254~259
- 23 Zhou Hongren, Kumar K S P. A current statistical model and adaptive algorithm for estimating maneuvering targets. *AIAA Journal, Guidance, Control and Dynamics*, 1984, 7(5)
- 24 Zhou Hongren, Kumar K S P. An adaptive algorithm for estimating the acceleration of highly maneuvering targets. *Proceedings for 21st Conference on Decision and Control*, Orlando, 1982, 3
- 25 彭永华,吴俊杰.采用自适应滤波技术的机载雷达跟踪系统. *航空学报*,1988, 9(4):192~199
- 26 McAulay R J, Denlinger E. A decision-directed adaptive tracker. *IEEE Transactions on Aerospace and Electronic Systems*, 1973, 9(2):229~236
- 27 Thorp J S. Optimal tracking of maneuvering targets. *IEEE Transactions on Aerospace and Electronic Systems*, 1973, 9(4),512~519
- 28 Middleton D, Esposito R. Simultaneous optimum detection and estimation of signals in noise. *IEEE Transactions on Information Theory*, 1968, 14(3):434~444
- 29 Magill D T. Optimal adaptive estimation of sampled stochastic process. *IEEE Transactions on Automatic Control*, 1965, 10(5):434~439
- 30 Chan Y T, Ho A G C, Plant J B. A Kalman filter based tracking scheme with input estimation. *IEEE Transactions on Aerospace and Electronic Systems*, 1979, 15(2):237~244
- 31 Chan Y T, Plant J B, Bottomley J R T. A Kalman tracker with a simple input estimator. *IEEE Transactions on Aerospace and Electronic Systems*, 1982, 18

- (2):235~241
- 32 Bogler P L. Tracking a maneuvering targets using input estimation. IEEE Transactions on Aerospace and Electronic Systems, 1987, 23(3):298~310
- 33 Bar-Shalom Y, Birmanwal K. Variable dimension filter for maneuvering target tracking. IEEE Transactions on Aerospace and Electronic Systems, 1982, 18(5):611~619
- 34 Blom H A P. An efficient filter for abruptly changing systems. Proceedings of IEEE 23rd Conference on Decision and Control, Las Vegas, 1984, 656~658
- 35 Blom H A P, Bar-Shalom Y. The interacting multiple model algorithm for systems with Markovian switching coefficients. IEEE Transactions on Automatic Control, 1988, 23(8):780~783
- 36 Bar-Shalom Y, Blom H A P. Tracking a maneuvering target using input estimation versus the interacting multiple model algorithm. IEEE Transaction on aerospace and Electronic Systems, 1989, 16(2):296~300
- 37 Blackman S S. Multiple-target tracking with radar application. Dedham: Artech House Inc., 1986
- 38 Sea R G. An efficient suboptimal decision procedure for associating sensor data with stored tracks in real-time surveillance systems. Proceedings of the IEEE Conference on Decision and Control, Miami Beach, 1971, 33~37
- 39 Farina A, Studer F A. Radar data processing. England: Research Studies Press Ltd., 1985
- 40 Sea R G. Optimal correlation of sensor data with tracks in surveillance system. Proceedings of the sixth International Conference on System Sciences, Honolulu, 1973, 424~426
- 41 Stein J J, Blackman S S. Generalized correlation of multi-target track data. IEEE Transactions, Aerospace Electronic Systems, 1975, 11(6):1207~1217
- 42 Lefferts R E. Adaptive Correlation regions for alpha-beta tracking filters. IEEE Transactions, Aerospace and Electronic Systems, 1981, 17(1):122~130
- 43 Zhou B, Bose N K. Multitarget tracking in clutter: fast algorithms for data association. IEEE Trans. AES-29, 2, April 1993, 352~363
- 44 Singer R A, Sea R G, Housewright K B. Derivation and evaluation of improved tracking filters for use dense multitarget environments. IEEE Transactions, Information Theory, 1974, 20(7):423~432
- 45 Reid D B. An algorithm for tracking multiple targets. IEEE Transactions, Automatic Control, 1979, 24(6):843~854
- 46 Singer R A, Sea R G. A new filter for optimal tracking in dense multitarget envi-

- ronments. Proceedings of the ninth Allerton Conference Circuit and System Theory, Urbana, 1971, 201~211
- 47 Singer R A, Stein J J. An optimal tracking filter for processing sensor data of imprecisely determined origin in surveillance system. Proceedings of the tenth IEEE Conference on Decision and Control, Miami Beach, 1971, 171~175
- 48 Bar-Shalom Y, Jaffer A G. Adaptive nonlinear filtering for tracking with measurements of uncertain origin. Proceedings of the 11th IEEE Conference on Decision and Control, 1972, 243~247
- 49 Bar-Shalom Y, Tse E. Tracking in a cluttered environment with probabilistic data association. Automatica, 1975, 11(5):451~460
- 50 Bar-Shalom Y. Extension of the probabilistic data association filter in multi-target tracking. Proceedings of the 5th Symp. on Nonlinear Estimation, 1974, 16~21
- 51 Jing Zhongliang, Zhou Hongren, Wang Peide. An effective algorithm for tracking multiple maneuvering targets. The 11th World Congress of IFAC, Tallinn, 1990
- 52 王培德, 周宏仁, 敬忠良. 残差滤波及其在密集多回波环境下机动多目标跟踪中的应用. 航空学报, 1988, 9(5):281~289
- 53 Morefield C L. Solution of multiple choice estimation problem via 0-1 integer programming. Proceedings of the 13th IEEE Conference on Decision and Control, 1974, 753~754
- 54 Morefield C L. Efficient computational forms for Bayesian multitarget tracking. Proceedings of the 6th Symp. Nonlinear Estimation Theory and its Applications, 1975, 208~216
- 55 Morefield C L. Application of 0-1 integer programming to a track assembly problem. Proceedings of the 14th IEEE Conf. on Decision and Control, 1975, 428~433
- 56 Morefield C L. Application of ILLIAC IV parallel processor to multitarget tracking problems. Proceedings of the 10th Annual Asilomar Conference Circuit, System and Computers, 1976
- 57 Morefield C L. Application of 0-1 integer programming to multitarget tracking problems. IEEE Transactions, Automatic Control, 1977, 22(3):302~312
- 58 Alspach D L, Sorenson H W. Recursive Bayesian estimation using Gaussian sums. Automatica, 1971, 7:465~479
- 59 Alspach D L. A Gaussian sum approach to the multitarget identification-tracking problem. Automatica, 1975, 11:285~296

- 60 Smith P, Buechler G. A branching algorithm for discriminating and tracking multiple objects. *IEEE Transactions on Automatic Control*, 1975, 20(2):101~104
- 61 Stein J J, Blackman S S. Generalized correlation of multitarget track data. *IEEE Transactions on Aerospace and Electronic Systems*, 1975, 11(6):1207~1217
- 62 Fitzgerald R J. Development of practical PDA logic for multitarget tracking by microprocessor. *Proc. of American Controls Conf.*, Seattle, USA, 1985, 889~898
- 63 Hole P G. *Introduction to mathematical statistics*. New York: John Wiley and Sons, 1971
- 64 Holmes J E. Development of algorithms for the formation and updating of tracks. *Proceedings of IEEE International Radar Conference*, London, 1977, 81~85
- 65 Fleskes W, Van Keuk G. Adaptive control and tracking with the ELRA phased array radar experimental system. *Proceedings of 1980 IEE International Radar Conference*, Arlington, 1980, 8~13
- 66 Casner P G, Prengaman R J. Integration and automation of multiple colocated radars. *proceedings of the IEE 1977 International Radar Conference*, London, 1977, 145~149
- 67 Bath W G. False alarm control in automated radar surveillance systems. *Proceedings of the IEE 1982 International Radar Conference*, London, 1982, 71~75
- 68 Chang C B, Athans M. State estimation for discrete systems with switching parameters. *IEEE Transactions on Aerospace and Electronic Systems*, 1978, 14(3):418~425
- 69 Chang C B, Tabaczynski J A. Application of state estimation to target tracking. *IEEE Transactions on Automatic Control*, 1984, 29(2): 98~109
- 70 Trunk G V, Wilson J D. Track initiation in a dense detection environment. AD-A060744, 1987
- 71 Trunk G V, Wilson J D. Track initiation of occasionally unresolved radar targets. *IEEE Transactions on Aerospace and Electronic Systems*, 1981, 17(1):122~129
- 72 Smith M C, Winter E M. On the detection of target trajectories in a multi-target Environments. *Proceedings of the 1978 IEEE Conference on Decision and Control*, San Diego, 1979, 1189~1194
- 73 Smith M C. Feature space transform for multitarget detection. *Proceedings of the 1980 IEEE Conference on Decision and Control*, Albuquerque, 1980, 835~

- 836
- 74 Duda R O, Hart P E. Use of the hough transform to detect lines and curves in pictures. *Communications of the ACM*, 1972, 15(1):11~15
- 75 Wishner R P. Advanced techniques for multi-target track formation. *Advanced Information and Decision Systems Report*, No. 1005, AD B057823, 1981
- 76 Barniv Y. Dynamic programming solution for detecting dim moving targets. *IEEE Transactions on Aerospace and Electronic Systems*, 1985, 21(1):144~156
- 77 Castellia F R. Sliding window detection probabilities. *IEEE Transactions on Aerospace and Electronic Systems*, 1976, 12(6):815~819
- 78 Sengupta D, Iltis R A. Neural solution to the multitarget tracking data association problem. *IEEE Transactions on Aerospace and Electronic Systems*, 1989, 25(1): 96~108
- 79 Kuczewski R M. Neural network approaches to multi-target tracking. *Proceedings of 1st IEEE International Conference on Neural Network*, 1987, 4, 619~633
- 80 Rumelhart D, McClelland J. Parallel distributed processing: Explorations in the microstructure of cognition. Cambridge: Bradford Books, MIT Press, 1986
- 81 Nielsen R H. Theory of the back-propagation neural network. *Proc. of IEEE International Conf. on Neural Network*, 1989
- 82 Kronhamn T R. Adaptive target tracking with serial Kalman filters. *Proc. of 24th Conf. on Decision and Control*, Ft. Lauderdale, FL., Dec. 1985
- 83 陶涛. 不确定多目标的“全面”自适应跟踪. 华中理工大学博士学位论文, 1991
- 84 Hopfield J J, Tank D W. "Neural" computation of decisions in optimization problems. *Biol. Cybern.*, 1985, 52:141~152
- 85 Wilson G V, Pawley G S. On the stability of the travelling salesman problem algorithm of Hopfield and Tank. *Biol. Cybern.*, 1988, 58:63~70
- 86 刘昆焱, 金道衡. 微机上 200 城市 TSP 人工神经网络解的实现. 中国神经网络首届学术大会论文集, 1990, 887~890
- 87 Kirkpatrick S, Gelatt C, Vecchi M. Optimization by simulated annealing. *Science*, 1983, 220:671~680
- 88 Eugene Wong. Stochastic neural networks. *Algorithmica*, 1991, 6:466~478
- 89 Fortmann T E, Bar-Shalom Y, Scheffe M. Sonar tracking of multiple targets using joint probabilistic data association. *IEEE Journal of Oceanic Engineering*, 1983, 8(3):173~184
- 90 敬忠良. 数据处理 CAD 数学模型研究. 研究报告, 1993
- 91 Irie B, Miyake S. Capabilities of three-layered perceptrons. *Proc. of IEEE In*

- ter. Conf. on Neural Networks, 1988, (1), 641~648
- 92 Hecht-Nielsen R. The theory of backpropagation neural network. In review, 1988
- 93 Murry A F, Smith A V. Asynchronous VLSI neural networks using pulse stream arithmetic. IEEE Jour. Solid State Circuit and Systems, 1988, 23(3), 688~697
- 94 Goser K, Ruchert U. VLSI design of associative networks. Proc. of Inter. Workshop on VLSI for AI, University of Oxford, 1988
- 95 Sivilotti M, Emerling M, Mead C. VLSI architectures for implementation of neural networks. AIP Conf. Proc., 1986, (151), 408~413
- 96 母国光等. 光学神经网络的特点、模型和应用. 神经元网络及应用学术讨论会论文集, 1989, 35~45
- 97 Conrad M. The lure of molecular computing. Spectrum, 1988, 55
- 98 李孝安等. 人工神经网络仿真计算机 NSC. 中国神经网络首届学术大会论文集, 1990, 512~522
- 99 解传圣. Transputer 与神经计算机. 计算机世界, 1990(282), 52~56
- 100 斯普. 神经网络与神经计算机的基本原理和应用. 计算机应用, 1991(3), 51~59
- 101 Bar-Shalom Y. Multitarget-multisensor tracking: advanced applications. New York: Artech House Inc., 1990
- 102 Waltz E, Llinas J. Multisensor data fusion. New York: Artech House Inc., 1990
- 103 Roth M W. Survey of neural networks technology for automatic target recognition. IEEE Trans. on Neural Networks, 1990, 1
- 104 Luo, Ren E, Michael G Kay. Multisensor integration and fusion in intelligence systems. IEEE Trans. on SMC, 1989, 19(5)
- 105 Fisher J L, Cusasant D P. Fast JPDA multitarget tracking algorithm. Applied Optics, 1989, 28
- 106 Jing Zhonghang, Zhou Hongren, Wang Peide. An effective algorithm for tracking multiple maneuvering targets. Preprints of the 11th IFAC World Congress, Tallinn, USSR, Vol. 3, Aug. 1990, 47~52
- 107 Jing Zhongliang, Zhou Hongren, Wang Peide. Tracking initiation and termination of multiple maneuvering targets in a dense multi-return environment. Proc. of the 20th IEEE Conf. Decision and Control, Hawaii, USA, Vol. 4, Dec. 1990, 2270~2275
- 108 Jing Zhongliang. An effective algorithm for initiation of tracking of multiple maneuvering targets. Journal of Northwestern Polytechnical University, Aug. 1991

- 109 Jing Zhongliang, Zhang Guowei, Zhou Hongren. A quick algorithm of neural combinatorial optimization to data association problem of multi-maneuvering target tracking. Proc. of 1993 IEEE Conf. Neural Networks, San Francisco, USA, Vol. 1, March 1993, 263~268
- 110 Jing Zhongliang, Zhang Guowei, Zhou Hongren. A fast adaptive neural network scheme for multi maneuvering target tracking. Proc. of 32nd IEEE Conf. Decision and Control, San Antonio, USA, Vol. 4, Dec. 1993, 3253~3258
- 111 Jing Zhongliang, Xu Hong, Zhou Xueqin. Information fusion and tracking of maneuvering targets with artificial neural network. Proc. of 1994 World Congress on Computational Intelligence, Orlando, USA, June 1994
- 112 敬忠良,戴冠中,佟明安,周宏仁. Stochastic neural network and its application to multi-maneuvering target tracking. Chinese Journal of Aeronautics, 1995, 3(1)
- 113 敬忠良,周宏仁,王培德. 一种密集多回波环境下的机动多目标跟踪起始算法. 航空学报, 1989, 10(11): 580~587
- 114 敬忠良,周宏仁,王培德. 密集多回波环境下的机动多目标跟踪终结决策. 控制与决策, 1989, 4(5): 30~35
- 115 张国伟,敬忠良,周宏仁. 基于神经网络的机动多目标数据关联问题研究. 信息与控制, 1993, 22(2): 90~96
- 116 敬忠良,张国伟,周宏仁. 随机神经网络在机动多目标跟踪中的应用. 航空学报, 1993, 22(2): 90~96
- 117 敬忠良,张国伟,周宏仁. 基于随机神经网络的多目标数据关联组合优化研究. 控制理论与应用, 1994, 11(3): 257~263
- 118 敬忠良. 机动目标模型与自适应跟踪算法综述. 空载雷达, 1991, 4, 1~9
- 119 敬忠良. 密集多回波环境下的机动多目标跟踪统一理论. 中国自动化学会第三届全国学术大会论文集, 北京, 1991(12)
- 120 敬忠良,周宏仁,王培德. 机动多目标跟踪统一方法. 全国控制理论及应用学术年会论文集, 威海, 1991(10)
- 121 敬忠良. 机动目标跟踪中的自适应滤波. 中国航空学会第三届控制与应用学术年会论文集, 温江, 1987(8)
- 122 敬忠良,周宏仁,王培德. 多目标跟踪起始与终结决策方法. 中国航空学会第四届控制与应用学术年会论文集, 厦门, 1990(5)
- 123 张国伟,敬忠良,周宏仁. 神经网络在机动多目标数据关联中的应用. 中国航空学会第五届控制与应用学术年会论文集, 大连, 1992(8)
- 124 敬忠良,张国伟,周宏仁. 基于神经网络的机动多目标快速自适应跟踪. 第一届全球华人智能控制与智能化世界大会, CWC, ICIA'93, 北京, 1993(8)
- 125 敬忠良,徐宏,周雪琴,戴冠中. 一种机动目标信息融合与并行自适应跟踪算法.

